

理论物理 · 讲义系列

人工智能的物理学基础

Phys4AI 讲义（一）

——*The Physics Foundation of Artificial Intelligence*——

课程名称 人工智能的物理学基础（一）
授课教师 兰晨，耿慧芳
适用专业 物理学 / 应用数学
学时安排 18 周，每周理论 2 学时 + 上机 2 学时
版本日期 2026 年 7 月 29 日

烟台大学 · 物理与电子信息学院

本讲义仅供课程学习使用



摘要

本讲义尝试从物理学的角度，介绍人工智能的基本思想与数学基础，重点是统计力学与机器学习之间的深刻联系。这两个领域通常被视为彼此独立：前者研究由大量微观自由度构成的物理系统，后者研究如何从数据中提取规律。但二者都要处理高维、随机、由大量自由度共同决定宏观行为的复杂系统，也因此共享一套数学结构——概率分布、熵、自由能、配分函数、涨落与相变——这套语言同样可以用来理解机器学习中的概率模型、损失函数、模型复杂度与泛化行为。

全部讲义计划分三个部分。本卷是第一部分，从概率和统计描述出发，依次引入熵、自由能、配分函数与玻尔兹曼分布，并展示这些概念如何在机器学习中反复出现、以不同的名字延续下去。第二部分将讨论神经网络的物理模型，第三部分转向优化与学习动力学；三部分合起来，构成一条从统计描述、到模型结构、再到学习过程的完整线索。

本讲义面向具有大学物理基础、但未必受过系统机器学习训练的读者，尤其适合物理、数学及相关专业的本科生与研究生。写作时始终强调物理直觉、数学推导与计算实验三者之间的相互印证，而不是单纯的类比罗列。

有过我的车辙的地方，也都有过母亲的脚印。

——史铁生《我与地坛》

前言

本讲义源于作者自 2023 年起在烟台大学物理专业本科生中设计的一门课程。课程最初名为《Python 物理高效计算》，目标是把深度学习等现代人工智能方法引入计算物理教学，探索人工智能在物理学中的应用（AI for Physics, AI4Phys）。随着教学实践和内容的不断拓展，课程逐渐转向一个更基础的问题：能否反过来，用物理学——尤其是统计力学的思想和方法——去理解人工智能本身？这门课因此逐步发展成了现在的《人工智能的物理学基础》。

本课程共 18 周，每周 4 学时，其中 2 学时为理论课、2 学时为上机实践课。本讲义对应的是理论课部分：上机课以本讲义建立的物理图像为背景，安排相应的编程练习与数值实验，与理论课互为印证，但内容组织各自独立，本讲义不包含上机课的具体安排。

本讲义的核心目标，是为物理专业学生搭建一座连接统计力学与机器学习的桥梁。两者通常被视为相对独立的领域，但在数学结构与思想方法上有深刻的共通之处：都要处理高维空间中的复杂系统，都必须面对随机性与大量自由度共同产生的集体现象。概率分布、熵、自由能、配分函数、涨落和相变等统计力学概念，也能够为理解机器学习中的损失函数、概率模型、模型复杂度、泛化以及学习行为提供统一的语言。

本讲义分为三个部分，计划分别对应三个学期的教学内容。本书的第一部分，即本卷，主要建立统计力学与机器学习之间的基本联系。我们将从概率和统计描述出发，逐步引入熵、自由能、配分函数和玻尔兹曼分布，并考察这些概念如何在机器学习中以不同形式反复出现。读者会看到，这种相似性并非简单的形式类比，而是源于两个领域在处理复杂、高维和不确定系统时所共享的数学结构——但书中也会同样明确地指出，哪些地方这种相似只是类比，不能直接当作严格的等价关系使用。

在此基础上，第二部分将进一步讨论神经网络的物理模型，第三部分则转向优化与学习动力学，研究模型如何通过动力学过程从数据中获得结构。三部分共同构成一条由统计描述、模型结构到学习过程的逻辑主线，试图从物理学的角度回答一个基本问题：

人工智能为什么能够从复杂数据中学习出规律？

本讲义面向具有大学物理基础、但未必接受过系统机器学习训练的读者，尤其适合物理、数学及相关专业的本科生和研究生使用，阅读时只需要微积分、线性代数与经典力学、热学的基本训练，不预设任何机器学习基础。物理直觉、数学推导与计算实验三者的相互印证，是贯穿全书的写作原则——书中的计算实验部分，主要通过与本讲义配套的上机课来完成。

讲义除正文内容外，每章还配有不同层次的习题，供读者根据自己的学习进度逐步完成。习题分为“基础题”、“进阶题”和“挑战题”三个层次：基础题用于巩固本章的核心概念与推导，多数只需重复章节中已经演示过的计算步骤；进阶题要求将所学方法应用到新的问题情境，通常需要独立完成一次较完整的分析与推导；挑战题则往往需要查阅适当的课外资料，或结合简单的数值计算与编程实验完成，旨在帮助读者进一步体会本书所介绍思想在更广泛问题中的应用。



目录

摘要	i
前言	iii
第一章 人工智能的世界地图	1
1.1 当我们谈论机器学习时我们在谈论什么?	2
1.2 为什么偏偏是统计物理?	9
1.3 全书第一部分导览	12
1.4 AI 也在改变物理研究本身	13
第二章 从经典统计物理说起	17
2.1 计数原理：宏观概率的集中效应	18
2.2 正则系综与玻尔兹曼分布的推导	20
2.3 一维伊辛模型：相互作用系统的精确解	28
第三章 机器学习中的概率模型	41
3.1 监督学习的基本设定	42
3.2 概率建模的基本假设	44
3.3 最大似然估计 (MLE)	46
3.4 最大后验估计 (MAP)	48
第四章 损失函数作为能量函数	57
4.1 核心类比	58
4.2 例子一：线性回归	59
4.3 例子二：逻辑回归	64
4.4 例子三：Softmax 回归 (多分类)	68
第五章 配分函数与归一化	75
5.1 归一化的普遍性	76
5.2 无向图模型 (Markov Random Fields)	76
5.3 配分函数的计算挑战	84
5.4 近似方法概述	86
第六章 自由能与损失函数的深层联系	91
6.1 变分自由能的物理推导	92

6.2	机器学习中的变分推断	95
6.3	物理—机器学习对应表	97
6.4	平均场近似	98
第七章	最大熵原理	105
7.1	统计力学中的最大熵原理	106
7.2	最大熵在机器学习中的应用	109
7.3	最小交叉熵原理	111
附录 A	常用记号与公式速查	123
A.1	概率论与数学工具记号	123
A.2	图与马尔可夫随机场记号	123
A.3	变分自由能与 KL 散度主公式	124
A.4	拉格朗日乘数法（用于带约束的熵极值问题）	125
附录 B	常见概率分布与统计量表	127
B.1	常见概率分布	127
B.2	一般定义（不限于特定分布）	128
附录 C	马尔可夫链与 MCMC 基础	129
C.1	平稳分布：反复游走的终点	129
C.2	细致平衡：一个容易验证的充分条件	129
C.3	Metropolis 算法：让细致平衡自动成立	130
C.4	Gibbs 采样：一种特殊的、接受概率恒为 1 的 Metropolis 算法	131
C.5	遍历性：反复跳转真的能走到每一个角落吗？	131

人工智能的世界地图

*Give me the map there. — Know that we
have divided
In three our kingdom...*

— 莎士比亚《李尔王》第一幕第一场，
李尔王

学习目标

- 理解“人工智能”这一名词在今天涵盖的范围，以及“机器学习”在其中的位置；
- 理解机器学习问题的通用结构——输入、模型、输出——即“学习一个函数”这一核心比喻；
- 理解“训练”与“参数”的直观含义，为第三章正式引入似然函数、参数估计等概念做铺垫；
- 亲手算一遍一个小型多层神经网络的前向传播，理解“深度”与“激活函数”的确切含义，为讲义第二部分“神经网络的物理模型”做铺垫；
- 理解概率与不确定性为何会自然地进入机器学习，这正是统计物理即将登场的入口；
- 理解为什么是统计物理、而非经典力学、量子力学或流体力学，构成了理解机器学习最自然的物理语言——这一判断本身有一条可检验的理由，而不是学科背景的偏好；
- 对讲义第一部分（第二至七章）的整体路线建立一张地图，明确每一章要回答的问题、对应的物理概念，以及它们如何前后衔接；
- 知道“用物理解 AI”之外，还存在“用 AI 做物理”这一方向相反、同样重要的故事。

在正式进入统计物理与机器学习相遇的故事之前，本章想先做一件与推导公式无关、却同样重要的事：画一张地图。接下来六章会陆续引入组合计数、玻尔兹曼分布、最大似然估计、损失函数、配分函数、变分自由能、最大熵原理——这些概念彼此之间的联系非常紧密，环环相扣，但如果不预先知道“这一切究竟是为了回答什么问题”，仅凭推导本身很容易让人只见树木、不见森林。本章不含任何需要记忆的公式，也不要求任何机器学习或编程基础，它唯一的目的，是让接下来六章里出现的每一个新名词，都能在你脑海里找到一个清楚的位置。

§1.1 当我们谈论机器学习时我们在谈论什么？

近几年，“人工智能”这个词几乎无处不在：能和你对话、写代码、写论文的 ChatGPT；能从氨基酸序列预测蛋白质三维结构、被认为解决了困扰生物学界数十年难题的 AlphaFold；曾经战胜人类顶尖棋手的围棋程序 AlphaGo；能够根据一段文字描述生成图像的 Stable Diffusion；还有自动驾驶汽车、推荐系统、语音识别……

下棋、画画、开车、预测分子结构、聊天——这些系统看起来做的事情天差地别，却都被统称为“人工智能”。

这提示我们一件事：“人工智能”不是一种单一的技术，而是一整个不断扩张的领域名称。如果不先弄清楚这个领域大致的内部结构，直接一头扎进其中某一个角落（比如本课程接下来要讲的这一支），很容易产生困惑：这些具体的推导，到底是在解决“人工智能”里的哪一部分问题？本节就是想在正式开始之前，把这张地图先展开看一眼。

■ 思考与验证

上面提到的几个系统——ChatGPT、AlphaFold、AlphaGo、Stable Diffusion——如果要你用一句话说出它们的共同点，你会怎么说？

解：一个合理的答案是：它们都不是被人一行一行“编程”出全部具体规则的，而是通过某种方式从大量数据中“学会”了自己的能力。至于这个“学会”具体是什么意思，正是接下来几节要讲清楚的问题。

人工智能这棵树：机器学习在哪里？

一句话概括：今天人工智能的绝大部分实际能力，都来自“机器学习”（Machine Learning）这一支。把人工智能粗略地画成一棵树（图 1.1），大致是这样的结构（这只是众多组织方式中的一种，边界并不像图示这样泾渭分明，但足以帮你在脑海中先安放一个坐标系）：

- 人工智能（Artificial Intelligence）：让机器表现出某种“智能行为”的整个领域。
 - 基于规则/符号的方法：由人预先写好明确的规则、逻辑或搜索算法。例如上世纪的国际象棋程序，主要依靠人工编码的规则和暴力搜索，而不是从棋局数据中“学习”。这类方法在本课程中不会涉及。
 - 机器学习（Machine Learning）：本书的主线。核心特征是模型的行为并非由人直接编写，而是从数据中“学”出来的（后面我们会把“学”这个字具体化）。机器学习内部通常又分为：
 - * 监督学习（Supervised Learning）：数据既有输入、又有“正确答案”（标签），模型的任务是学会从输入预测答案。讲义第一部分（第二至七章）几乎全部围绕这一支展开。
 - * 无监督学习（Unsupervised Learning）：数据只有输入、没有标签，模型需要自己发现数据里的结构或规律。讲义第二部分“神经网络的物理模型”中将讨论的 Hopfield 网络、玻尔兹曼机，大多属于这一支。



图 1.1: 人工智能地图。

- * 强化学习 (Reinforcement Learning): 模型（称为“智能体”）通过与环境反复交互、根据获得的奖励信号调整自己的行为，AlphaGo 正是这一支的代表。
- * 深度学习 (Deep Learning): 并不是与前三者并列的第四个分支，而是一整套用“多层神经网络”实现监督、无监督或强化学习的具体技术，几乎渗透进了机器学习的每一个角落。
- 大语言模型/生成式模型 (LLM / Generative Models): 如 ChatGPT、Stable Diffusion。它们本质上是监督学习与“自监督学习”（一种从数据自身构造标签的巧妙监督学习）在海量文本、图像数据上大规模应用的产物，仍然建立在机器学习的地基之上。

看到这张图（图 1.1），你至少可以确定一件事：本课程接下来要讲的内容，属于机器学习这一支，并且几乎全部集中在监督学习上。这就是我们即将深入的“那一个角落”。

■ 后续预告

讲义第二部分“神经网络的物理模型”会讨论的 Hopfield 网络与玻尔兹曼机，其实属于上面提到的“无监督学习”一支——它们不需要标签，而是让一个由统计物理直接启发的能量模型自己去“记住”或“生成”数据的分布。这也是为什么第二章要不厌其烦地把玻尔兹曼分布、配分函数这套语言打好基础：它不仅服务于本书第一部分的监督学习，也是第二部分的地基。

机器学习到底在解决什么问题？

抛开“学习”这个略带拟人色彩的说法，机器学习问题几乎都可以归结为同一个极其朴素的结构：

输入 → 模型 → 输出

我们来看几个具体例子（图 1.2）：

- 输入一张图片 → 模型 → 输出“猫”（这张图片里是不是猫）；
- 输入一套房子的面积、位置等信息 → 模型 → 输出这套房子的价格（这正是第二、三章将反复使用的例子）；
- 输入一句英文 → 模型 → 输出对应的一句中文；
- 输入一段文字描述 → 模型 → 输出一张符合描述的图片（如 Stable Diffusion）。




图 1.2: 机器学习的具体例子。

这些例子表面上毫不相干，但抽去具体内容后，结构完全相同：都是给定某个输入 x ，希望模型给出我们期望的输出 y 。用最精简的数学语言说，机器学习要做的事情就是学习一个函数 $y = f(x)$ ——但请注意，这里的“学习”二字很关键：这个函数不是由人把对应关系一条条写进代码里的，而是由算法根据大量“输入-输出”样本自动找出来的。这正是机器学习与传统编程最本质的区别：传统编程是“人告诉机器规则”，机器学习是“机器从例子里自己找规则”。

■ 思考与验证

判断下面几个任务分别是“输入是什么，输出是什么”：

- (1) 判断一封邮件是否为垃圾邮件；
- (2) 根据一段心电图信号判断是否存在心律不齐；
- (3) 给一段旋律的开头，续写接下来的几个音符。

解：(1) 输入是邮件内容（可以是文字，也可以是从文字中提取出的一些数字特征），输出是“是”或“否”这一个类别标签；(2) 输入是心电图这段随时间变化的信号，输出同样是一个类别标签；(3) 输入是已有的旋律片段，输出是接下来的音符序列——这一例子提醒我们，“输出”不一定是一个简单的数字或类别，它也可以是一整段结构化的内

容，但“从输入预测输出”这个核心结构并没有变。

什么叫“训练”？

上面我们说过“函数是从数据中学出来的”，但这句话具体是什么意思？下面用一个完全不需要任何公式、只凭直觉就能理解的例子把它讲清楚。

想象你面前有一张纸，纸上画了几个点，横坐标是房子的面积，纵坐标是这套房子的成交价格（这正是第二、三章将要正式使用的数据）。这些点大致沿着一个方向分布——面积越大，价格总体上也越高。现在，你想在这些点中间画一条直线，让它尽可能贴近所有的点。

你会怎么画这条直线？大概率不会一次就画对，而是会先随手画一条，看看它离这些点是不是偏得太远，然后不断地小幅调整这条直线的斜率和截距，直到这条线“看起来”最贴合这些点为止。

这条直线可以写成 $y = ax + b$ 的形式，其中 a （斜率）和 b （截距）这两个数，就是这个模型的参数（parameter）。而你刚才做的这件事——不断调整 a 和 b ，让直线越来越贴近数据点——正是训练（training）这个词最朴素的含义：

训练，就是不断调整模型的参数，使模型的输出越来越接近我们期望的答案。

真实的机器学习模型（比如后面章节会讲到的逻辑回归、Softmax 回归，乃至第二部分要讲的神经网络）当然远比一条直线复杂，参数的数目可以从几个变成几百万甚至更多，但“训练”这个动作在本质上和你刚才手动调整这条直线时做的事情完全一样，只是需要交给计算机、用更系统的算法自动完成——这正是讲义第三部分“优化与动力学”要专门讨论的内容。而“怎样的直线才算贴近数据”、“该往哪个方向调整参数”这些问题，恰恰是接下来第二、三章要正式回答的。

多层神经网络：从单个神经元到深度网络

上面说的直线 $y = ax + b$ 只有两个参数，表达能力非常有限——无论怎么调整 a, b ，它画出来的永远是一条直线，永远无法拟合一条明显弯曲的曲线。真实世界中的大多数规律（一张图片是不是猫、一句话该翻译成什么）显然不是“直线”能描述的。神经网络正是为了获得更强表达能力而设计的一族模型——接下来，我们的目标，是让你在不接触任何反向传播算法的前提下，亲手算一遍神经网络“从输入到输出”这一步（称为前向传播，forward propagation）具体在做什么。这也是讲义第二部分“神经网络的物理模型”的直接铺垫。

从直线到神经元

$y = ax + b$ 只有一个输入 x ：只用房子的面积去预测价格。但现实中价格显然不止取决于面积——装修情况通常也很重要。假设装修情况被量化成一个 1 到 10 分的评分 x_2 （面积仍记作 x_1 ），一个自然的猜测是：装修每提高 1 分，价格大约多值 8 万元；面积每多 1 平方米，价格大约多值 3 万元；再加上一个与地段等其他因素有关的基础价格，比如 30 万元。合在一起，价格的估计值就是

$$\text{价格} \approx 3x_1 + 8x_2 + 30 \quad (\text{单位：万元}) .$$

比如一套 100 平米、装修评分 7 分的房子，预测价格约为 $3(100) + 8(7) + 30 = 386$ 万元。这个式子和 $y = ax + b$ 相比，唯一的变化是：斜率 a 变成了两个数（3 和 8），分别对应两个不同的输入。如果输入是更多个数（记作向量 $\mathbf{x} = (x_1, \dots, x_n)$ ），把上面这个具体例子照搬过去，最自然的推广就是把它们逐一加权、再求和：

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b = \mathbf{w}^T\mathbf{x} + b,$$

其中每个 w_i （权重，weight，对应上面例子里的 3、8）和 b （偏置，bias，对应上面例子里的 30）都是参数，其数目从直线的 2 个增加到了 $n+1$ 个。这一步本身还是“直线”的直接推广（一个超平面），并没有变得更强大。真正带来变化的是下一步：把 z 送入一个激活函数（activation function） σ ，得到

$$a = \sigma(z).$$

这一对“加权求和 + 激活函数”的组合，就称为一个神经元（neuron）。

这里的“神经元”并不是一个随意的名字。它来自生物学中的神经元细胞（nerve cell）（见图 1.3）：在真实的神经系统中，神经元通过树突接收来自其他神经元的信号，将这些信号进行某种整合，并在满足一定条件时通过轴突向外传递信号。早期人工智能研究者受到这一过程的启发，尝试用一个极其简化的数学模型来描述类似的“接收—整合—输出”过程。当然，人工




图 1.3: 神经元（神经细胞）。

神经元并不是生物神经元的精确复制。真实神经元的工作机制涉及复杂的电化学过程，而这里的数学模型只是从中抽取了一个非常粗略但极其重要的思想：多个输入经过加权整合，再通过一个非线性机制产生输出。正是这个简单的思想，构成了现代神经网络中最基本的计算单元。

■ 为什么必须有激活函数？

本节稍后会用具体数字证明：如果 σ 是恒等函数（即不做任何变换， $a = z$ ），那么无论叠多少层神经元，最终算出来的仍然只是输入的一个线性函数——和一条（高维）“直线”毫无区别。激活函数里必须包含某种“弯折”，多层堆叠才有意义。本节使用两种最常见

的激活函数：

$$\text{ReLU}(z) = \max(0, z), \quad \sigma_{\text{sigmoid}}(z) = \frac{1}{1 + e^{-z}}.$$

ReLU 只是“负数归零、正数不变”，算起来最省力，适合手算；sigmoid 会在第四章正式登场——它的具体形式，读者不妨先留意一下，是否似曾相识。

拼成一层，叠成多层

一个神经元只能输出一个数。把若干个神经元并排放在一起，各自独立地对同一个输入 $\mathbf{x}$ 做“加权求和 + 激活”，就构成了神经网络的一层（layer）。把上一层的输出，当作下一层的输入，再重复这一过程，层与层之间串联起来，就得到一个多层神经网络——这正是“深度学习”（deep learning）中“深度”（depth）一词的来源：深度就是层数。用矩阵记号，第 l 层的计算可以统一写成

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = \sigma(\mathbf{z}^{(l)}), \quad (1.1)$$

其中 $\mathbf{a}^{(0)} = \mathbf{x}$ 是网络的输入， $\mathbf{W}^{(l)}$ 的每一行就是该层某一个神经元的权重向量，激活函数 σ 逐元素作用。网络最后一层的输出 $\mathbf{a}^{(L)}$ ，就是整个模型的预测结果 $\hat{y}$ 。




图 1.4: 神经网络（深度学习）。

具体算例：一个可以完全手算的两层网络

抽象公式到此为止，下面用一组具体的数字，把式 (1.1) 从头到尾算一遍。设计一个最小的、但已经具备“深度”结构的网络：输入是 2 维向量 $\mathbf{x} = (x_1, x_2)$ ，隐藏层含 2 个 ReLU 神经元，输出层是 1 个 sigmoid 神经元。

网络参数（人为设定，与训练无关）：

$$\mathbf{W}^{(1)} = \begin{pmatrix} 2 & -1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{b}^{(1)} = \begin{pmatrix} -1 \\ -2 \end{pmatrix} \quad \left(\text{即 } h_1: z_1 = 2x_1 - x_2 - 1, \quad h_2: z_2 = x_1 + x_2 - 2 \right),$$

$$\mathbf{W}^{(2)} = \begin{pmatrix} 3 & -2 \end{pmatrix}, \quad b^{(2)} = 1 \quad (\text{即输出层: } z_{\text{out}} = 3a_1 - 2a_2 + 1).$$

第一步：代入 $\mathbf{x} = (1, 2)$ ，算隐藏层。

$$z_1 = 2(1) - 2 - 1 = -1 \quad \implies \quad a_1 = \text{ReLU}(-1) = 0,$$

$$z_2 = 1 + 2 - 2 = 1 \quad \implies \quad a_2 = \text{ReLU}(1) = 1.$$

第二步：算输出层。

$$z_{\text{out}} = 3(0) - 2(1) + 1 = -1 \quad \implies \quad \hat{y} = \sigma_{\text{sigmoid}}(-1) = \frac{1}{1 + e^1} \approx 0.269.$$

■ 似曾相识的 0.269

这个数字，读者应该并不陌生——它正是第二章表 2.4 中双态系统在 $k_B T = 1$ 时激发态概率 P_1 的数值！这并非巧合：sigmoid 函数 $\sigma(z) = 1/(1 + e^{-z})$ 与玻尔兹曼分布描述的双态系统概率公式，写出来本来就是同一个代数表达式（只是变量的符号约定不同），这一点从两个公式并排放在一起即可直接看出，不需要额外证明。第四章会系统地展开这一联系，正式将其命名为逻辑回归，并推导出对应的损失函数。这里提前让你亲眼“撞见”这个连接。

验证网络确实“非线性”：换一个输入点。取 $\mathbf{x} = (3, 1)$ ： $z_1 = 2(3) - 1 - 1 = 4$ ， $z_2 = 3 + 1 - 2 = 2$ （两者都是正数，ReLU 不裁剪， $a_1 = 4, a_2 = 2$ ）， $z_{\text{out}} = 3(4) - 2(2) + 1 = 9$ ， $\hat{y} = \sigma_{\text{sigmoid}}(9) \approx 0.9999$ 。再取 $\mathbf{x} = (0, 0)$ ： $z_1 = -1, z_2 = -2$ （两者都被 ReLU 裁剪为 0）， $z_{\text{out}} = 3(0) - 2(0) + 1 = 1$ ， $\hat{y} = \sigma_{\text{sigmoid}}(1) \approx 0.731$ 。

关键验证：如果没有 ReLU，会发生什么？假设隐藏层不做任何非线性变换（ $a_1 = z_1, a_2 = z_2$ ，即用恒等函数代替 ReLU），直接代数展开：

$$\begin{aligned} z_{\text{out}} &= 3z_1 - 2z_2 + 1 = 3(2x_1 - x_2 - 1) - 2(x_1 + x_2 - 2) + 1 \\ &= (6 - 2)x_1 + (-3 - 2)x_2 + (-3 + 4 + 1) = 4x_1 - 5x_2 + 2. \end{aligned}$$

也就是说，去掉激活函数后，无论隐藏层看起来有多少个神经元、参数排布多复杂，两层网络算出来的 z_{out} 永远等于同一个线性函数 $4x_1 - 5x_2 + 2$ ——这正是“预备说明”中承诺要证明的事实：没有非线性激活函数，层数再多也只是一条（高维）直线。表 1.1 把“坍塌为线性”的预测值和真实 ReLU 网络的输出并列比较，可以直接看出两者何时相同、何时不同：

表 1.1: 有无 ReLU 激活函数：三个输入点的对比

输入 (x_1, x_2)	若无激活 $(4x_1 - 5x_2 + 2)$	实际 z_{out} (有 ReLU)	是否相同
$(1, 2)$	-4	-1	不同 (h_1 被裁剪为 0)
$(3, 1)$	9	9	相同 (两个预激活均为正，未被裁剪)
$(0, 0)$	2	1	不同 (h_1, h_2 均被裁剪)

只要 ReLU 真正“裁剪”过某个神经元（预激活值为负），网络的输出就会偏离“坍塌线性模型”的预测——这就是深度与非线性共同带来的、超出任何单一直线（或超平面）的表达能力。

■ 思考与验证

用同一个网络（式中给定的 $\mathbf{W}^{(1)}, \mathbf{b}^{(1)}, \mathbf{W}^{(2)}, b^{(2)}$ ），手算输入 $\mathbf{x} = (1, 0)$ 对应的隐藏层激活值 a_1, a_2 、输出层 z_{out} ，以及最终预测 $\hat{y}$ 。

解： $z_1 = 2(1) - 0 - 1 = 1 \Rightarrow a_1 = 1$ ； $z_2 = 1 + 0 - 2 = -1 \Rightarrow a_2 = \text{ReLU}(-1) = 0$ ；
 $z_{\text{out}} = 3(1) - 2(0) + 1 = 4$ ； $\hat{y} = \sigma_{\text{sigmoid}}(4) = 1/(1 + e^{-4}) \approx 0.982$ 。

这和“训练”有什么关系？

以上算的是给定参数、算输出这件事（前向传播）。上面说过，“训练”是不断调整参数，使输出接近期望的答案——对神经网络而言，需要调整的参数就是每一层的 $\mathbf{W}^{(l)}, \mathbf{b}^{(l)}$ ，本例中一共有 $2 \times 2 + 2 + 1 \times 2 + 1 = 9$ 个数。九个参数已经无法像调整直线的 a, b 那样凭直觉去试了，需要一套系统的算法——这正是讲义第三部分“优化与动力学”要解决的问题，也是第二部分“神经网络的物理模型”要用统计物理语言重新理解的对象：读者将会看到，一个训练好的神经网络，从统计物理的视角看，本质上是一个把“能量”刻在权重里的系统。

§1.2 为什么偏偏是统计物理？

刚才那一节，我们把“直线”升级成了“神经网络”，但不论模型变得多复杂，都还没有回答一个更根本的问题：不管是一条直线还是一个九参数的网络，都只能给出一个确定的数字作为输出。现在暂时把神经网络放在一边，回到最初那个最简单的例子——用一条直线拟合房价——重新提出这个问题。

假设你发现，两套面积完全相同的房子，成交价却并不完全一样——一套因为装修好、楼层佳，卖得贵一些；另一套因为其他原因，卖得便宜一些。这种“同样的输入，却没有完全相同的输出”的现象，在真实数据里几乎无处不在。

这意味着，一条直线（或者任何一个模型）几乎不可能让全部数据点都精确地落在它上面——总会存在一些无法用模型里已经包含的那些因素解释的“剩余”偏差。物理学家会立刻联想到一个熟悉的说法：噪声（noise）¹。而一旦承认真实数据中普遍存在噪声，一个自然的问题就出现了：模型给出的输出，究竟应该是一个“绝对确定”的数字，还是应该带有某种置信程度——比如“这套房子的价格最可能是 285 万元，但也有一定概率在 270 万到 300 万之间”？

后一种想法，正是把概率引入机器学习的根本原因。而这里就出现了一个物理学家会觉得似曾相识的问题：如何用大量微观、不可预知的细节，去描述一个宏观上看起来相对确定、有规律的结果？这正是统计物理从诞生之初就在处理的核心问题——一杯咖啡里 10^{23} 个分子的运动细节谁也无法逐一追踪，但咖啡的温度、压强这些宏观量却可以被精确描述和预测。

接下来六章要做的事情，正是把统计物理处理“微观不确定性如何产生宏观规律”这一整

¹这里的“噪声”并不一定意味着数据真的被仪器测量错误了。更准确地说，它指的是：对于当前模型而言，输出中那些无法由模型已经考虑的输入因素完全解释的随机性或不确定性。例如，在房价问题中，即使两套房子的面积相同，价格仍可能受到装修、楼层、朝向、地段的细微差异，甚至买卖双方的偶然因素影响。只要这些因素没有被模型纳入输入，它们对价格造成的影响就会表现为模型眼中的“噪声”。因此，“噪声”往往不是自然界中某种独立存在的神秘扰动，而是相对于特定模型和可用信息而言的未解释部分。

套已经非常成熟的数学语言——玻尔兹曼分布、配分函数、自由能、熵、变分方法、最大熵原理——原封不动地搬到机器学习的语境中来，用同一套工具回答“模型应该如何刻画数据中的不确定性”这个问题。这就是为什么下一章会突然开始讲一个和“人工智能”表面上毫无关系的物理模型：一群粒子随机分布在容器两侧。它不是在讲热学，而是在为整本讲义搭建后续六章都要共用的语言。

回答了“为什么需要概率”，我们还需要进一步回答一个更尖锐的问题：物理学有很多分支——经典力学、量子力学、流体力学，都是研究“大量组成部分如何产生整体行为”的成熟理论，为什么这本书偏偏选了统计力学，而不是其他任何一支？这个问题值得认真回答，而不是想当然地略过——如果答案只是“因为作者是统计物理背景”（事实上也不是），那这本书的方法论就立不住脚；只有当统计物理确实比其他分支更贴合机器学习问题本身的结构时，这一选择才算数。

为什么不是经典力学？

经典力学（牛顿定律、拉格朗日/哈密顿力学）处理的问题是：已知支配系统的力或势能，系统会如何精确演化。这要求你一开始就掌握规则本身——知道弹簧的劲度系数，才能算出振子的轨迹。

但机器学习的核心困难恰恰相反：我们从来不知道“真实的规则”是什么。给定一批房价数据，没有人告诉我们“面积与价格之间的真实函数关系”，这个关系本身是需要从带噪声的有限样本中推断出来的对象。这是一个认识论问题（我们对规则的无知该如何量化、更新），而不是一个动力学问题（已知规则，系统怎么走）。经典力学的整套工具——拉格朗日量、作用量、运动方程——都建立在“规则已知”这个前提之上，这个前提在机器学习最核心的问题（学习一个未知的函数）里恰好不成立。

■ 经典力学并非无用，只是回答另一半问题

需要澄清：这不代表经典力学在这本书里毫无位置。一旦模型的“规则”（损失函数的形状）确定下来，训练过程本身——参数如何随着一步步梯度更新而演化——就是一个不折不扣的动力学问题，梯度下降本身可以被看作一个（带耗散的）力学系统在“势能”（损失函数）中运动。这正是讲义第三部分“优化与动力学”要处理的内容。准确的说法不是“经典力学不适用”，而是“经典力学回答的是训练怎么走，而统计物理回答的是损失函数长什么样、为什么长这样”——讲义第一部分先处理后者，是因为在讨论“沿着地形往下走”之前，得先说清楚这片地形从哪里来。

为什么不是量子力学？

量子力学也处理概率，而且它的数学结构（配分函数、 $\beta = 1/k_B T$ 、甚至路径积分）与统计物理有大量形式上的相似之处，历史上两者也确实深度交织（统计物理的量子版本正是通过量子系综理论建立的）。那么，为什么不直接用量子力学的语言来理解机器学习？

关键区别在于不确定性的来源。量子力学中的概率来自概率幅的干涉——两条路径可以相长或相消，这是微观世界内禀的、无法通过“掌握更多信息”而消除的不确定性。而机器学习中的概率是纯粹认识论的：硬币究竟正面朝上的概率是多少，原则上只是我们信息不足；一

旦知道了硬币的全部物理细节（质量分布、抛掷的初始条件），结果就不再随机。机器学习处理的“噪声”——测量误差、未观测到的混杂因素、有限样本——全部属于这一类，不涉及任何量子叠加或干涉结构。用量子力学的形式体系（复数概率幅、厄米算符）去解释为什么交叉熵损失长这个样子，不仅不会让论证更清楚，反而会引入完全不必要的额外结构。（量子机器学习是一个真实存在、正在发展的方向，但它处理的是一类不同的问题——用量子计算机本身作为计算资源——而不是“用量子力学语言理解经典监督学习”，这不是本讲义的主题。）

为什么不是流体力学？

这一条的答案最出人意料：流体力学（纳维-斯托克斯方程等）在物理学内部，本身就不是一个与统计力学并列的独立基础理论，而是统计力学在特定极限下的推论。具体来说，从描述大量粒子概率分布演化的玻尔兹曼方程出发，通过 Chapman-Enskog 展开（一种系统的多尺度近似方法），可以在“碰撞频繁、宏观尺度远大于分子平均自由程”这一极限下，严格推导出纳维-斯托克斯方程——密度、流速、温度这些流体力学变量，都是玻尔兹曼分布对分子速度的矩（moments）。换句话说，流体力学处理的是统计力学在“大量弱相互作用粒子 + 局域近平衡”这一特定物理情形下的连续介质近似，而不是一套平行的、可以替代统计力学的语言。

这件事说起来只是一句话，但做起来有多难，值得用一个足够权威的例子说清楚：从牛顿力学（大量相互碰撞的硬球粒子）出发，严格证明系统在合适的极限下确实会产生玻尔兹曼方程、进而推导出纳维-斯托克斯方程——这正是希尔伯特第六问题（1900 年提出：能否用公理化的方式，从微观力学严格建立起宏观物理学）的核心内容之一，一个多世纪都没有被完全解决。2026 年，华人数学家邓煜与合作者的一系列工作，在 Boltzmann-Grad 极限下严格证明了硬球气体的微观动力学确实能在足够长的时间尺度上产生玻尔兹曼方程，并进一步建立起与流体方程的联系，因此获得了菲尔兹奖。“微观规律不自动等于宏观规律”这句话，不是一句方便的口号，而是一个连最严格的数学家都要花上一百多年才逐步攻克的真问题。

需要说明的是，从微观粒子动力学严格推导宏观方程，和后面几章要讨论的“从数据训练机器学习模型”，是两个不同的数学问题，不能因为两者表面上都是“从复杂系统提取宏观规律”就把它们简单等同——但两者确实共享同一种科学视角：面对包含大量自由度的系统，真正的任务不是逐一描述所有细节，而是寻找能够组织这些细节的有效结构；统计力学通过概率分布和热力学势寻找这种结构，机器学习则通过参数化模型和数据驱动的优化寻找这种结构。这个共同视角，而不是某一条具体方程，才是本书真正要借用的东西。

这一点也提示了统计力学在这四者中的特殊位置。需要说明的是，这不是说统计力学比经典力学“更基础”——恰恰相反，统计力学通常需要以微观动力学（经典或量子）、系综假设、平衡假设与热力学极限等一整套额外结构作为输入，是建立在微观动力学之上的一层理论，而非替代或凌驾于它之上。

这里想强调的是另一件事：统计力学处理的“大量微观自由度的概率分布如何产生宏观规律”这一问题，与经典力学“已知规则、求解确定性演化”是两类不同性质的问题（前者是认识论/概率论问题，后者是动力学问题），而流体力学（连续介质极限）在很大程度上正是统计力学在特定极限下的推论。

就“为机器学习提供恰当的语言”这一本书特定的目标而言，统计力学处理的是概率分布、涨落与宏观规律之间的关系，这恰好与机器学习的核心结构相配——但这是“哪个理论框架更

适合这一类具体问题”的判断，不是物理学理论体系内“谁更基础”的一般性论断。

一条可检验的判据

以上三条比较，可以压缩成一条具体、可检验的判据，而不是停留在“物理学家的直觉”：

凡是核心结构表现为“能量最小化与熵最大化的竞争、由一个标量温度参数调控”的问题，统计物理就是天然合适的语言。

经典力学的中心原理是作用量取极值（最小作用量原理），不涉及熵；量子力学的中心结构是么正演化与测量，同样不涉及“能量与熵的竞争”这一图景；流体力学的中心对象是守恒律（质量、动量、能量的连续性方程），是统计力学在特定极限下的推论，本身也不以“熵”为组织原则。而机器学习里几乎所有核心概念——正则化（先验把参数拉向简单，对应“外场”；数据把参数拉向复杂，对应灵活性）、过拟合与欠拟合的权衡、Softmax 的温度参数——都反复表现为这同一种“拟合精度 vs. 灵活性”的竞争。这不是巧合，也不是比喻：这一竞争在全书中会以同一个数学对象 $F = E - TS$ （或其信息论对应物）反复出现并被严格证明——第二章直接从物理系统导出它，第六章证明变分自由能与 ELBO 是同一个不等式的两种说法，第七章证明它就是最大熵原理给出的解——而不是需要读者自己在几个比喻之间脑补的相似性。

■ 小结

经典力学要求已知规则，机器学习恰恰是要从数据中推断规则——这是两者最根本的错位；量子力学的不确定性来自内禀的概率幅干涉，机器学习的不确定性纯粹是认识论上的信息不足；流体力学本身是统计力学在特定极限下的推论，而非与之并列的替代方案。真正让统计物理成为天然语言的，不是学科声望，而是一条具体的结构判据：机器学习的核心概念普遍表现为“能量与熵的竞争，由一个标量参数调控”，而在经典物理的主要理论框架中，统计物理正是最系统、最直接地围绕这一结构组织起来的分支（量子统计、非平衡统计物理、信息热力学等现代分支同样处理能量-熵-温度的关系，但这些恰恰是统计物理框架内部的延伸，而不是外部的竞争者）。这也是为什么下一节的路线图，能够被压缩进表 2.8 那样一张具体、可核对的表格，而不是一系列松散的比喻。

§1.3 全书第一部分导览

有了以上的铺垫，现在可以把全书第一部分（第二至七章）的路线图完整地画出来了。表 1.2 给出一个总览，每一章更详细的“本章导览”也会在各章正文开头再次出现。

简单展开一下这条路线背后的叙事：第二章从最朴素的组合计数出发，推出玻尔兹曼分布和配分函数——这是全书剩余部分共用的物理语言。第三章转向机器学习，展示“从数据估计参数”这件事在数学操作上和第二章惊人地相似。第四章把两条线正式焊接在一起：展示机器学习中的负对数似然与统计物理中“能量 + 配分函数的对数”这一结构具有完全相同的数学形式——“损失函数”与“能量函数”都只是这同一个数学操作在两个领域里的不同名字。第五章指出，第二到四章里能够手算的例子都是因为变量数目很少，一旦规模变大，配分函数的计算会成为真正的瓶颈。第六章给出应对这一瓶颈的核心武器——变分方法，并证明它在

表 1.2: 全书第一部分（第二至七章）路线图

章节	这一章要回答的问题	引入的核心概念
第二章	概率为何会呈现“能量越低、概率越大”这种指数形式？	微观/宏观状态、玻尔兹曼分布、配分函数、自由能、一维伊辛模型
第三章	给定观测数据，如何为模型估计出“最合理”的参数？	似然函数、最大似然估计 (MLE)、最大后验估计 (MAP)
第四章	机器学习中的损失函数（均方误差、交叉熵……）从何而来？	负对数似然 = 能量 + 归一化项，线性/逻辑/Softmax 回归
第五章	为什么“归一化”在实际训练中是一个真正的计算难题？	马尔可夫随机场、Hammersley–Clifford 定理、正相位与负相位
第六章	当配分函数算不出来时，应该怎么办？	变分自由能、证据下界 (ELBO)、平均场近似
第七章	玻尔兹曼分布究竟是物理假设，还是必然结果？	最大熵原理、拉格朗日乘数法、最小交叉熵原理

物理和机器学习中其实是同一个数学定理。第七章从纯信息论的角度，把玻尔兹曼分布重新推导一遍，作为全书第一部分的收束：物理直觉、变分原理、信息论约束，三条彼此独立的推导路径，最终都通向同一个数学对象；而第四章建立的“ $-\ln P = \text{能量} + \text{归一化项}$ ”这一恒等式，则是让这三条路径的结论都能不加改动地应用在任意一个机器学习模型上的关键桥梁。

§1.4 AI 也在改变物理研究本身

以上建立的整张地图，箭头全部指向同一个方向：用物理理解 AI——用统计力学的语言，重新讲清楚损失函数、归一化、变分推断这些机器学习概念“真正在做什么”。这是本书接下来六章要做的事。

但这个故事其实还有另外一半，方向恰好相反：AI 也正在成为物理研究本身的工具，而且影响的不只是“算得更快”这么简单。这一半故事不是本书的重点（如果你对此感兴趣，它本身足够撑起一整门课），但作为读者，你至少应该知道它的存在。粗略地说，目前 AI 介入物理研究的方式大致可以归为表 1.3 所列的几类：

■ 一个真实发生过的例子

2026 年初，哈佛大学物理学教授 Matthew Schwartz 做了一个实验：他只通过文本提示指挥 Claude（不直接编辑任何文件、不代入自己算过的公式），让 AI 独立完成一项量子

表 1.3: AI 介入物理研究的几种典型方式

方向	大致在做什么
数值 AI	用神经网络直接学习偏微分方程的解（如物理信息神经网络 PINN、神经算子），替代或加速传统数值方法。
符号 AI	从数据中自动发现闭式的物理定律（符号回归），而不只是拟合一个“黑箱”数值模型。
形式化 AI	用 Lean 4 等证明助手，把物理推导中的每一步都变成计算机可以逐条检验的严格证明。
研究代理 AI	让大模型在人类监督下，承担计算、编码、排查错误等具体研究工作，见下文的真实例子。
科学基础模型	在海量科学数据（如蛋白质结构）上预训练的大模型，AlphaFold 是最著名的代表。
自主科学家 AI	更远期的设想：AI 自主提出假设、设计并（借助机器人）执行实验、分析结果，形成闭环。

色动力学（QCD）中的技术性计算—— C 参数分布中“Sudakov 肩部”的重求和。这项工作他估计如果指导一名研究生来做，需要一整年；这一次，两周内就得到了一篇可以公开发表的论文（Schwartz, arXiv:2601.02484, 2026）。过程并不是一路顺利：AI 一度自信地给出了一个错误的基础公式，绕过了真正的物理计算，直到 Schwartz 反复追问、亲自排查之后，真正的推导才浮现出来。Schwartz 本人给出的评价是：到 2025 年底，这一代大模型的计算能力大致相当于二年级研究生——能够执行复杂的计算，但还缺乏独立判断“这个结果到底对不对”的科研“品味”。这句评价，或许是目前对 AI 介入物理研究现状最诚实的概括。

这半个故事想说明的是：你即将用统计物理去理解的这些机器学习概念，并不只是一个方便记忆的类比练习——AI 正在实实在在地进入物理学家的日常工作。而无论 AI 未来在物理研究中扮演什么角色，能够看穿它“在数学上到底在做什么”的人，永远比只会调用它的人更有主动权。这也是这整本书想要培养的能力。

这门课想教会你什么

读到这里，也许可以坦白说一句更大的话：这门课真正的目标，并不是把你训练成一个“会调库、会写代码的机器学习工程师”（虽然理解这些数学之后，写代码会容易很多），也不只是一门泛泛而谈的“人工智能导论”。它想做的事情更具体，也更有野心：培养一种用物理学家的眼光看待“学习”这件事的思维方式。

当你在后面六章里看到损失函数，希望你能同时看到能量函数；看到训练过程中的正则化强度，希望你能同时联想到温度；看到“为什么模型会过拟合”，希望你能想到自由能里能量

与熵的竞争。这种双重视角，不是为了炫技式地“到处类比”，而是因为——正如第七章结尾会证明的那样——这些概念在数学结构上本来就是同一个对象。物理学为理解机器学习提供的，不是一个方便记忆的比喻，而是一整套已经被验证过、更早成熟的数学工具。

本章思考题

以下问题大多不需要计算（除第 4 题外），只是希望你在正式进入第二章之前，先对本章的内容做一次自己的梳理。

1. 除了本章列举的例子外，你还能想到哪些“输入 $\rightarrow$ 模型 $\rightarrow$ 输出”结构的人工智能应用？试着明确指出它们各自的输入和输出分别是什么。
2. 为什么“基于规则的方法”（如传统的国际象棋程序）不需要“训练”这个概念，而机器学习方法却离不开它？
3. 本章提到，统计物理处理的是“大量微观自由度如何产生宏观规律”这一类问题。你能否举出一个日常生活中的类似例子（不必与人工智能有关）？
4. 在 §1.1 的算例中，如果把隐藏层的两个 ReLU 神经元换成两个恒等函数（即完全不做非线性变换），网络会退化成什么？试着不看正文，自己重新推导一遍那个“坍塌”为线性函数的过程。
5. 回顾表 1.2：你觉得哪一章要回答的问题，目前对你来说最难以想象“物理学怎么可能帮上忙”？带着这个疑问往下读，看看六章之后这个疑问是否已经被解答。

从经典统计物理说起

Though this be madness, yet there is method in't.

—— 莎士比亚《哈姆雷特》第二幕第二场，波洛涅斯

学习目标

- 从等概率原理出发，理解玻尔兹曼分布与配分函数的组合数学起源；
- 通过可手算验证的具体数值实例，掌握正则系综的完整推导过程；
- 系统地说明如何由配分函数导出平均能量、自由能、熵与比热等热力学量；
- 将上述框架应用于一维伊辛模型，给出相互作用系统的精确解，并初步建立与机器学习模型的对应关系。

■ 本章导览

本章回答的问题：机器学习中反复出现的“损失函数”“归一化”“温度参数”等概念，其数学结构究竟从何而来？本章完全不预设物理知识，从最朴素的组合计数出发，把这套数学结构从头推导一遍。

统计物理对应：本章建立的是统计物理本身的核心语言——微观状态、能量、玻尔兹曼分布、配分函数、自由能、一维伊辛模型——这是全书接下来五章共用的词汇表，其他各章都会不断回到这里定义的记号。

后续预告：第三章会展示，机器学习中“参数估计”遵循一条几乎与本章镜像对称的逻辑链；第四章将证明本章的能量函数就是损失函数本身；第七章会从纯粹信息论的角度，把本章推出的玻尔兹曼分布重新推导一遍——那是与本章物理直觉完全独立的另一条推导路径。

本章的目标是使读者在不预先掌握统计物理知识的前提下，理解玻尔兹曼分布与配分函数等核心概念的物理与数学起源，而非将其作为既定结论加以记忆。全部推导都从一个仅需组合计数即可完全解决的简单模型出发，通过一系列可自行验证的具体数值算例逐步展开，最终抵达一维伊辛模型——统计物理中处理相互作用系统的标准范例。

§2.1 计数原理：宏观概率的集中效应

在正式引入能量与温度等物理概念之前，本节首先讨论一个纯属组合数学的问题——它不涉及任何物理内容，却是整个统计物理理论的基础。

基本模型

考虑一个由虚拟分界线分成左右两半的容器，其中包含 N 个粒子。每个粒子独立、等概率地处于左半区或右半区（概率各为 $1/2$ ，如同抛掷一枚均匀硬币）。

若只关心左半区的粒子数目 k 这一宏观量，而不区分具体是哪些粒子处于左侧，则 k 取不同值的概率分布如何？

这里需要严格区分两个层次的“状态”，这一区分将贯穿统计物理的始终：

- **微观状态**：精确指定每一个粒子所处的位置（左或右）。例如当 $N = 4$ 时，“粒子 1、2 在左，粒子 3、4 在右”即构成一个微观状态。 N 个粒子共有 2^N 个微观状态，且由于每个粒子的左右选择相互独立、概率相等，这些微观状态天然等概率。
- **宏观状态**：仅指定左半区的粒子总数，而不区分具体成员。例如“左侧恰有 2 个粒子”构成一个宏观状态，对应多个微观状态。

宏观状态 k 所对应的微观状态数目记为 $\Omega(k)$ 。由于这等价于从 N 个粒子中选出 k 个置于左侧、其余留在右侧，故

$$\Omega(k) = C_N^k \equiv \frac{N!}{k!(N-k)!}, \quad (2.1)$$

对应的概率为

$$P(k) = \frac{\Omega(k)}{2^N}. \quad (2.2)$$

算例： $N = 4$ 的情形

当 $N = 4$ 时，共有 $2^4 = 16$ 个微观状态，可以逐一列出（以 L、R 分别表示某粒子处于左侧或右侧）：

表 2.1: $N = 4$ 时各宏观状态对应的微观状态数与概率

左侧粒子数 k	微观状态数 $\Omega(k) = C_4^k$	概率 $P(k)$
0 (RRRR)	1	0.0625
1 (LRRR, RLRR, RRLR, RRRL)	4	0.2500
2	6	0.3750
3	4	0.2500
4 (LLLL)	1	0.0625

总数校验： $1 + 4 + 6 + 4 + 1 = 16 = 2^4$ ，与预期一致。

由此可见一个关键现象：“左侧恰有 2 个粒子”这一宏观状态出现的概率，远高于“左侧 0 个”或“左侧 4 个”的概率，尽管每一个微观状态本身的概率完全相等（均为 $1/16$ ）。这并非物理规律偏好“均匀分布”，而是因为能够实现“均匀”这一宏观状态的微观状态数目，远多于能够实现“全部聚集于一侧”这一宏观状态的微观状态数目。

大 N 极限下的集中效应

当 N 增大时，上述效应将进一步加剧。表 2.2 与表 2.3 分别列出 $N = 10$ 与 $N = 20$ 时的计算结果（读者可自行验证任意一行）：

表 2.2: $N = 10$ 时的微观状态数与概率

k	0	1	2	3	4	5	6	7	8	9	10
$\Omega(k)$	1	10	45	120	210	252	210	120	45	10	1
$P(k)$	0.001	0.010	0.044	0.117	0.205	0.246	0.205	0.117	0.044	0.010	0.001

表 2.3: $N = 20$ 时的微观状态数与概率（部分取值；完整分布为对称钟形曲线）

k	0	5	8	9	10	11	12	15	20
$\Omega(k)$	1	15504	125970	167960	184756	167960	125970	15504	1
$P(k)$	$\approx 10^{-6}$	0.015	0.120	0.160	0.176	0.160	0.120	0.015	$\approx 10^{-6}$

由此可见，随着 N 增大，分布 $P(k)$ 在最概然宏观状态（ $k = N/2$ ）附近变得愈发尖锐，而“所有粒子聚集于一侧”这类极端宏观状态的概率则迅速趋于可忽略。当 $N \sim 10^{23}$ （真实气体中的分子数量级）时，这种尖锐化的程度达到天文数字级别——“容器中的气体自发地全部聚集到一侧”这一事件，在宇宙年龄的时间尺度上也不会发生一次；这并非源于某条物理定律的禁止，而是因为能够实现该宏观状态的微观状态数目极其稀少。

■ 核心直觉

一个宏观状态出现的概率，取决于能够实现它的微观状态数目。宏观世界所呈现的“确定性”（例如气体总是趋于均匀分布），本质上是海量微观可能性在概率意义下相互竞争的结果：多数微观状态所支持的宏观状态，就是实际观测到的结果。

从状态计数到熵的定义

统计物理为“某一宏观状态所对应的微观状态数目”给出了正式的度量。玻尔兹曼将熵定义为

$$S = k_B \ln \Omega, \quad (2.3)$$

其中 k_B 为玻尔兹曼常数（在纯数学讨论中，常直接取 $k_B = 1$ ，将其视为单位换算因子即可）。之所以取对数，是出于以下考虑： Ω 增长极快（当 $N = 20$ 时其最大值已达 184756，当 $N \sim 10^{23}$ 时更是天文数字），直接使用 Ω 并不方便；而 $\ln \Omega$ 增长缓和，并且具有可加性——两个独立子系统合并后，微观状态数相乘（ $\Omega = \Omega_1 \Omega_2$ ），取对数后即变为相加（ $S = S_1 + S_2$ ），这与熵作为广延量的物理图像完全吻合。

■ 思考与验证

设某系统由两个独立部分组成,第一部分有 $\Omega_1 = 100$ 个微观状态,第二部分有 $\Omega_2 = 1000$ 个微观状态,问整体系统的微观状态数目为多少? 整体的熵 (取 $k_B = 1$) 是否等于两部分熵之和?

解: 整体的微观状态数为 $\Omega = \Omega_1 \Omega_2 = 10^5$; 而 $\ln(10^5) = \ln 100 + \ln 1000$, 故二者确实相等。

至此,讨论中尚未涉及“能量”这一概念。下面将为每一个微观状态赋予一个能量标签,考察当系统可与外界交换能量时,等概率原理将如何演化。

§2.2 正则系综与玻尔兹曼分布的推导

问题的提出

考虑如下场景:一杯静置于桌面上的咖啡,包含约 10^{23} 个分子,每个分子都在运动,具有各自的位置与速度。若要完整描述这杯咖啡的微观状态,需要给出每个分子的全部 6 个自由度 (3 个位置坐标与 3 个动量分量),总计 6×10^{23} 个数值——这显然是不可实现的任务。

然而,我们并不需要掌握这些微观细节,即可准确预测该系统的宏观性质,例如温度、压强与热容量。这正是统计物理的核心方法,而 §2.1 中“数格子”一例所揭示的“宏观确定性源自微观概率优势”这一逻辑,已经为此提供了基本思路。

统计物理处理此类问题的核心思想是:不关心系统究竟处于哪一个具体的微观状态,而关心系统处于各微观状态的概率分布。

正则系综的设定

§2.1 中,粒子处于左侧或右侧完全对称、不存在偏好,这对应于物理上“不受外界约束”的最简单情形。然而真实的物理系统通常需要与外界交换能量:一杯热咖啡会向周围空气持续散热,分子运动越剧烈(能量越高),这种状态也就越难以长期维持。因此,需要将能量这一因素纳入概率的计算之中。

考虑一个与温度为 T 的“热库”(例如咖啡周围的大量空气)接触的系统(例如咖啡本身)。该系统可以与热库交换能量,但不能交换粒子——这就是正则系综的基本设定。

系统可能处于诸多不同的微观状态。以 $\mathbf{x}$ 表示某一微观状态(可以是粒子的位置与动量组态,也可以是 §2.1 中“每个粒子处于左/右”的组态,或是自旋取向组态),每一状态 $\mathbf{x}$ 对应确定的能量 $E(\mathbf{x})$ 。

由此产生的核心问题是:系统处于状态 $\mathbf{x}$ 的概率 $P(\mathbf{x})$ 具有怎样的形式? 在 §2.1 中,由于不存在能量偏好,所有微观状态等概率;引入能量之后,直观上能量较低的状态应更为“常见”,但其精确的函数形式需要通过下面的推导得到——而推导的出发点,仍是同一条等概率原理。

玻尔兹曼分布的推导

基本假设（等概率原理）：对于一个总能量固定为 E_{total} 的孤立系统，所有能量为 E_{total} 的微观状态出现的概率相等。这正是 §2.1 中“各微观状态概率均等”这一假设的推广：孤立系统被限定为能量固定的系统。

考虑“小系统 + 热库”构成的整体（这是一个孤立系统）：

- 设小系统处于状态 $\mathbf{x}$ ，能量为 $E(\mathbf{x})$ ；
- 热库的能量则为 $E_R = E_{\text{total}} - E(\mathbf{x})$ ；
- 热库处于能量 E_R 的微观状态数为 $\Omega_R(E_R)$ 。

此处的核心技巧与 §2.1 中的“数格子”完全一致：小系统固定于某一特定微观状态 $\mathbf{x}$ （仅有 1 种取法），而热库在能量约束 E_R 下仍有 $\Omega_R(E_R)$ 种可能的微观排布。根据等概率原理，“系统 + 热库”的每一种联合微观状态概率均等，因此小系统处于状态 $\mathbf{x}$ 的概率正比于与之相容的热库微观状态数目：

$$P(\mathbf{x}) \propto \Omega_R(E_{\text{total}} - E(\mathbf{x})). \quad (2.4)$$

这与 §2.1 中“左侧恰有 k 个粒子”的概率正比于 $\Omega(k) = C_N^k$ 是同一结构，只是“宏观标签”替换为“小系统处于状态 $\mathbf{x}$ ”，“相容的微观状态数”替换为热库一侧的 Ω_R 。

利用热库的熵定义 $S_R = k_B \ln \Omega_R$ （式 (2.3)），可得

$$\Omega_R(E_R) = e^{S_R(E_R)/k_B}.$$

由于热库远大于小系统（可将其想象为整个房间中的空气，相对于一杯咖啡近乎无限大的能量储库），可将 $S_R(E_R)$ 在 $E_R = E_{\text{total}}$ 附近作泰勒展开。回忆单变量函数的泰勒展开公式

$$g(a + \delta) = g(a) + \delta g'(a) + \frac{1}{2} \delta^2 g''(a) + \dots,$$

取 $g = S_R$ ， $a = E_{\text{total}}$ ， $\delta = -E(\mathbf{x})$ （因为 $E_R = E_{\text{total}} - E(\mathbf{x})$ ），逐项代入得

$$S_R(E_{\text{total}} - E(\mathbf{x})) = S_R(E_{\text{total}}) - E(\mathbf{x}) \left. \frac{\partial S_R}{\partial E_R} \right|_{E_R=E_{\text{total}}} + \frac{1}{2} E(\mathbf{x})^2 \left. \frac{\partial^2 S_R}{\partial E_R^2} \right|_{E_R=E_{\text{total}}} - \dots \quad (2.5)$$

为何可以只保留一阶项？一阶项 $\partial S_R / \partial E_R$ 是一个强度量（intensive quantity）——按热力学关系（下面即将用到）它等于 $1/T$ ，与热库的大小（粒子数目）无关，故一阶项本身是 $O(1)$ 量级，不能省略。但二阶项中的 $\partial^2 S_R / \partial E_R^2$ 却不同：读者在《热学》课程中已经学过，热容 $C_R = \partial E_R / \partial T$ 是一个广延量，正比于热库所含的粒子数 N_R ；由 $\partial S_R / \partial E_R = 1/T$ 求导可得

$$\frac{\partial^2 S_R}{\partial E_R^2} = \frac{\partial}{\partial E_R} \left(\frac{1}{T} \right) = -\frac{1}{T^2} \frac{\partial T}{\partial E_R} = -\frac{1}{T^2 C_R},$$

由于 $C_R \propto N_R$ ，这一项是 $O(1/N_R)$ 量级的小量（这里隐含了几个通常自动满足、但值得明确写出的前提：热库处于普通热力学相、热容作为广延量随粒子数线性增长、且系统不处于临界点附近——临界点处涨落异常增大，热容对 N_R 的依赖会偏离简单的线性关系，届时二阶项未必能被忽略）。于是式 (2.5) 中的二阶项整体为

$$\frac{1}{2} E(\mathbf{x})^2 \frac{\partial^2 S_R}{\partial E_R^2} \sim O\left(\frac{E(\mathbf{x})^2}{N_R}\right),$$

在热库趋于无穷大 ($N_R \rightarrow \infty$, 而小系统的能量 $E(\mathbf{x})$ 保持有限) 的极限下严格趋于零, 可以舍去; 同理, 三阶及更高阶项衰减得更快。这正是“热库”这一概念的意义所在: 它必须足够大, 以至于与小系统交换少量能量不会改变自身的温度 (即一阶项 $1/T$ 保持不变), 这也正是我们在泰勒展开中只需保留到一阶项的根本原因。

利用热力学关系 $\partial S / \partial E = 1/T$ (T 为温度), 有

$$S_R(E_{\text{total}} - E(\mathbf{x})) \approx S_R(E_{\text{total}}) - \frac{E(\mathbf{x})}{T}.$$

代入概率表达式 (2.4):

$$P(\mathbf{x}) \propto e^{S_R(E_{\text{total}})/k_B} \cdot e^{-E(\mathbf{x})/(k_B T)}.$$

第一个因子对所有状态均相同 (不依赖于 $\mathbf{x}$, 仅依赖于热库总能量), 可并入归一化常数。定义逆温度 $\beta \equiv 1/(k_B T)$, 最终得到

$$P(\mathbf{x}) = \frac{1}{Z} e^{-\beta E(\mathbf{x})} \quad (2.6)$$

这就是玻尔兹曼分布: 能量越低的微观状态概率越大; 能量每增加 $k_B T$, 概率大约衰减为原来的 $1/e$ 。温度这一参数控制着衰减的快慢——温度越高, 平衡分布对高能量状态的压制越弱; 温度越低, 平衡分布越趋于集中在能量最低的状态附近。

严格来说, 以上是平衡分布本身的性质, 并不直接是一个动力学论断: “系统更容易探索高能区域” 这类说法, 隐含了某种具体的随机动力学过程 (如 Langevin 动力学、Metropolis 算法、Glauber 动力学), 仅凭平衡分布 $P(\mathbf{x})$ 本身无法推出具体的“探索速度”; 不过在这些常见采样算法中, 温度升高确实通常表现为更容易访问高能区域, 这也是 §4.4 “温度参数” 与后续章节“模拟退火”等内容里这一直觉被反复借用的原因。

这与 §2.1 中“ N 越大分布越尖锐”的现象在数学结构上完全平行: 此处由 $1/T$ (逆温度) 扮演此前 N (粒子数) 所扮演的角色。

■ 释疑

为何概率随能量呈指数衰减, 而非其他函数形式? 答案蕴含于上述推导之中: 熵是对数尺度的量 ($S = k_B \ln \Omega$), 而“熵对能量的导数等于 $1/T$ ”这一热力学关系经过指数化后, 自然地将线性的能量变换为指数中的能量。这并非人为约定, 而是等概率原理与热力学基本关系共同导出的必然结果。

配分函数及其物理意义

归一化常数 Z 称为配分函数 (partition function):

$$Z = \sum_{\mathbf{x}} e^{-\beta E(\mathbf{x})} \quad (2.7)$$

对于连续系统, 求和相应地替换为积分:

$$Z = \int e^{-\beta E(\mathbf{x})} d\mathbf{x}.$$

“配分”一词源于该函数描述了各微观状态之间对能量权重的“分配”方式：可将 $e^{-\beta E(\mathbf{x})}$ 理解为状态 $\mathbf{x}$ 所得的权重， Z 即为全部状态权重之和。这也说明了 §2.1 中的“数格子”与此处的联系：若所有状态的能量相等 ($E(\mathbf{x}) = 0$)，则 $Z = \sum_{\mathbf{x}} 1$ 即为微观状态总数，恰好退化为最初纯粹计数的情形。引入能量之后， Z 相当于一种加权计数：每个状态不再简单地计为 1，而是按其玻尔兹曼因子 $e^{-\beta E(\mathbf{x})}$ 计权。

■ 历史：从玻尔兹曼的计数到吉布斯的配分函数

本节的推导顺序——先做纯粹的组合计数 (§2.1)，再引入能量与热库得到玻尔兹曼分布——并非本书任意选择的教学顺序，而大致重演了这段历史本身的顺序。玻尔兹曼在 1870 年代已经通过组合计数的方法，为稀薄气体建立起 $\propto e^{-\alpha E}$ 这一分布，并将熵与微观状态数的对数联系起来（他称之为 H 函数）。但把这一图景系统化为“系统与热库接触”这一普遍框架、并明确定义出配分函数 Z 本身作为独立研究对象的，是 J. Willard Gibbs 在 1902 年出版的《统计力学的基本原理》(*Elementary Principles in Statistical Mechanics*, 耶鲁大学)。正是在这本书中，“系综”(ensemble)——大量假想的系统副本，各自处于不同微观状态——第一次被系统性地用来定义配分函数，并由此导出全部热力学量，构成了本节“配分函数即生成函数”这一叙事的原始版本。这也是为什么配分函数在很多文献中记作 Z ——源自德文“Zustandssumme”，字面意思就是“状态之和”。

配分函数具有双重物理意义：其一，作为归一化常数，保证 $\sum_{\mathbf{x}} P(\mathbf{x}) = 1$ ；其二，作为生成函数，全部热力学量均可由其导出（详见下文）。下面先通过一个最简单的具体例子，使玻尔兹曼分布与配分函数的计算完全落实，随后再推导一般情形下的热力学量。

算例：二能级系统

考虑仅有两个微观状态的系统——例如一个只有基态与单一激发态的原子，或只有“开”“关”两种构型的分子开关。设：

- 状态 0 (基态)：能量 $E_0 = 0$ ；
- 状态 1 (激发态)：能量 $E_1 = \varepsilon$ ($\varepsilon > 0$)。

配分函数为对两个状态求和：

$$Z = e^{-\beta E_0} + e^{-\beta E_1} = 1 + e^{-\beta \varepsilon}. \quad (2.8)$$

各状态的概率为

$$P_0 = \frac{1}{Z} = \frac{1}{1 + e^{-\beta \varepsilon}}, \quad P_1 = \frac{e^{-\beta \varepsilon}}{Z} = \frac{e^{-\beta \varepsilon}}{1 + e^{-\beta \varepsilon}}. \quad (2.9)$$

取 $\varepsilon = 1$ (即以激发能本身为能量单位)，改变温度 $k_B T$ 后的具体数值列于表 2.4 (其中 $\langle E \rangle = P_1 \varepsilon$ 为系统的平均能量)：

以 $k_B T = 1$ 行为例： $Z = 1 + e^{-1} = 1 + 0.3679 = 1.3679$ ， $P_1 = 0.3679/1.3679 = 0.2689$ ，与表中数值一致。

表 2.4 揭示了两个反复出现的极限：

表 2.4: 二能级系统 ($\varepsilon = 1$) 在不同温度下的数值结果

$k_B T$	$\beta = 1/(k_B T)$	Z	P_0 (基态概率)	P_1 (激发态概率)	$\langle E \rangle$
0.2	5.00	1.007	0.993	0.007	0.007
0.5	2.00	1.135	0.881	0.119	0.119
1.0	1.00	1.368	0.731	0.269	0.269
2.0	0.50	1.607	0.622	0.378	0.378
5.0	0.20	1.819	0.550	0.450	0.450
10.0	0.10	1.905	0.525	0.475	0.475

- 低温极限 ($k_B T \rightarrow 0$, 即 $\beta \rightarrow \infty$): $P_0 \rightarrow 1$, $P_1 \rightarrow 0$, 系统几乎必然处于能量最低的基态。这正是 §2.1 中“分布随参数增大而尖锐化、极端宏观状态被压制”这一现象的直接体现, 只不过此处的“极端”方向相反: 低温下系统恰恰只停留于能量最低的极端状态, 因为热库不再提供足够的能量以支持系统进入激发态。
- 高温极限 ($k_B T \rightarrow \infty$, 即 $\beta \rightarrow 0$): $e^{-\beta\varepsilon} \rightarrow 1$, 故 $P_0 \rightarrow 1/2$, $P_1 \rightarrow 1/2$, 两状态趋于等概率——这正是 §2.1 中“无能量偏好时各微观状态等概率”这一情形的复现: 高温相当于抹平了能量的影响。

■ 思考与验证

若将激发态能量改为 $\varepsilon = 5$ (能级间隔增大), 在同样的 $k_B T = 1$ 下, P_1 相较于 $\varepsilon = 1$ 时的 0.269 应增大还是减小?

解: 能级间隔相对于 $k_B T$ 增大, 意味着跃迁至激发态的能量代价相对更高, 故 P_1 应减小。代入 $\beta\varepsilon = 5$ 计算: $P_1 = e^{-5}/(1 + e^{-5}) \approx 0.0067$, 确实大幅下降。

该二能级系统虽然结构简单, 却是后续讨论逻辑回归与二分类问题的物理原型: 只有两个可选“标签”的系统, 其标签概率恰由某种能量差的玻尔兹曼因子决定。这一线索将在本书后续关于 Softmax 函数的章节中被重新讨论。

从配分函数导出热力学量

现在回到一般情形, 考察配分函数 Z 如何“生成”出全部所关心的宏观量。为使推导保持具体, 每给出一个新公式, 都随即以上述二能级系统进行数值验证。在此之前, 先将本节将要反复用到的两个记号——期望值与方差——正式定义清楚。

■ 预备定义: 期望值与方差

对于取值于状态集合 $\{\mathbf{x}\}$ 、服从概率分布 $P(\mathbf{x})$ 的系统, 任意一个依赖于状态的物理量 $A(\mathbf{x})$ (例如能量 $E(\mathbf{x})$) 的期望值 (或称“平均值”, 物理学中常记作 $\langle A \rangle$) 定义为该物理

量在全部状态上按概率加权的求和：

$$\langle A \rangle \equiv \sum_{\mathbf{x}} P(\mathbf{x}) A(\mathbf{x}).$$

特别地，取 $A(\mathbf{x}) = E(\mathbf{x})$ 即为下面 (1) 中的平均能量 $\langle E \rangle$ ；取 $A(\mathbf{x}) = E(\mathbf{x})^2$ 则记作 $\langle E^2 \rangle = \sum_{\mathbf{x}} P(\mathbf{x}) E(\mathbf{x})^2$ ，即“能量平方”这一物理量的期望值（并非先取平均能量、再平方）。

物理量 A 的方差定义为它偏离自身平均值的均方，用以刻画涨落的剧烈程度：

$$\text{Var}(A) \equiv \langle (A - \langle A \rangle)^2 \rangle.$$

这一定义还有一个更便于计算的等价形式 $\text{Var}(A) = \langle A^2 \rangle - \langle A \rangle^2$ ，下面给出证明（把 $\langle A \rangle$ 看作一个普通常数展开平方即可）：

$$\begin{aligned} \text{Var}(A) &= \langle A^2 - 2A\langle A \rangle + \langle A \rangle^2 \rangle \\ &= \langle A^2 \rangle - 2\langle A \rangle \cdot \langle A \rangle + \langle A \rangle^2 \quad (\text{因 } \langle A \rangle \text{ 是常数, 可提出求和}) \\ &= \langle A^2 \rangle - \langle A \rangle^2. \end{aligned}$$

本节将在 (5) 比热的推导中直接用到这一等价关系。

(1) 平均能量. 系统的平均能量为

$$\langle E \rangle = \sum_{\mathbf{x}} P(\mathbf{x}) E(\mathbf{x}) = \frac{1}{Z} \sum_{\mathbf{x}} E(\mathbf{x}) e^{-\beta E(\mathbf{x})}.$$

注意到对 β 求导会自动引出一个 $E(\mathbf{x})$ 因子：

$$\frac{\partial}{\partial \beta} e^{-\beta E(\mathbf{x})} = -E(\mathbf{x}) e^{-\beta E(\mathbf{x})},$$

因此

$$\sum_{\mathbf{x}} E(\mathbf{x}) e^{-\beta E(\mathbf{x})} = -\frac{\partial}{\partial \beta} \sum_{\mathbf{x}} e^{-\beta E(\mathbf{x})} = -\frac{\partial Z}{\partial \beta},$$

从而

$$\langle E \rangle = -\frac{1}{Z} \frac{\partial Z}{\partial \beta} = -\frac{\partial \ln Z}{\partial \beta}. \quad (2.10)$$

这是一个简洁的结果：平均能量等于配分函数对数关于 β 的负导数。只需求得 Z （无需知道任何单个状态的概率），对其取对数并求导，平均能量即随之给出——这正是“生成函数”方法的核心： Z 相当于一个压缩包，对其对数求导即为“解压”的方式。

■ 数值验证

二能级系统中 $\ln Z = \ln(1 + e^{-\beta \varepsilon})$ ，求导得

$$-\frac{\partial \ln Z}{\partial \beta} = \frac{\varepsilon e^{-\beta \varepsilon}}{1 + e^{-\beta \varepsilon}} = \varepsilon P_1,$$

与直接计算得到的 $\langle E \rangle = P_1 \varepsilon$ （因 $E_0 = 0$ 无贡献）完全一致。

(2) 自由能. 定义亥姆霍兹自由能 (Helmholtz free energy)

$$F = -k_B T \ln Z = -\frac{1}{\beta} \ln Z. \quad (2.11)$$

下面利用自由能的定义, 将平均能量改写为熵的形式, 每一步代数运算均单独列出。

第一步: 将 $\ln Z$ 用 F 表示。由定义 (2.11), $F = -\frac{1}{\beta} \ln Z$, 两边同乘 $-\beta$, 得

$$\ln Z = -\beta F.$$

第二步: 代入平均能量公式 (2.10)。

$$\langle E \rangle = -\frac{\partial \ln Z}{\partial \beta} = -\frac{\partial(-\beta F)}{\partial \beta} = \frac{\partial(\beta F)}{\partial \beta}.$$

第三步: 对 βF 关于 β 求导, 使用乘积法则 (把 $F = F(T(\beta))$ 看作依赖于 β 的函数):

$$\frac{\partial(\beta F)}{\partial \beta} = \underbrace{\frac{\partial \beta}{\partial \beta}}_{=1} \cdot F + \beta \cdot \frac{\partial F}{\partial \beta} = F + \beta \frac{\partial F}{\partial \beta}.$$

因此

$$\langle E \rangle = F + \beta \frac{\partial F}{\partial \beta}. \quad (2.12)$$

第四步: 将 $\partial F / \partial \beta$ 换算为 $\partial F / \partial T$ 。由链式法则,

$$\frac{\partial F}{\partial \beta} = \frac{\partial F}{\partial T} \cdot \frac{\partial T}{\partial \beta}.$$

其中 $\partial T / \partial \beta$ 需要由 $\beta = 1/(k_B T)$ 求出。对 $\beta(T)$ 直接求导:

$$\frac{\partial \beta}{\partial T} = \frac{\partial}{\partial T} \left(\frac{1}{k_B T} \right) = -\frac{1}{k_B T^2}.$$

再利用反函数求导法则 (若 $y = f(x)$ 可逆, 则 $dx/dy = 1/(dy/dx)$):

$$\frac{\partial T}{\partial \beta} = \frac{1}{\partial \beta / \partial T} = \frac{1}{-1/(k_B T^2)} = -k_B T^2.$$

(若采用 $k_B = 1$ 的数学约定, 即 $\partial T / \partial \beta = -T^2$ 。) 代入链式法则:

$$\frac{\partial F}{\partial \beta} = -k_B T^2 \frac{\partial F}{\partial T}. \quad (2.13)$$

第五步: 将式 (2.13) 代入式 (2.12), 并利用 $\beta = 1/(k_B T)$ 化简:

$$\langle E \rangle = F + \beta \left(-k_B T^2 \frac{\partial F}{\partial T} \right) = F - \beta k_B T^2 \frac{\partial F}{\partial T} = F - \underbrace{(\beta k_B T)}_{=1} T \frac{\partial F}{\partial T},$$

最终得到 (与 k_B 的具体取值无关):

$$\langle E \rangle = F - T \frac{\partial F}{\partial T}.$$

(3) 熵. 热力学中熵定义为 $S = -\partial F / \partial T$, 因此 $\langle E \rangle = F + TS$, 整理得

$$F = \langle E \rangle - TS. \quad (2.14)$$

该关系表明, 自由能是能量与熵相互竞争的结果: 低温 ($T \rightarrow 0$) 时 $F \approx \langle E \rangle$, 系统趋于最小化能量; 高温 ($T \rightarrow \infty$) 时熵项占主导, 系统趋于最大化熵 (无序度)。

■ 数值验证

二能级系统在 $k_B T = 1$ ($\beta = 1$) 时, $\ln Z = \ln 1.3679 = 0.3133$, 故 $F = -k_B T \ln Z = -0.3133$; 又 $\langle E \rangle = 0.2689$, 由式 (2.14) 反推熵: $S = (\langle E \rangle - F)/T = (0.2689 - (-0.3133))/1 = 0.5822$ (单位 k_B)。该数值介于“系统完全确定于基态” ($S = 0$) 与“两态等概率”对应的最大熵 $S = \ln 2 \approx 0.693$ 之间, 符合中等温度下系统部分确定、部分不确定的物理图像。

(4) 熵的统计表达式. 熵也可以直接由概率分布计算:

$$S = -k_B \sum_{\mathbf{x}} P(\mathbf{x}) \ln P(\mathbf{x}). \quad (2.15)$$

该式是式 (2.3) ($S = k_B \ln \Omega$) 的推广: 若全部 Ω 个状态等概率, $P(\mathbf{x}) = 1/\Omega$, 代入上式即可还原 $S = k_B \ln \Omega$ (读者可自行验证)。引入能量、概率不再均匀之后, 这一“信息熵”形式的表达式依然成立, 并且正是本书后续讨论最大熵原理时的核心对象。

代入玻尔兹曼分布 (2.6):

$$\begin{aligned} S &= -k_B \sum_{\mathbf{x}} P(\mathbf{x}) [-\beta E(\mathbf{x}) - \ln Z] \\ &= k_B \beta \sum_{\mathbf{x}} P(\mathbf{x}) E(\mathbf{x}) + k_B \ln Z \sum_{\mathbf{x}} P(\mathbf{x}) \\ &= k_B \beta \langle E \rangle + k_B \ln Z \\ &= \frac{\langle E \rangle}{T} + k_B \ln Z. \end{aligned}$$

由 $F = -k_B T \ln Z$ 知 $k_B \ln Z = -F/T$, 因此

$$S = \frac{\langle E \rangle - F}{T},$$

这恰好验证了式 (2.14)。

(5) 比热, 热容量 (比热) 定义为

$$C = \frac{\partial \langle E \rangle}{\partial T}.$$

利用式 (2.10) 与链式法则:

$$C = \frac{\partial \langle E \rangle}{\partial \beta} \frac{\partial \beta}{\partial T} = -\frac{1}{k_B T^2} \frac{\partial \langle E \rangle}{\partial \beta}.$$

其中

$$\frac{\partial \langle E \rangle}{\partial \beta} = -\frac{\partial^2 \ln Z}{\partial \beta^2},$$

而

$$\begin{aligned} \frac{\partial^2 \ln Z}{\partial \beta^2} &= \frac{\partial}{\partial \beta} \left(\frac{1}{Z} \frac{\partial Z}{\partial \beta} \right) \\ &= \frac{1}{Z} \frac{\partial^2 Z}{\partial \beta^2} - \frac{1}{Z^2} \left(\frac{\partial Z}{\partial \beta} \right)^2. \end{aligned}$$

利用

$$\frac{\partial Z}{\partial \beta} = - \sum_{\mathbf{x}} E(\mathbf{x}) e^{-\beta E(\mathbf{x})}, \quad \frac{\partial^2 Z}{\partial \beta^2} = \sum_{\mathbf{x}} E^2(\mathbf{x}) e^{-\beta E(\mathbf{x})},$$

可得

$$\begin{aligned} \frac{\partial^2 \ln Z}{\partial \beta^2} &= \frac{1}{Z} \sum_{\mathbf{x}} E^2(\mathbf{x}) e^{-\beta E(\mathbf{x})} - \left(\frac{1}{Z} \sum_{\mathbf{x}} E(\mathbf{x}) e^{-\beta E(\mathbf{x})} \right)^2 \\ &= \langle E^2 \rangle - \langle E \rangle^2 = \text{Var}(E). \end{aligned}$$

因此

$$C = \frac{1}{k_B T^2} \text{Var}(E). \quad (2.16)$$

该结果表明，比热与能量涨落的方差成正比，这是统计物理中的一个重要结论：宏观响应函数（比热）与微观涨落（能量方差）直接相关，此即涨落-耗散定理的一个具体体现。

■ 数值验证

二能级系统的 E^2 仅取 0（概率 P_0 ）或 ε^2 （概率 P_1 ），故 $\langle E^2 \rangle = P_1 \varepsilon^2$ ，而 $\langle E \rangle^2 = (P_1 \varepsilon)^2$ 。当 $k_B T = 1$ 、 $\varepsilon = 1$ 时， $\text{Var}(E) = P_1 - P_1^2 = P_1(1 - P_1) = 0.2689 \times 0.7311 = 0.1966$ ，故 $C = \text{Var}(E)/T^2 = 0.1966$ （此时 $T = 1$ ，单位 k_B ）。可以验证 $\text{Var}(E) = P_0 P_1 \varepsilon^2$ 这一形式，恰与伯努利分布的方差公式 $p(1-p)$ 一致——这并非巧合：二能级系统本质上就是一次“温度决定成功概率”的伯努利试验。

■ 小结

只要写出配分函数 $Z(\beta) = \sum_{\mathbf{x}} e^{-\beta E(\mathbf{x})}$ ，即可通过对 $\ln Z$ 求一阶导数得到平均能量，通过其二阶导数（表现为方差的形式）得到比热，并借助 $F = -k_B T \ln Z$ 得到自由能，进而导出熵。“配分函数即生成函数”这一表述的全部含义，正是上述推导。

§2.3 一维伊辛模型：相互作用系统的精确解

二能级系统虽然直观，却存在一个重要局限：系统中只有单个粒子，不涉及粒子间的相互作用。而现实系统（以及后续将讨论的神经网络与马尔可夫随机场）真正引人入胜之处，恰恰在于大量单元之间存在相互作用。为使上述抽象概念在具有相互作用的情形下具体化，本节详细讨论一维伊辛模型——统计物理中处理相互作用系统最经典、最简单的模型，也是后续 Hopfield 网络与玻尔兹曼机的直接原型。

模型定义

考虑 N 个排列成一条链的自旋，每个自旋 s_i 可取向上（ $s_i = +1$ ）或向下（ $s_i = -1$ ）两个值——这可视作 §2.1 中“左右两格”模型的推广：相邻自旋之间将产生倾向于同向取值的相互作用，且存在作用于每个自旋的外磁场。系统的能量函数为

$$E(\{s_i\}) = -J \sum_{i=1}^{N-1} s_i s_{i+1} - h \sum_{i=1}^N s_i, \quad (2.17)$$

其中 $J > 0$ 为相互作用强度（铁磁耦合，同向自旋对贡献负能量，故更为稳定）， h 为外磁场强度（ $h > 0$ 倾向于使自旋向上）。

能量函数的物理意义

通过若干典型配置可以理解上述能量函数的行为。

情形一：全部自旋向上（ $s_i = +1, \forall i$ ）：

$$E = -J(N-1) - hN,$$

当 $J, h > 0$ 时，这是能量最低（最稳定）的配置之一。

情形二：全部自旋向下（ $s_i = -1, \forall i$ ）：

$$E = -J(N-1) + hN,$$

当 $h = 0$ 时，该配置与情形一能量相同，体现了系统的对称性。

情形三：完全无序（自旋随机取值）：平均而言，相邻自旋同向的概率约为 $1/2$ ，因此

$$\langle s_i s_{i+1} \rangle \approx 0, \quad \langle s_i \rangle \approx 0, \quad \langle E \rangle \approx 0.$$

情形四：单个自旋翻转：设第 k 个自旋 $s_k = -1$ （ $1 < k < N$ ，即不在链的两端），其余自旋均为 $+1$ 。下面逐步计算此时的能量。

第一步：统计相互作用项 $\sum_i s_i s_{i+1}$ 。整条链共有 $N-1$ 条相邻键。其中：

- 与第 k 个自旋直接相连的键有两条： (s_{k-1}, s_k) 与 (s_k, s_{k+1}) ，每一条键两端一个为 $+1$ 、一个为 -1 （因为只有 s_k 翻转），故每条键贡献 $s_i s_{i+1} = (+1)(-1) = -1$ ，两条键共贡献 $2 \times (-1) = -2$ ；
- 其余 $(N-1) - 2 = N-3$ 条键，两端的自旋均为 $+1$ （未受翻转影响），每条贡献 $s_i s_{i+1} = (+1)(+1) = +1$ ，共贡献 $(N-3) \times (+1) = N-3$ 。

因此

$$\sum_{i=1}^{N-1} s_i s_{i+1} = (N-3) + 2 \times (-1) = N-3-2 = N-5.$$

第二步：统计外场项 $\sum_i s_i$ 。除第 k 个自旋为 -1 外，其余 $N-1$ 个自旋均为 $+1$ ，故

$$\sum_{i=1}^N s_i = (N-1) \times (+1) + 1 \times (-1) = N-2.$$

第三步：代入能量函数 (2.17)：

$$E = -J \sum_i s_i s_{i+1} - h \sum_i s_i = -J(N-5) - h(N-2) = -JN + 5J - hN + 2h.$$

将其改写为与“全部自旋向上”情形（ $E_{\uparrow\uparrow\cdots\uparrow} = -J(N-1) - hN = -JN + J - hN$ ）便于比较的形式：

$$E = [-JN + J - hN] + 4J + 2h = -J(N-1) + 4J - hN + 2h.$$

相较于全部向上的情形，能量增加了

$$\Delta E = E - E_{\uparrow\uparrow\dots\uparrow} = 4J + 2h,$$

这就是产生一个“畴壁”（domain wall）所需付出的能量代价： $4J$ 来自两条被“破坏”的铁磁键（每条键的能量代价为 $2J$ ，因为它从 $-J$ 变为 $+J$ ）， $2h$ 来自一个自旋逆着外场方向排列所付出的塞曼能量代价（从 $-h$ 变为 $+h$ ）。

算例： $N = 2$ 的伊辛链

在处理一般 N 之前，先如 §2.1 与二能级系统的处理方式一样，将 $N = 2$ （仅两个自旋、一条相互作用“键”）的情形完整求解。取 $h = 0$ ，能量简化为 $E = -Js_1s_2$ 。此时仅有 $2^2 = 4$ 个微观状态，可逐一列出：

表 2.5: $N = 2$ 伊辛链（ $h = 0$ ）的微观状态与玻尔兹曼权重

状态 (s_1, s_2)	能量 $E = -Js_1s_2$	玻尔兹曼权重 $e^{-\beta E}$
$(+1, +1)$	$-J$	$e^{\beta J}$
$(+1, -1)$	$+J$	$e^{-\beta J}$
$(-1, +1)$	$+J$	$e^{-\beta J}$
$(-1, -1)$	$-J$	$e^{\beta J}$

配分函数为四个权重之和：

$$Z = 2e^{\beta J} + 2e^{-\beta J} = 4 \cosh(\beta J). \quad (2.18)$$

取 $J = 1$ ，代入具体数值（表 2.6）：

表 2.6: $N = 2$ 伊辛链（ $J = 1$ ）在不同温度下的数值结果

$k_B T$	βJ	权重 $(++, +-, -+, --)$	$Z = 4 \cosh(\beta J)$	概率 $(++, +-, -+, --)$
0.2	5.0	(148.41, 0.0067, 0.0067, 148.41)	296.84	(0.500, 0.000, 0.000, 0.500)
1.0	1.0	(2.718, 0.368, 0.368, 2.718)	6.172	(0.440, 0.060, 0.060, 0.440)
5.0	0.2	(1.221, 0.819, 0.819, 1.221)	4.080	(0.299, 0.201, 0.201, 0.299)

由表 2.6 可读出如下物理图像：

- 低温 ($k_B T = 0.2$)：两个“同向”状态 $(++)$ 与 $(--)$ 几乎占据全部概率（各约 50%），“反向”状态则被显著压制——这正是 $J > 0$ 导致相邻自旋倾向同向这一规则在低温下被严格体现的结果。
- 高温 ($k_B T = 5.0$)：四个状态的概率逐渐趋于 $1/4$ （均匀分布），相互作用的偏好再次被高温“抹平”，这与二能级系统在高温下趋于等概率是同一机制。
- 中间温度 ($k_B T = 1.0$) 则处于二者之间的过渡区域。

■ 思考与验证

能否验证上表中任意温度下均有 $P(++) = P(--)$ 、 $P(+-) = P(-+)$? 这一性质源于系统的何种对称性?

解：将每个自旋同时翻转 ($s_i \rightarrow -s_i$) 不改变能量 $E = -Js_1s_2$ ，因为符号乘积保持不变。这就是 $h = 0$ 时系统所具有的上下对称性，它保证了成对状态的概率必然相等。

有限长开链的精确公式

上述 $N = 2$ 的解法可直接推广至任意有限的 N ，且无需任何近似。考虑一条“开链”（两端不闭合，共有 $N - 1$ 条相邻的键），配分函数为

$$Z = \sum_{s_1, \dots, s_N = \pm 1} \exp\left(\beta J \sum_{i=1}^{N-1} s_i s_{i+1}\right).$$

求解的关键在于逐个自旋地进行求和。将指数中的求和展开为逐项相乘：

$$Z = \sum_{s_1, \dots, s_N = \pm 1} \prod_{i=1}^{N-1} e^{\beta J s_i s_{i+1}} = \sum_{s_1} \sum_{s_2} \dots \sum_{s_N} e^{\beta J s_1 s_2} e^{\beta J s_2 s_3} \dots e^{\beta J s_{N-1} s_N}.$$

注意被求和的乘积中，只有最后一个因子 $e^{\beta J s_{N-1} s_N}$ 含有 s_N ，因此可以先对 s_N 求和，把其余因子作为常数提出：

$$\sum_{s_N = \pm 1} e^{\beta J s_{N-1} s_N} = e^{\beta J s_{N-1}} + e^{-\beta J s_{N-1}}.$$

由于 $s_{N-1} = \pm 1$ ，上式无论 s_{N-1} 取何值，结果都是同一个数：

$$\sum_{s_N = \pm 1} e^{\beta J s_{N-1} s_N} = e^{\beta J} + e^{-\beta J} = 2 \cosh(\beta J),$$

(这一点直接代入 $s_{N-1} = +1$ 或 $s_{N-1} = -1$ 均可验证：两种情形下 $\{e^{\beta J s_{N-1}}, e^{-\beta J s_{N-1}}\}$ 只是把 $\{e^{\beta J}, e^{-\beta J}\}$ 这两个数交换了次序，求和结果不变)。于是对 s_N 求和之后，剩下的表达式变为

$$Z = \sum_{s_1} \dots \sum_{s_{N-1}} e^{\beta J s_1 s_2} \dots e^{\beta J s_{N-2} s_{N-1}} \times 2 \cosh(\beta J),$$

即恰好回到了同样形式的求和问题，只是自旋数目由 N 减少为 $N - 1$ ，并多出一个整体因子 $2 \cosh(\beta J)$ 。

归纳论证。设 $Z(m)$ 表示 m 个自旋、 $m - 1$ 条键的开链配分函数（对 $s_1, \dots, s_m$ 求和）。上述计算表明

$$Z(m) = 2 \cosh(\beta J) \cdot Z(m - 1), \quad m \geq 2,$$

即每对一个自旋求和，都会独立地贡献一个因子 $2 \cosh(\beta J)$ ，且这一递推关系与 m 具体取值无关（每一步的推导过程完全相同，只是变量名从 s_N 换成 s_{N-1} 、 s_{N-2} ，依此类推）。反复应用这一递推关系，从 $m = N$ 降到 $m = 1$ ：

$$Z(N) = 2 \cosh(\beta J) \cdot Z(N - 1) = (2 \cosh(\beta J))^2 Z(N - 2) = \dots = (2 \cosh(\beta J))^{N-1} Z(1).$$

最后 $Z(1)$ 表示只剩一个自由自旋 s_1 、不再有任何键，此时求和只是 $\sum_{s_1=\pm 1} 1 = 2$ （每种取值权重为 1，因为没有键贡献指数因子）。代入即得对任意有限 N 精确成立的结果：

$$Z_{\text{开链}}(N) = 2(2 \cosh(\beta J))^{N-1}. \quad (2.19)$$

可以验证： $N = 2$ 时， $Z = 2(2 \cosh \beta J)^1 = 4 \cosh(\beta J)$ ，与式 (2.18) 一致。取 $N = 3$ 、 $k_B T = 1$ （即 $J = 1, \beta = 1$ ）代入式 (2.19)： $Z = 2 \times (2 \cosh 1)^2 = 2 \times (2 \times 1.5431)^2 = 2 \times (3.0862)^2 = 2 \times 9.524 = 19.05$ ；若将全部 $2^3 = 8$ 个微观状态直接列出并逐一求和，同样得到 19.05，读者可将此作为自我检验。

■ 注

“逐个求和、每一步均得到与前面变量无关的同一因子”这一技巧，正是后续章节中信念传播（belief propagation）与变量消去（variable elimination）算法的雏形——在机器学习的图模型推断中，这本质上是同一套数学操作的不同名称。

转移矩阵方法与周期边界条件

开链公式虽然精确，但当链长趋于任意大、并研究其体相(bulk)性质时，两端的边界效应会使公式显得不够对称。物理学家通常改用周期边界条件，将链首尾相连成一个环（即令 $s_{N+1} = s_1$ ）。这样处理的优点在于：链上每一个自旋的地位完全等价，不存在特殊的两端，因而更适合提取热力学极限（ $N \rightarrow \infty$ ）下的普遍规律；而当 N 充分大时，边界条件的选择对宏观热力学量的影响仅是可忽略的边界修正，两种边界条件给出的结果趋于一致。

定义转移矩阵 $\mathbf{T}$ ：

$$T_{s,s'} = e^{\beta J s s'}, \quad s, s' \in \{-1, +1\}, \quad (2.20)$$

具体地，

$$\mathbf{T} = \begin{pmatrix} e^{\beta J} & e^{-\beta J} \\ e^{-\beta J} & e^{\beta J} \end{pmatrix},$$

其中第一行/列对应 $s = +1$ ，第二行/列对应 $s = -1$ 。不难发现，该矩阵的每一个元素正是前文 $N = 2$ 算例中已经算出的四个玻尔兹曼权重，转移矩阵只是将它们排列为矩阵形式，以便处理更长的链。

配分函数可写为

$$Z = \sum_{\{s_i\}} \prod_{i=1}^{N-1} e^{\beta J s_i s_{i+1}} = \sum_{s_1, \dots, s_N} T_{s_1, s_2} T_{s_2, s_3} \cdots T_{s_{N-1}, s_N}.$$

在周期边界条件（ $s_{N+1} = s_1$ ）下，

$$Z = \sum_{s_1} (T^N)_{s_1, s_1} = \text{Tr}(\mathbf{T}^N). \quad (2.21)$$

矩阵的迹恰好等于其全部本征值之和，这正是转移矩阵方法的强大之处：将一个包含 2^N 项的求和问题，转化为求解一个 2×2 矩阵本征值的线性代数问题。

求解转移矩阵的本征值与本征向量

本征值 λ 满足特征方程 $\det(\mathbf{T} - \lambda \mathbf{I}) = 0$ 。代入 $\mathbf{T}$ 的具体形式：

$$\det \begin{pmatrix} e^{\beta J} - \lambda & e^{-\beta J} \\ e^{-\beta J} & e^{\beta J} - \lambda \end{pmatrix} = 0 \implies (e^{\beta J} - \lambda)^2 - (e^{-\beta J})^2 = 0.$$

这是一个关于 $(e^{\beta J} - \lambda)$ 的平方差方程，可直接开方：

$$e^{\beta J} - \lambda = \pm e^{-\beta J} \implies \lambda = e^{\beta J} \mp e^{-\beta J}.$$

于是得到两个本征值：

$$\lambda_+ = e^{\beta J} + e^{-\beta J} = 2 \cosh(\beta J), \quad \lambda_- = e^{\beta J} - e^{-\beta J} = 2 \sinh(\beta J). \quad (2.22)$$

λ_+ 恰好就是开链求和中反复出现的 $2 \cosh(\beta J)$ ，这并非巧合——两种方法（逐项求和与转移矩阵对角化）本质上是同一个计算的两种组织方式。

对应的本征向量可代入 $(\mathbf{T} - \lambda_{\pm} \mathbf{I})\mathbf{v} = 0$ 直接求得。以 λ_+ 为例：

$$\begin{pmatrix} e^{\beta J} - \lambda_+ & e^{-\beta J} \\ e^{-\beta J} & e^{\beta J} - \lambda_+ \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \mathbf{0} \implies -e^{-\beta J} v_1 + e^{-\beta J} v_2 = 0 \implies v_1 = v_2,$$

（这里用到了 $e^{\beta J} - \lambda_+ = -e^{-\beta J}$ ，即式 (2.22) 的定义）故 λ_+ 对应的（归一化）本征向量为

$$\mathbf{v}_+ = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

完全类似地，代入 λ_- 可得 $-e^{-\beta J} v_1 - e^{-\beta J} v_2 = 0$ ，即 $v_1 = -v_2$ ，对应本征向量为

$$\mathbf{v}_- = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

这两个本征向量分别是自旋组态“对称”与“反对称”叠加的类比，二者正交，构成 $\mathbb{R}^2$ 的一组标准正交基——这一结果在后文推导关联函数时将被直接用到。于是

$$Z = \lambda_+^N + \lambda_-^N.$$

对于大 N ，由于 $\lambda_+ > |\lambda_-|$ （当 $J > 0$ 时），最大本征值 λ_+ 占主导地位 $((\lambda_-/\lambda_+)^N \rightarrow 0)$ ：

$$Z \approx \lambda_+^N = (e^{\beta J} + e^{-\beta J})^N = (2 \cosh(\beta J))^N.$$

该结果与开链公式 $Z_{\text{开链}} = 2(2 \cosh \beta J)^{N-1}$ 相比，仅相差一个不随 N 增长的前置因子（即 2 与 $(2 \cosh \beta J)^N / (2 \cosh \beta J)^{N-1} = 2 \cosh \beta J$ 之比），在 $N \rightarrow \infty$ 取每格点平均量（例如“每格点自由能”）时，这一差异将被 N 除掉而彻底消失——这印证了前文所述“边界效应在热力学极限下可忽略”这一结论。

因此，每格点自由能为

$$f = \frac{F}{N} = -\frac{1}{\beta N} \ln Z \approx -\frac{1}{\beta} \ln(2 \cosh(\beta J)). \quad (2.23)$$

高温与低温极限

高温极限 ($T \rightarrow \infty, \beta \rightarrow 0$): 利用 $\cosh$ 函数在 $x = 0$ 附近的泰勒展开 $\cosh x = 1 + \frac{x^2}{2!} + \cdots$, 当 $\beta J \rightarrow 0$ 时只保留到二阶:

$$\cosh(\beta J) \approx 1 + \frac{(\beta J)^2}{2} \quad \Rightarrow \quad 2 \cosh(\beta J) \approx 2 \left[1 + \frac{(\beta J)^2}{2} \right].$$

代入式 (2.23), 并利用对数的乘法法则 $\ln(ab) = \ln a + \ln b$:

$$f = -\frac{1}{\beta} \ln(2 \cosh(\beta J)) \approx -\frac{1}{\beta} \ln \left(2 \left[1 + \frac{(\beta J)^2}{2} \right] \right) = -\frac{1}{\beta} \left[\ln 2 + \ln \left(1 + \frac{(\beta J)^2}{2} \right) \right].$$

当 $\beta \rightarrow 0$ 时, $\ln \left(1 + \frac{(\beta J)^2}{2} \right) \rightarrow 0$ 且趋于零的速度快于 $\ln 2$ (后者是与 β 无关的常数), 故只保留主导项:

$$f \approx -\frac{1}{\beta} \ln 2 = -k_B T \ln 2.$$

相应的熵可由 $f \approx -k_B T \ln 2$ 直接求导得到:

$$s = -\frac{\partial f}{\partial T} = -\frac{\partial}{\partial T} (-k_B T \ln 2) = k_B \ln 2 \cdot \frac{\partial T}{\partial T} = k_B \ln 2,$$

这正是 N 个独立自旋所具有的熵: 高温下自旋完全无序, 相互作用可忽略不计——这与 $N = 2$ 数值算例中“高温下四个状态趋于等概率 $1/4$ ”的结果相吻合: 每个自旋独立地贡献 $\ln 2$ 的熵, 正对应 §2.1 中“无偏好、等概率”情形的推广。

低温极限 ($T \rightarrow 0, \beta \rightarrow \infty$): 当 $\beta J \rightarrow \infty$ 时 $e^{-\beta J} \rightarrow 0$, 故

$$\cosh(\beta J) = \frac{e^{\beta J} + e^{-\beta J}}{2} \approx \frac{e^{\beta J}}{2} \quad \Rightarrow \quad 2 \cosh(\beta J) \approx e^{\beta J}.$$

代入式 (2.23):

$$f = -\frac{1}{\beta} \ln(2 \cosh(\beta J)) \approx -\frac{1}{\beta} \ln e^{\beta J} = -\frac{1}{\beta} \cdot \beta J = -J,$$

这正是基态能量 (全部自旋同向, 每条键贡献 $-J$)。低温下系统被“冻结”于最低能量态, 这一结论与二能级系统中 $T \rightarrow 0$ 时 $P_0 \rightarrow 1$ 的结果、以及 $N = 2$ 数值算例中低温下同向状态占据全部概率的现象相互呼应。

相关函数

定义自旋-自旋相关函数

$$C(r) = \langle s_i s_{i+r} \rangle - \langle s_i \rangle \langle s_{i+r} \rangle.$$

在 $h = 0$ 时, 由对称性可知 $\langle s_i \rangle = 0$ (与前文“思考与验证”中所验证的上下对称性一致), 故

$$C(r) = \langle s_i s_{i+r} \rangle.$$

下面完整推导 $\langle s_i s_{i+r} \rangle$ 的转移矩阵表达式, 并由此得到式 (2.24)。由周期边界条件下链上各格点地位等价 (平移不变性), 不失一般性取 $i = 1$ 。

第一步：将求和写成矩阵乘积的收缩。按期望值的定义，

$$\langle s_1 s_{1+r} \rangle = \frac{1}{Z} \sum_{s_1, \dots, s_N = \pm 1} s_1 s_{1+r} T_{s_1 s_2} T_{s_2 s_3} \cdots T_{s_N s_1}.$$

把从 s_1 到 s_1 的这一整条闭合路径，在 s_{1+r} 处切成两段：第一段是从 s_1 经 r 步到 s_{1+r} ，第二段是从 s_{1+r} 经 $N-r$ 步回到 s_1 。对居中的自旋 $s_2, \dots, s_r$ 以及 $s_{r+2}, \dots, s_N$ 逐个求和，按矩阵乘法的定义 $(T^m)_{a,b} = \sum_{c_1, \dots, c_{m-1}} T_{a,c_1} T_{c_1,c_2} \cdots T_{c_{m-1},b}$ ，两段分别收缩为 T^r 与 T^{N-r} 的矩阵元：

$$\langle s_1 s_{1+r} \rangle = \frac{1}{Z} \sum_{s_1, s_{1+r}} s_1 (T^r)_{s_1, s_{1+r}} s_{1+r} (T^{N-r})_{s_{1+r}, s_1}.$$

第二步：引入自旋算符矩阵 $\mathbf{S}$ 。定义对角矩阵

$$\mathbf{S} = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \quad (\text{即 } S_{s,s'} = s \delta_{s,s'}),$$

它的作用是给每个自旋态乘上其自身的取值 $s = \pm 1$ 。由于 $\mathbf{S}$ 对角， $s_1 (T^r)_{s_1, s_{1+r}} s_{1+r} = S_{s_1, s_1} (T^r)_{s_1, s_{1+r}} S_{s_{1+r}, s_{1+r}}$ $(\mathbf{S} T^r \mathbf{S})_{s_1, s_{1+r}}$ ，于是

$$\langle s_1 s_{1+r} \rangle = \frac{1}{Z} \sum_{s_1, s_{1+r}} (\mathbf{S} T^r \mathbf{S})_{s_1, s_{1+r}} (T^{N-r})_{s_{1+r}, s_1} = \frac{1}{Z} \text{Tr}(\mathbf{S} \mathbf{T}^r \mathbf{S} \mathbf{T}^{N-r}),$$

最后一步用到了矩阵乘积的迹 $\text{Tr}(AB) = \sum_{a,b} A_{a,b} B_{b,a}$ 的定义。

第三步：在转移矩阵的本征基下计算这一迹。迹与所选基底无关，因此可以改在 $\mathbf{T}$ 的本征基 $\{\mathbf{v}_+, \mathbf{v}_-\}$ （已在上文求出）下计算。在此基下 $\mathbf{T}$ 是对角矩阵 $\text{diag}(\lambda_+, \lambda_-)$ ；而 $\mathbf{S}$ 的作用是 $\mathbf{S} \mathbf{v}_+ = \mathbf{v}_-$ 、 $\mathbf{S} \mathbf{v}_- = \mathbf{v}_+$ （读者可直接代入 $\mathbf{v}_{\pm} = \frac{1}{\sqrt{2}}(1, \pm 1)^T$ 验证： $\mathbf{S} \mathbf{v}_+ = \frac{1}{\sqrt{2}}(1, -1)^T = \mathbf{v}_-$ ），即 $\mathbf{S}$ 在本征基下把两个本征向量互换，其矩阵表示为

$$\mathbf{S} \rightarrow \mathbf{X} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \quad (\text{本征基下}).$$

记 $D_1 = \text{diag}(\lambda_+^r, \lambda_-^r)$ ， $D_2 = \text{diag}(\lambda_+^{N-r}, \lambda_-^{N-r})$ ，逐步计算 $\mathbf{X} D_1 \mathbf{X} D_2$ ：

$$\begin{aligned} \mathbf{X} D_1 &= \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} \lambda_+^r & 0 \\ 0 & \lambda_-^r \end{pmatrix} = \begin{pmatrix} 0 & \lambda_-^r \\ \lambda_+^r & 0 \end{pmatrix}, \\ (\mathbf{X} D_1) \mathbf{X} &= \begin{pmatrix} 0 & \lambda_-^r \\ \lambda_+^r & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} \lambda_-^r & 0 \\ 0 & \lambda_+^r \end{pmatrix}, \\ (\mathbf{X} D_1 \mathbf{X}) D_2 &= \begin{pmatrix} \lambda_-^r & 0 \\ 0 & \lambda_+^r \end{pmatrix} \begin{pmatrix} \lambda_+^{N-r} & 0 \\ 0 & \lambda_-^{N-r} \end{pmatrix} = \begin{pmatrix} \lambda_-^r \lambda_+^{N-r} & 0 \\ 0 & \lambda_+^r \lambda_-^{N-r} \end{pmatrix}. \end{aligned}$$

取迹（对角元求和）：

$$\text{Tr}(\mathbf{S} \mathbf{T}^r \mathbf{S} \mathbf{T}^{N-r}) = \lambda_+^{N-r} \lambda_-^r + \lambda_+^r \lambda_-^{N-r}.$$

第四步：代入 $Z = \lambda_+^N + \lambda_-^N$ ，取热力学极限。于是

$$\langle s_1 s_{1+r} \rangle = \frac{\lambda_+^{N-r} \lambda_-^r + \lambda_+^r \lambda_-^{N-r}}{\lambda_+^N + \lambda_-^N}.$$

分子分母同除以 λ_+^N :

$$\langle s_1 s_{1+r} \rangle = \frac{\left(\frac{\lambda_-}{\lambda_+}\right)^r + \left(\frac{\lambda_-}{\lambda_+}\right)^{N-r}}{1 + \left(\frac{\lambda_-}{\lambda_+}\right)^N}.$$

当 $J > 0$ 且温度有限时, $0 < \lambda_-/\lambda_+ = \tanh(\beta J) < 1$; 固定 r , 取 $N \rightarrow \infty$, 则 $(\lambda_-/\lambda_+)^N \rightarrow 0$, 且 $(\lambda_-/\lambda_+)^{N-r} \rightarrow 0$ (因为 $N-r \rightarrow \infty$)。分母趋于 1, 分子中第二项趋于 0, 只剩下第一项:

$$C(r) = \langle s_1 s_{1+r} \rangle \xrightarrow{N \rightarrow \infty} \left(\frac{\lambda_-}{\lambda_+}\right)^r = \left(\frac{e^{\beta J} - e^{-\beta J}}{e^{\beta J} + e^{-\beta J}}\right)^r = [\tanh(\beta J)]^r. \quad (2.24)$$

这就完整地证明了式 (2.24)。

相关长度的定义。物理上习惯将关联函数的衰减写成指数形式 $C(r) \sim e^{-r/\xi}$, 其中 ξ 称为相关长度, 表征关联“传播”的空间尺度。将式 (2.24) 中的幂函数改写为指数形式 (利用 $a^r = e^{r \ln a}$):

$$C(r) = [\tanh(\beta J)]^r = e^{r \ln \tanh(\beta J)} = e^{-r/\xi},$$

两边指数上的系数相等, 即 $\ln \tanh(\beta J) = -1/\xi$, 解得 (注意 $0 < \tanh(\beta J) < 1$ 时 $\ln \tanh(\beta J) < 0$, 故需取绝对值以保证 $\xi > 0$)

$$\xi = -\frac{1}{\ln |\tanh(\beta J)|}. \quad (2.25)$$

取 $J = 1$, 代入具体数值 (表 2.7):

表 2.7: 相关长度 ξ 随温度的变化 ($J = 1$)

$k_B T$	βJ	$\tanh(\beta J)$	ξ (相关长度, 单位: 格点数)
0.3	3.33	0.998	393
1.0	1.00	0.762	3.7
3.0	0.33	0.322	0.9

由表 2.7 可见: 高温时 (表中最后一行) $\beta J \ll 1$, $\tanh(\beta J) \approx \beta J$, 相关长度不足一个格点, 自旋之间几乎不相关。

低温时 (表中第一行) $\beta J \gg 1$, 可以进一步给出 ξ 的解析近似。此时 $e^{-\beta J} \ll e^{\beta J}$, 将 $\tanh(\beta J) = \frac{e^{\beta J} - e^{-\beta J}}{e^{\beta J} + e^{-\beta J}}$ 的分子分母同除以 $e^{\beta J}$:

$$\tanh(\beta J) = \frac{1 - e^{-2\beta J}}{1 + e^{-2\beta J}}.$$

利用 $\beta J \gg 1$ 时 $e^{-2\beta J} \ll 1$, 对分母作一阶近似 $\frac{1}{1 + e^{-2\beta J}} \approx 1 - e^{-2\beta J}$, 代入并只保留一阶小量:

$$\tanh(\beta J) \approx (1 - e^{-2\beta J})(1 - e^{-2\beta J}) \approx 1 - 2e^{-2\beta J}.$$

代入相关长度公式 (2.25), 并利用 $\ln(1-x) \approx -x$ (当 $x \ll 1$, 此处 $x = 2e^{-2\beta J}$):

$$\ln \tanh(\beta J) \approx \ln(1 - 2e^{-2\beta J}) \approx -2e^{-2\beta J},$$

于是

$$\xi = -\frac{1}{\ln \tanh(\beta J)} \approx \frac{1}{2e^{-2\beta J}} = \frac{1}{2}e^{2\beta J}.$$

相关长度呈指数增长，可达数百个格点——此时一个自旋的取向将“传播”至远处的自旋，使整条链趋于协同取向。这种“温度越低、相关长度越长”的现象，正是许多物理系统（以及后续将讨论的深层神经网络中长程依赖关系）中临界现象与关联结构的雏形。

与机器学习的联系

一维伊辛模型已经包含了后续在机器学习中将反复出现的全部要素：

1. 能量函数 $E(\{s_i\})$ ：对不满足约束的组态施加惩罚；
2. 玻尔兹曼分布 $P \propto e^{-\beta E}$ ：在能量最小化与状态探索之间取得平衡；
3. 配分函数 Z ：归一化常数，但其计算通常十分困难——当自旋数目庞大、相互作用图变得复杂时， Z 不再具有一维链这样的解析解，这一计算挑战将在本书后续章节详细讨论；
4. 相互作用：相邻单元之间的依赖关系；
5. 温度：控制系统随机性的参数。

在后续章节中将会看到，Hopfield 网络与玻尔兹曼机正是一维伊辛模型的直接推广：一维链上“相邻自旋相互作用”这一简单规则，将被推广为“任意两个神经元之间均可能存在带权重的连接”；而本节逐一验证过的每一个概念——能量、配分函数、玻尔兹曼分布、相关长度——都将原封不动地延续到机器学习的语境之中。

■ 小结

本节沿着一条完整的路径展开：首先从纯粹的组合数学“数格子”问题出发 (§2.1)，无需任何物理假设即得到“宏观确定性源自微观概率优势”这一核心直觉；引入能量与热库之后，同一条等概率原理自然导出了玻尔兹曼分布与配分函数 (§2.2)，且配分函数的对数可以生成平均能量、自由能、熵、比热等全部热力学量；最后将这套工具应用于一个具有真实相互作用的系统——一维伊辛模型（本节），精确求解了配分函数、相关函数与相关长度，并首次观察到“高温无序、低温有序”这一将反复出现的主题。本节建立的语言——能量、玻尔兹曼分布、配分函数、温度——构成了后续将统计物理与机器学习相连接时所需的全部基本词汇。

一张待填的表：本书接下来要做的事

本章从头到尾没有出现过一个机器学习名词，这是刻意的——先把物理语言本身的地基打牢，再去看它能承载什么。但读到这里，读者已经拥有了表 2.8 左边一整列的全部词汇。右边一列暂时空着，只标注了“将在何处揭晓”；接下来五章要做的事情，说到底就是把这张表的右边逐一填满——每一次填表，都会在正文中被明确标出，读者可以随时翻回这里核对进度。

表 2.8: 全书的核心对照表——第二章播下的种子（将在后续各章逐行填满）

统计物理（本章已建立）	机器学习对应	将在何处揭晓
微观状态 $\mathbf{x}$	（待填）	第四章
能量函数 $E(\mathbf{x})$	（待填）	第四章
玻尔兹曼分布 $P(\mathbf{x}) \propto e^{-\beta E(\mathbf{x})}$	（待填）	第四章
配分函数 Z	（待填）	第四、五章
自由能 $F = \langle E \rangle - TS$	（待填）	第六章
逆温度 $\beta = 1/(k_B T)$	（待填）	第四章
熵 S	（待填）	第六、七章

这张表不是装饰——它是一份可以核对的承诺。如果读到全书第一部分结尾（第七章末尾的表 7.2），这里列出的“将在何处揭晓”有任何一处落空，那就是这本书没有兑现自己的叙事，读者应当据此追问。

习题

基础题

习题 2.1: 配分函数与平均能量

考虑一个两态系统，能级为 $E_1 = 0$ 和 $E_2 = \epsilon$ 。

- 写出配分函数 $Z(\beta)$ ；
- 计算平均能量 $\langle E \rangle$ 作为温度 T 的函数；
- 画出 $\langle E \rangle$ 随 T 变化的曲线。在高温和低温极限下， $\langle E \rangle$ 的值是多少？
- 计算热容 $C = \frac{\partial \langle E \rangle}{\partial T}$ ，并找出 C 取最大值时的温度。

提示： $\langle E \rangle = \frac{\epsilon}{e^{\beta\epsilon} + 1}$ 。

进阶题

习题 2.2: 一维伊辛模型的精确解

考虑 N 个自旋的一维伊辛模型（周期边界条件）：

$$E = -J \sum_{i=1}^N s_i s_{i+1}, \quad s_i \in \{-1, +1\} \quad (\text{约定 } s_{N+1} = s_1).$$

- 写出转移矩阵 $\mathbf{T}$ ，其元素为 $T_{s,s'} = e^{\beta J s s'}$ ；

- (b) 证明配分函数可以写为 $Z = \text{Tr}(\mathbf{T}^N)$;
- (c) 计算转移矩阵的本征值;
- (d) 在热力学极限 $N \rightarrow \infty$, 推导自由能 (per site) $f = -\frac{1}{\beta} \lim_{N \rightarrow \infty} \frac{1}{N} \ln Z$;
- (e) 计算平均能量 (per site) 和热容。

挑战题

习题 2.3: Landauer 原理与计算的物理极限

- (a) 研究 Landauer 原理：擦除 1 bit 信息需要耗散至少 $k_B T \ln 2$ 的能量;
- (b) 估算：在室温下 ($T = 300 \text{ K}$)，擦除 1 bit 的最小能量是多少焦耳?
- (c) 现代 CPU 的晶体管开关一次大约耗能 10^{-15} J ，这比 Landauer 极限高多少倍?
- (d) 估算训练一个大型语言模型（如 GPT-3，参数量 $\sim 10^{11}$ ）所需的理论最小能量（假设每个参数存储需要 32 bit）;
- (e) 人脑大约有 10^{11} 个神经元、 10^{15} 个突触，功率约 20 W 。估算人脑的“计算效率”（每焦耳的突触操作次数），并与现代计算机比较。

习题 2.4: 跨学科项目：物理启发的优化算法

设计并测试一个物理启发的优化算法。

- (a) 模拟退火 (**Simulated Annealing**): 实现一个模拟退火算法，用于优化一个非凸函数（如 Ackley 函数或 Rastrigin 函数）;
- (b) 退火策略：比较不同的“温度衰减”策略——线性 $T(t) = T_0 - \alpha t$ 、指数 $T(t) = T_0 e^{-\alpha t}$ 、对数 $T(t) = T_0 / \ln(1 + t)$;
- (c) 物理类比：将优化过程可视化能量景观上的扩散，温度的作用是什么?
- (d) 与梯度下降比较：在哪些情况下模拟退火优于梯度下降？什么时候不如?
- (e) 扩展：研究“量子退火” (Quantum Annealing) 的基本原理，它与经典模拟退火有什么区别?

机器学习中的概率模型

*Trifles light as air
Are to the jealous confirmations strong
As proofs of holy writ.*

—— 莎士比亚《奥赛罗》第三幕第三场，
伊阿古

学习目标

- 理解监督学习中回归与分类问题的本质区别，以及概率视角相对于传统函数拟合视角的优势；
- 通过可徒手验证的具体算例，掌握似然函数的构造方法与最大似然估计（MLE）的推导；
- 理解 MLE 在小样本下容易给出过度自信估计的局限性，并掌握引入先验分布后的最大后验估计（MAP）；
- 建立正则化（如 L^2 正则化/岭回归）与先验分布之间的对应关系，并与统计物理中的“外场”类比相联系。

■ 本章导览

本章回答的问题：给定一批观测数据，如何为一个带参数的模型估计出“最合理”的参数？机器学习中最基础的两种估计方法——最大似然估计（MLE）与最大后验估计（MAP）——是如何从概率论的第一原理推导出来的？

统计物理对应：本章“观测数据 → 似然函数 → 参数估计”这条逻辑链，与第二章“等概率原理 → 玻尔兹曼分布 → 配分函数”几乎镜像对称；MAP 中“先验”所扮演的角色，将在第四章被重新理解为物理上的“外场”。

后续预告：第四章会证明，本章“取负对数似然作为损失”这一操作，正是把第二章的能量函数原封不动地搬到机器学习中来；第七章的最小交叉熵原理，会把本章“先验把估计拉向自身”这一直觉，从单个参数推广到整个概率分布的选择上。

在第二章中，我们经由这样一条逻辑链展开：等概率原理 → 玻尔兹曼分布 → 配分函数 → 热力学量。本章将沿着一条几乎与之镜像对称的路径展开：观测数据 → 似然函数 → 参数

估计。这条路径在数学操作上与前一章惊人地相似——都是先将一个“乘积”或“求和”取对数，再求极值。若某个推导步骤显得似曾相识，这并非巧合，而正是贯穿本书的核心线索之一。

§3.1 监督学习的基本设定

问题描述

考虑一组训练数据：

$$\mathcal{D} = \{(\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots, (\mathbf{x}^{(N)}, y^{(N)})\},$$

其中：

- $\mathbf{x}^{(n)} \in \mathbb{R}^d$ 是第 n 个样本的特征向量（输入）；
- $y^{(n)}$ 是对应的标签（输出）：
 - 回归问题： $y^{(n)} \in \mathbb{R}$ ；
 - 分类问题： $y^{(n)} \in \{1, 2, \dots, K\}$ 。

目标：学习一个函数 $f: \mathbb{R}^d \rightarrow \mathcal{Y}$ ，使得对于新的输入 $\mathbf{x}$ ，能够准确预测 $y = f(\mathbf{x})$ 。

回归与分类：两个具体例子

上述记号较为抽象，下面用两个具体的数据集，将“回归”与“分类”的区别彻底阐明——这一区别归根结底在于标签 $y^{(n)}$ 究竟是连续数值还是离散类别。

例 1（回归）：根据面积预测房价。设已收集 5 套房产的成交记录，特征 $x^{(n)}$ 为面积（平方米），标签 $y^{(n)}$ 为成交价（万元）：

表 3.1: 房价预测（回归问题）示例数据

样本 n	面积 $x^{(n)}$ (m ²)	成交价 $y^{(n)}$ (万元)
1	50	150
2	70	205
3	90	260
4	110	310
5	130	365

此处 $y^{(n)}$ 可取任意实数值（150, 205, 260, ..., 甚至未来可能出现 208.5 这样的数字），且这些数值之间具有明确的大小关系与距离——“310 万”比“260 万”贵 50 万，这一“50 万”具有实际意义。这正是回归问题的特征：标签是连续的、可施加算术运算的数值。给定一个新的面积（例如 $x = 100$ ），模型需要输出一个具体的价格预测（例如 285 万左右）。

例 2（分类）：判断一封邮件是否为垃圾邮件。特征 $\mathbf{x}^{(n)}$ 可以是一个向量，例如 [邮件中“免费”一词出现的次数、包含的链接数、发件人是否为陌生地址]；标签 $y^{(n)} \in \{0, 1\}$ ，其中 1 表示垃圾邮件，0 表示正常邮件：

表 3.2: 垃圾邮件识别（分类问题）示例数据

样本 n	“免费”出现次数	链接数	发件人陌生?	标签 $y^{(n)}$
1	3	5	是	1 (垃圾邮件)
2	0	1	否	0 (正常邮件)
3	2	4	是	1 (垃圾邮件)
4	0	0	否	0 (正常邮件)

此处标签 0 与 1 仅为类别的编号，而非可施加算术运算的数值——“垃圾邮件”减去“正常邮件”没有任何意义；若将标签替换为“猫/狗”这样的文字，问题的本质完全不变。这正是分类问题的特征：标签是离散的类别，类别之间（在一般情形下）不存在大小或距离关系。若类别数 $K > 2$ （例如手写数字识别， $y \in \{0, 1, \dots, 9\}$ ），道理完全相同，只是需要在更多类别中作出选择。

■ 释疑

回归与分类的界限有时会模糊。例如“预测一个学生的期末成绩等级：优秀/良好/合格/不合格”，表面上是若干离散类别（看似分类问题），但这些等级之间存在天然的顺序（优秀 > 良好 > 合格 > 不合格）。此类问题有时被当作一种特殊处理的有序分类（ordinal classification），介于纯粹的回归与无序的分类之间。面对具体问题时，可先自问：标签之间“能否做减法、是否存在大小关系”，这通常有助于判断应采用哪一类方法。

■ 思考与验证

判断下列两个预测任务分别属于回归还是分类：（1）预测一段音频中有几个人在说话（0 人、1 人、2 人……）；（2）预测一张图片中的动物是猫、狗还是鸟。

解：（1）尽管说话人数为整数，但它具有明确的大小关系与算术意义（“3 人”比“1 人”多说了 2 人份的话），可以采用回归的思路来处理；但直接套用本章接下来要推导的、以高斯噪声为前提的普通回归（见 §4.2）并不理想——高斯回归的预测值可以取任意实数，容易给出 $\hat{y} < 0$ 这样对“人数”没有意义的结果。更自然的选择是把 $y \in \{0, 1, 2, \dots\}$ 本身的计数结构纳入概率模型，例如泊松回归（Poisson regression，假设 $y|\mathbf{x} \sim \text{Poisson}(\lambda(\mathbf{x}))$ ）或负二项回归；这正是“选定噪声/随机性的分布形式 → 写出似然 → 取负对数”这一整套方法论（第四章的主题）在计数数据上的具体应用，只是把“高斯噪声”换成“泊松噪声”。（2）“猫、狗、鸟”之间不存在任何大小或顺序关系，是标准的三分类问题。

从函数拟合到概率建模

传统观点：机器学习是寻找一个“最佳拟合”的函数。

概率观点：数据由某个未知的概率分布生成，学习的目标是估计这一分布（或其参数）。

这两种观点的差别，用天气预报的例子最容易体会。传统观点式的天气预报会直接给出“明天下雨”这一确定的判断；概率观点式的天气预报则会给出“明天下雨的概率为 70%”。后

者显然携带了更多信息——它不仅给出了最可能的结果，还说明了这一判断的把握程度。这正是概率建模相较于单纯函数拟合的核心优势。

概率观点的优势主要体现在以下几个方面：

1. 不确定性的量化：概率模型不仅给出预测值，还给出置信度；
2. 噪声的自然处理：现实数据普遍存在噪声，概率框架天然包含噪声模型；
3. 正则化的自然解释：先验分布对应于正则化；
4. 统一的框架：回归、分类、聚类均可在概率框架下统一处理。

■ 物理类比

在概率建模的语言中，模型参数 θ 所扮演的角色，正如伊辛模型中的耦合强度 J 与外场 h ——它们本身并非“数据”，而是决定整个概率分布形状的参数。调节 J, h 会改变伊辛链倾向于哪些自旋构型；调节 θ 会改变模型倾向于对哪些 y 分配较高概率。学习的过程，本质上就是调节这些参数，使分布更符合观测到的数据。

■ 思考与验证

设想一个二分类问题——判断一封邮件是否为垃圾邮件。“传统观点”给出的输出是“是”或“否”；“概率观点”给出的输出可能是“是垃圾邮件的概率为 0.93”。对邮件客户端的设计者而言，为何概率式的输出更为有用？

解：可以考虑“概率为 0.51”与“概率为 0.99”这两种情形——二者对应同一个“是”的判断，但对判断的信任程度、以及是否需要交由用户复核，理应有所不同。纯粹的“是/否”输出会将这一差别完全抹去。

§3.2 概率建模的基本假设

■ 预备定义：条件概率与独立性

本章将大量使用形如 $P(y|\mathbf{x}, \theta)$ 这样带竖线的记号，这里先将其含义正式说明清楚。对于两个（可能相关的）随机量 A, B ， A 在“已知 B ”这一条件下的条件概率定义为

$$P(A|B) \equiv \frac{P(A, B)}{P(B)} \quad (\text{要求 } P(B) > 0),$$

其中 $P(A, B)$ 表示 A 与 B 同时发生的联合概率。直观上， $P(A|B)$ 回答的问题是：“一旦已经知道 B 发生了， A 发生的概率应当如何重新评估？”对于式 (3.1) 中的 $P(y|\mathbf{x}, \theta)$ ，可以将 $\mathbf{x}$ （输入特征）与 θ （模型参数）都看作“已知条件”， $P(y|\mathbf{x}, \theta)$ 描述的正是在这些条件下标签 y 的概率分布——这与《热学》中条件概率的用法完全一致，只是此处的“条件”换成了特征与参数。

两个随机量 A, B 称为相互独立，如果知道 B 的取值完全不改变 A 的概率分布，即

$$P(A|B) = P(A) \quad \Longleftrightarrow \quad P(A, B) = P(A)P(B),$$

(两个条件相互等价, 可直接由条件概率的定义代入验证: 若 $P(A|B) = P(A)$, 代入定义式 $P(A|B) = P(A, B)/P(B)$ 即得 $P(A, B) = P(A)P(B)$, 反之亦然)。这正是式 (3.2) 中“联合概率等于各自概率之乘积”这一 i.i.d. 假设的精确含义。

假设数据由一个参数化的条件概率分布生成:

$$y \sim P(y|\mathbf{x}, \boldsymbol{\theta}), \quad (3.1)$$

其中 $\boldsymbol{\theta}$ 为模型参数 (在物理类比中, 对应于系统的“外部参数”)。

独立同分布 (i.i.d.) 假设: 假设全部数据点相互独立地从同一分布中抽取:

$$P(\mathcal{D}|\boldsymbol{\theta}) = \prod_{n=1}^N P(y^{(n)}|\mathbf{x}^{(n)}, \boldsymbol{\theta}). \quad (3.2)$$

这一“乘积”结构在第二章中已经出现过: 回忆 §2.1 中“数格子”的讨论——若一个系统由两个独立子系统组成, 合并后的微观状态数是两部分微观状态数的乘积 ($\Omega = \Omega_1 \Omega_2$), 相应地熵是两部分熵的和 ($S = S_1 + S_2$, 因为取了对数)。此处的逻辑与之完全一致: 若 N 个数据点相互独立产生, 则“观测到整个数据集”这一事件的概率, 就是每个数据点单独发生的概率之乘积; 一旦对其取对数 (下文即将进行), 乘积便化为求和。这并非数学上的巧合, 而是“独立性 $\Rightarrow$ 联合概率相乘 $\Rightarrow$ 对数相加”这一通用规律, 在物理与机器学习中的两次独立应用。

该假设在现实中常常并不严格成立 (例如时间序列数据具有相关性, 恰如伊辛模型中相邻自旋并不独立), 但它极大简化了分析, 是绝大多数基础机器学习模型的默认起点。

■ 思考与验证

在 §2.3 讨论的一维伊辛模型中, 相邻自旋 s_i 与 s_{i+1} 是否独立? 若 $J \neq 0$, 联合概率 $P(s_i, s_{i+1})$ 能否写成 $P(s_i)P(s_{i+1})$ 的乘积形式?

解: 不能——正因为 $J \neq 0$ 引入了关联, 两个自旋的联合分布无法分解为各自边缘分布的乘积, 这正是 §2.3 中专门求解的关联函数 $C(r) = \langle s_i s_{i+r} \rangle$ 不恒为零的原因。在“把每个数据点看作一个自旋、把数据点间的耦合类比为伊辛耦合 J ”这一特定类比之下, i.i.d. 假设对应的正是“假设 $J = 0$ ”——即在这个类比框架里, 各数据点之间不存在相互作用。需要提醒的是, 这仅仅是一个类比, 而不是 i.i.d. 与 $J = 0$ 之间的一般数学等价: i.i.d. 的严格含义是式 (3.2) 中的联合概率可以分解为乘积, 这一性质本身并不依赖于是否存在某个可以类比为“伊辛耦合”的参数。现实数据完全可能在不违反 i.i.d. 假设的意义下仍存在这样那样的结构 (例如输入 $\mathbf{x}^{(n)}$ 之间可以相关, 只要标签的条件分布 $P(y^{(n)}|\mathbf{x}^{(n)}, \boldsymbol{\theta})$ 相互独立即可), 也可能违反 i.i.d. 却找不到任何自然的“ J ”与之对应 (例如分层数据结构)。

把“类比”和“严格等价”区分清楚, 本身正是本书反复强调的“类比不是比喻, 而是需要说清楚适用范围的数学结构”这一原则的体现。

§3.3 最大似然估计 (MLE)

在给出一般定义之前，先通过一个可徒手验证的具体例子，将 MLE 的核心逻辑充分阐明，再处理一般情形。

算例：估计硬币的偏性

设定：一枚硬币正面朝上的概率为某未知常数 $p \in [0, 1]$ ($p = 0.5$ 对应“公平硬币”，但 p 的真实取值预先未知)。独立抛掷 N 次，观测到 k 次正面、 $N - k$ 次反面。问题：根据这些观测， p 最合理的估计值是多少？

这一设定正是 §2.2 中“二能级系统”在机器学习中的对应版本：将“正面”与“反面”视为两个可能的“状态”，每次抛掷是一次独立观测。单次抛掷的概率可统一写为

$$P(x|p) = p^x(1-p)^{1-x}, \quad x = \begin{cases} 1 & \text{正面} \\ 0 & \text{反面} \end{cases} \quad (3.3)$$

该分布称为伯努利分布 (Bernoulli distribution)。代入 $x = 1$ 得 $P = p$ ，代入 $x = 0$ 得 $P = 1 - p$ ，与预期一致。

利用式 (3.2) 中的 i.i.d. 假设，观测到这一整组结果 (k 次正面、 $N - k$ 次反面，具体顺序已知) 的似然函数为

$$\mathcal{L}(p) = \prod_{i=1}^N P(x_i|p) = p^k(1-p)^{N-k}. \quad (3.4)$$

代入具体数值。取 $N = 10$ ，观测到 $k = 7$ 次正面。将若干候选 p 值代入式 (3.4)，比较哪个 p 使这组观测显得“最不令人意外”：

表 3.3: 不同 p 取值下的似然函数 $\mathcal{L}(p) = p^7(1-p)^3$ ($N = 10, k = 7$)

p	$\mathcal{L}(p) = p^7(1-p)^3$
0.1	7.29×10^{-8}
0.3	7.50×10^{-5}
0.5	9.77×10^{-4}
0.7	2.22×10^{-3}
0.9	4.78×10^{-4}

由表 3.3 可见， $p = 0.7$ (即观测到的正面频率 $k/N = 7/10$) 使似然函数取得表中最大值。这并非巧合——下面用微积分严格证明这一点。

解析求解。对似然取对数 (对数似然)：

$$\ell(p) = \ln \mathcal{L}(p) = k \ln p + (N - k) \ln(1 - p).$$

对 p 求导并令其为零：

$$\frac{d\ell}{dp} = \frac{k}{p} - \frac{N - k}{1 - p} = 0.$$

整理：

$$k(1-p) = (N-k)p \implies k - kp = Np - kp \implies k = Np,$$

从而

$$p_{\text{MLE}} = \frac{k}{N}. \quad (3.5)$$

该结果正是最朴素的直觉：用观测到的频率估计概率。在这一最简单的例子中，MLE 将“最大似然”这一听似抽象的方法，还原为人所共知的常识——这也是理解 MLE 的一条有效途径：无论模型多复杂，MLE 本质上都是“频率估计”的推广。

■ 计算说明

取对数不仅能将乘积变为便于求导的求和，还具有重要的数值计算意义。设想 $N = 100$ 次抛掷，即使在最大似然点附近（例如 $p = 0.5$ ），似然函数本身的数值也小至 $0.5^{100} \approx 7.9 \times 10^{-31}$ ——这一数字已逼近计算机浮点数所能表示的下界，继续增大 N 将发生数值下溢（underflow），计算机会将其直接归零，从而无法比较不同 p 之间的优劣。相比之下，对数似然 $100 \ln 0.5 \approx -69.3$ 是一个数值范围正常的量，运算远为稳定。这正是几乎所有实际的机器学习代码都在对数似然（或负对数似然损失）层面进行优化、而非直接操作似然函数本身的原因。这一技巧与 §2.2 中使用 $\ln Z$ 而非 Z 本身提取热力学量，属于同一种“取对数以换取数值稳定性与可加性”的思想。

■ 思考与验证

若这枚硬币被抛掷 $N = 3$ 次，三次均为正面（ $k = 3$ ），则 $p_{\text{MLE}} = 3/3 = 1$ ，即模型断言“这枚硬币绝不可能出现反面”。这一结论是否可信？问题出在哪里？

解：这一问题不宜用公式直接回答，留待 §3.4 讨论——最大后验估计（MAP）正是为解决“小样本下 MLE 容易给出过度自信的极端结论”这一问题而引入的。

一般情形：似然函数

现在将刚才对硬币所做的处理，原封不动地推广到一般的监督学习问题。给定数据集 $\mathcal{D}$ 与参数 θ ，似然函数定义为

$$\mathcal{L}(\theta) = P(\mathcal{D}|\theta) = \prod_{n=1}^N P(y^{(n)}|\mathbf{x}^{(n)}, \theta). \quad (3.6)$$

需要注意的是，此处将数据集 $\mathcal{D}$ 视为固定，将 θ 视为变量。似然函数并非概率密度（对 θ 积分不必等于 1），而是衡量“在给定参数 θ 的条件下，观测到数据集 $\mathcal{D}$ 的可能性”。前述硬币例子中的 $\mathcal{L}(p) = p^k(1-p)^{N-k}$ ，正是这一般公式在 $P(y|\mathbf{x}, \theta)$ 取伯努利分布、参数 $\theta = p$ 时的特例。

最大似然原理

最大似然估计（Maximum Likelihood Estimation, MLE）寻找使似然函数最大的参数：

$$\theta^* = \arg \max_{\theta} \mathcal{L}(\theta). \quad (3.7)$$

直观而言，这一原则选择使“当前观测到的数据最有可能出现”的参数——这与从硬币的似然数值表中“挑出使 $\mathcal{L}(p)$ 最大的 p ”完全是同一件事，只不过此处 θ 一般是高维向量，不能再简单地列表比较，而需依赖微积分（求导）或数值优化（梯度下降）寻找最大点。

对数似然

由于似然函数是乘积形式，取对数将其化为求和：

$$\ell(\theta) = \ln \mathcal{L}(\theta) = \sum_{n=1}^N \ln P(y^{(n)} | \mathbf{x}^{(n)}, \theta). \quad (3.8)$$

由于对数函数单调递增，最大化 $\ell(\theta)$ 等价于最大化 $\mathcal{L}(\theta)$ 。

最大化对数似然等价于最小化负对数似然（Negative Log-Likelihood, NLL）：

$$\mathcal{L}(\theta) = -\ell(\theta) = -\sum_{n=1}^N \ln P(y^{(n)} | \mathbf{x}^{(n)}, \theta). \quad (3.9)$$

这正是机器学习中的“损失函数”。（此处沿用教材惯例，用 $\mathcal{L}$ 同时表示“似然函数”与“损失函数”——读者可通过上下文及是否带负号加以区分，负对数似然才是需要最小化的损失。）本书后续讨论损失函数的章节将会看到，几乎所有常见的损失函数——均方误差、交叉熵——均可通过为 $P(y|\mathbf{x}, \theta)$ 选定具体的分布形式，从这一负对数似然公式推导得到，而非凭空构造。

§3.4 最大后验估计（MAP）

前述“三次抛掷、三次正面、MLE 给出 $p = 1$ ”的例子暴露了一个问题：当数据量很少时，MLE 容易给出过度自信、脱离常识的极端估计。若在抛掷硬币之前，已有理由相信“绝大多数硬币基本公平”这类先验知识，能否将这类先验知识纳入估计过程，使结果更为“稳健”？这正是 MAP 所要解决的问题。

有时我们对参数持有先验知识或偏好。在贝叶斯框架下，引入参数的先验分布 $P(\theta)$ 。

贝叶斯定理的推导。我们想知道“看到数据 $\mathcal{D}$ 之后，参数 θ 的概率分布应如何更新”，即求 $P(\theta|\mathcal{D})$ 。这只需把条件概率的定义（见本章前面的“预备定义”）分别应用给 $(\theta, \mathcal{D})$ 这一对随机量两次：一次以 $\mathcal{D}$ 为条件，一次以 θ 为条件。按定义，

$$P(\theta|\mathcal{D}) = \frac{P(\theta, \mathcal{D})}{P(\mathcal{D})}, \quad P(\mathcal{D}|\theta) = \frac{P(\theta, \mathcal{D})}{P(\theta)}.$$

这两个式子中的联合概率 $P(\theta, \mathcal{D})$ 是同一个量，将第二式改写为 $P(\theta, \mathcal{D}) = P(\mathcal{D}|\theta)P(\theta)$ ，代入第一式，即得贝叶斯定理：

$$P(\theta|\mathcal{D}) = \frac{P(\mathcal{D}|\theta)P(\theta)}{P(\mathcal{D})}. \quad (3.10)$$

式中各项均有明确名称： $P(\theta|\mathcal{D})$ 称为后验分布（posterior，看到数据之后对 θ 的信念）； $P(\mathcal{D}|\theta)$ 正是式 (3.6) 中的似然函数； $P(\theta)$ 称为先验分布（prior，看到数据之前对 θ 的信念）； $P(\mathcal{D})$ 称为证据（evidence），它不依赖于 θ ，只起归一化作用。

■ 同一个符号，在不同的概率对象里换了角色

初学者最容易在这里犯的一个错误，是把 $P(\mathcal{D}|\theta)$ 和 $P(\theta|\mathcal{D})$ 里的 θ 和 $\mathcal{D}$ 当作“地位对等”的两个变量，而没有注意到竖线两边的角色其实换了：

在似然函数 $P(\mathcal{D}|\theta)$ 中， θ 是给定的、固定的参数（把它当作一个已知常数代进去）， $\mathcal{D}$ 才是这个概率分布真正描述的对象——这是“如果参数是 θ ，看到这份数据的可能性有多大”。

在后验分布 $P(\theta|\mathcal{D})$ 中，角色完全反过来： $\mathcal{D}$ 变成了给定的、固定的数据（已经观测到，不再变化）， θ 才是这个概率分布真正描述的对象——这是“看到了这份数据之后，参数取各个值的可能性有多大”。

同一个 θ ，在 $P(\mathcal{D}|\theta)$ 里是背景条件，在 $P(\theta|\mathcal{D})$ 里却变成了随机变量本身。竖线“|”右边永远是被给定、暂时不变的那一方，左边才是概率分布实际描述的那一方——读这类表达式时，先看竖线右边是谁被固定住了，往往比先看左边更容易理清。

最大后验估计 (Maximum A Posteriori, MAP) 寻找使后验概率最大的参数：

$$\theta^* = \arg \max_{\theta} P(\theta|\mathcal{D}). \quad (3.11)$$

将式 (3.10) 代入：

$$\theta^* = \arg \max_{\theta} \frac{P(\mathcal{D}|\theta)P(\theta)}{P(\mathcal{D})}.$$

关于 $\arg \max$ 的一条一般性质：若 $g(\theta) = c \cdot f(\theta)$ ，其中 $c > 0$ 是一个不依赖于 θ 的常数，则 g 与 f 在同一个 θ 处取得最大值——因为 $c > 0$ 时乘以 c 不改变函数各处取值的相对大小关系，即 $f(\theta_1) > f(\theta_2) \Leftrightarrow c f(\theta_1) > c f(\theta_2)$ ，故 $\arg \max_{\theta} g(\theta) = \arg \max_{\theta} f(\theta)$ 。这里 $P(\mathcal{D})$ 不依赖于 θ （它是对全部可能的 θ 积分/求和之后的结果，一个确定的数），取 $c = 1/P(\mathcal{D}) > 0$ ，即可将其从 $\arg \max$ 中拿掉：

$$\theta^* = \arg \max_{\theta} [P(\mathcal{D}|\theta)P(\theta)].$$

取对数（对数函数单调递增，不改变 $\arg \max$ 的位置，这一点在 §3.3 推导对数似然时已经说明）：

$$\theta^* = \arg \max_{\theta} [\ln P(\mathcal{D}|\theta) + \ln P(\theta)],$$

或等价地，最小化

$$\mathcal{L}(\theta) = -\ln P(\mathcal{D}|\theta) - \ln P(\theta). \quad (3.12)$$

物理类比：

- $-\ln P(\mathcal{D}|\theta)$ ：数据项，类似“能量”；
- $-\ln P(\theta)$ ：先验项，类似“外场”。

先验分布 $P(\theta)$ 在机器学习中对应于正则化。

硬币算例：先验对过度自信估计的修正

继续使用硬币的例子，将 MAP 具体计算一遍，直接回答前一小节末尾的疑问。为 p 选取一个称为 **Beta** 分布的先验：

$$P(p) \propto p^{\alpha-1}(1-p)^{\beta-1}. \quad (3.13)$$

■ 预备说明：“ $\propto$ ”记号的含义

式 (3.13) 中的 “ $\propto$ ”（正比于）表示等式右边只写出了依赖于 p 的部分，省略了一个不依赖于 p 的归一化常数 $C(\alpha, \beta)$ ，即完整地写应为 $P(p) = C(\alpha, \beta) p^{\alpha-1}(1-p)^{\beta-1}$ ，其中 $C(\alpha, \beta)$ 由归一化条件 $\int_0^1 P(p) dp = 1$ 唯一确定。这与 §2.2 中配分函数 Z 的作用完全一致： $P(\mathbf{x}) = \frac{1}{Z} e^{-\beta E(\mathbf{x})}$ 中的 $e^{-\beta E(\mathbf{x})}$ 部分依赖于状态 $\mathbf{x}$ ，而 $1/Z$ 正是那个不依赖于 $\mathbf{x}$ 的归一化常数。之所以可以放心地略去这个常数，是因为——正如上文“关于 $\arg \max$ 的一条一般性质”所说——它不影响 $\arg \max$ （或 $\arg \min$ ）的位置：无论 $C(\alpha, \beta)$ 具体是多少，使 $P(p|\mathcal{D})$ 最大的 p 都是同一个。下面的推导将持续利用这一点，直到最后一步才需要（如果需要的话）把归一化常数找回来。

该先验的形状恰好也是 p 的幂次乘积——这并非随意选取，而是因为它与伯努利似然的形式相“匹配”（数学上称为共轭先验），从而后验分布仍属于同一分布族，计算十分简洁。取 $\alpha = \beta$ 时，先验关于 $p = 0.5$ 对称； α, β 越大，先验越强烈地认为 p 应接近 0.5。

后验正比于似然乘以先验：

$$P(p|\mathcal{D}) \propto p^k(1-p)^{N-k} \cdot p^{\alpha-1}(1-p)^{\beta-1} = p^{k+\alpha-1}(1-p)^{N-k+\beta-1}. \quad (3.14)$$

这与此前 MLE 的推导形式完全相同，只是指数上多出了 $\alpha-1$ 与 $\beta-1$ 两个附加量。下面完整重复一遍 §3.3 中“取对数、求导、令其为零”的三个步骤，只是把 $p^k(1-p)^{N-k}$ 换成式 (3.14) 中的 $p^{k+\alpha-1}(1-p)^{N-k+\beta-1}$ 。

第一步：取对数。由于式 (3.14) 中省略的归一化常数不依赖于 p ，取对数后只贡献一个可以忽略的加性常数：

$$\ln P(p|\mathcal{D}) = (k + \alpha - 1) \ln p + (N - k + \beta - 1) \ln(1 - p) + \text{const.}$$

第二步：对 p 求导并令其为零。

$$\frac{d}{dp} \ln P(p|\mathcal{D}) = \frac{k + \alpha - 1}{p} - \frac{N - k + \beta - 1}{1 - p} = 0.$$

第三步：解出 p 。两边同乘 $p(1-p)$ ：

$$(k + \alpha - 1)(1 - p) = (N - k + \beta - 1)p.$$

展开左边：

$$(k + \alpha - 1) - (k + \alpha - 1)p = (N - k + \beta - 1)p.$$

将含 p 的项移到等式右边合并：

$$k + \alpha - 1 = (N - k + \beta - 1)p + (k + \alpha - 1)p = [(N - k + \beta - 1) + (k + \alpha - 1)]p.$$

中括号内合并同类项, $N - k$ 与 k 相消: $(N - k + \beta - 1) + (k + \alpha - 1) = N + \alpha + \beta - 2$, 于是

$$k + \alpha - 1 = (N + \alpha + \beta - 2)p,$$

解得

$$p_{\text{MAP}} = \frac{k + \alpha - 1}{N + \alpha + \beta - 2}. \quad (3.15)$$

一个有启发性的解读是将 α, β 理解为“虚拟观测次数”。观察上式的结构——它与 $p_{\text{MLE}} = k/N$ 几乎相同, 只是分子多加了 $\alpha - 1$ 、分母多加了 $\alpha + \beta - 2$ 。这可理解为: 先验相当于在正式抛掷硬币之前, 已“虚拟地”观测到 $\alpha - 1$ 次正面与 $\beta - 1$ 次反面, 这些虚拟观测与真实数据共同参与“计数”。数据越多, 虚拟观测在总数中所占比例越小, 先验的影响也越弱; 数据越少, 虚拟观测的相对权重越大, 先验对估计结果的牵引也就越明显。

代入具体数值验证这一直觉 (取一组较弱的先验 $\alpha = \beta = 2$, 相当于“虚拟地”各观测到 1 次正面与反面; 再取一组较强的先验 $\alpha = \beta = 5$ 作为对比):

表 3.4: MLE 与 MAP 估计值的比较

数据 (N, k)	$p_{\text{MLE}} = k/N$	$p_{\text{MAP}}(\alpha = \beta = 2)$	$p_{\text{MAP}}(\alpha = \beta = 5)$
$N = 3, k = 3$ (全正面)	1.000	0.800	0.636
$N = 10, k = 7$	0.700	0.667	0.611
$N = 100, k = 70$	0.700	0.696	0.685

表 3.4 体现了两个值得记住的现象:

1. 小样本、极端观测 ($N = 3, k = 3$ 一行): MLE 给出了不合常理的 $p = 1$, 而 MAP 将其拉回至 0.8 (弱先验) 或 0.636 (强先验)——这恰好回答了 §3.3 末尾提出的问题: 先验知识 (“大多数硬币接近公平”) 成功地避免了模型仅凭 3 次观测便得出 “这枚硬币绝不会出现反面” 这一过度自信的结论。
2. 大样本 ($N = 100, k = 70$ 一行): 无论先验强弱, MAP 的结果均已十分接近 MLE 的 0.700——当真实数据足够多时, “虚拟观测” 在总计数中的占比可忽略不计, 先验的影响会被数据 “淹没”。这正是贝叶斯统计中常被引用的一个结论的具体体现: 数据足够多时, 先验的具体选择将不再重要。

■ 思考与验证

表中 $\alpha = \beta = 5$ 的先验, 相较于 $\alpha = \beta = 2$ 的先验, 在相同数据下总是将估计拉得更靠近 0.5。这是否意味着 “先验越强越好”? 若对硬币的偏性其实一无所知, 选取一个很强的先验会带来何种风险?

解: 若先验与事实不符——例如这枚硬币确实存在偏性, 真实的 p 为 0.9——过强的先验会持续将估计 “拉离” 真实值, 即使提供大量数据也难以纠正。先验的强度需要与对先验知识的信心程度相匹配, 这本身是建模过程中需要权衡的选择, 而非 “越强越安全”。

从虚拟计数到 L^2 正则化：另一个常见的先验

Beta 先验是离散概率参数场景下的经典例子；在连续参数（例如线性回归的权重 $\theta \in \mathbb{R}^d$ ）场景下，最常见的先验是高斯分布：

$$P(\theta) \propto \exp\left(-\frac{\lambda}{2}\|\theta\|^2\right). \quad (3.16)$$

完整地写出应为 $P(\theta) = C(\lambda) \exp(-\frac{\lambda}{2}\|\theta\|^2)$ ，其中 $C(\lambda)$ 是与 θ 无关的归一化常数。将其代入一般的 MAP 目标函数 (3.12) 中的 $-\ln P(\theta)$ 一项：

$$\begin{aligned} -\ln P(\theta) &= -\ln\left[C(\lambda) \exp\left(-\frac{\lambda}{2}\|\theta\|^2\right)\right] \\ &= -\ln C(\lambda) - \ln \exp\left(-\frac{\lambda}{2}\|\theta\|^2\right) \quad (\text{利用 } \ln(ab) = \ln a + \ln b) \\ &= \underbrace{-\ln C(\lambda)}_{\text{与 } \theta \text{ 无关的常数}} + \frac{\lambda}{2}\|\theta\|^2 \quad (\text{利用 } \ln e^x = x). \end{aligned}$$

代入式 (3.12)，并按照“常数不影响 $\arg \min$ ”这一原则（与前文“关于 $\arg \max$ ”的性质完全对称，只需把不等号方向反过来即可）将 $-\ln C(\lambda)$ 舍去：

$$\mathcal{L}(\theta) = -\ln P(\mathcal{D}|\theta) + \frac{\lambda}{2}\|\theta\|^2. \quad (3.17)$$

这正是岭回归（Ridge Regression）或权重衰减（Weight Decay）。它与此前 Beta 先验的“虚拟计数”直觉属于同一套逻辑的连续版本：高斯先验将 θ “虚拟地”拉向 $\mathbf{0}$ （因为高斯分布在 $\theta = \mathbf{0}$ 处概率密度最大），拉力的强弱由 λ 控制—— λ 越大，相当于“虚拟证据”越多，模型也就越不敢让参数偏离零太远。这正是正则化防止过拟合的数学本质：以先验知识平衡数据量不足时的过度自信，与此前在硬币例子中观察到的现象完全一致。

■ 小结

最大似然估计（MLE）回答“哪一组参数使观测到的数据显得最不令人意外”，本质上是频率估计的推广；数据量较少时可能给出过度自信的极端结果。最大后验估计（MAP）在 MLE 的基础上引入先验，相当于为数据“掺入”一定量的虚拟先验证据；数据越少，先验的影响越大，数据越多，先验的影响则越会被“淹没”。无论是 Beta 先验还是高斯先验，正则化都可以理解为“虚拟观测”与真实数据共同决定最终估计。

至此，本书已将统计物理中“从能量到概率”的逻辑，与机器学习中“从数据到参数估计”的逻辑分别梳理清楚。下一章，将把这两条逻辑链正式统一起来——读者将会看到，负对数似然损失，正是以另一种形式呈现的能量函数。

习题

基础题

习题 3.1: 另一枚硬币的 MLE 与 MAP

仍是 §3.3 中“抛硬币”的设定：硬币正面朝上的概率为未知常数 $p \in [0, 1]$ 。这一次独立抛掷 $N = 16$ 次，观测到 $k = 11$ 次正面。

- 写出似然函数 $L(p)$ ，并按 §3.3 中的求导步骤，求出 p_{MLE} ；
- 取 $\text{Beta}(\alpha = 3, \beta = 3)$ 先验，按 §3.4 中的公式，求出 p_{MAP} ，并说明它相较于 p_{MLE} 是被拉向了 0.5 还是拉离了 0.5；
- 若观测比例不变，但样本量扩大十倍 ($N = 160, k = 110$)，在同样的先验 $\alpha = \beta = 3$ 下重新计算 p_{MAP} ，并比较它与 $p_{\text{MLE}} = k/N$ 的差距，是变大了还是变小了？
- 结合 (b)(c) 的数值结果，用“虚拟观测次数”这一直觉 (§3.4) 解释：为什么样本量越大，先验对 MAP 估计的影响就越弱？

提示： $p_{\text{MLE}} = k/N$, $p_{\text{MAP}} = \frac{k + \alpha - 1}{N + \alpha + \beta - 2}$ 。

习题 3.2: 高斯分布的最大似然估计

设 $x^{(1)}, \dots, x^{(N)}$ 是从高斯分布 $\mathcal{N}(\mu, \sigma^2)$ 中独立抽取的 N 个样本，均值 μ 与方差 σ^2 均未知。高斯分布的概率密度为

$$P(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right).$$

- 仿照 §3.3 中硬币算例的步骤（先写似然、再取对数、再求导），写出对数似然 $\ell(\mu, \sigma^2)$ ；
- 对 μ 求偏导并令其为零，解出 μ_{MLE} ；
- 对 σ^2 求偏导并令其为零（把 σ^2 当作一个整体变量求导即可，不必拆成对 σ 求导），解出 σ_{MLE}^2 ；
- （思考） σ_{MLE}^2 是用同一组数据先估计出的 μ_{MLE} 代入计算出来的——这会不会让 σ_{MLE}^2 系统性地低估真实方差？（提示：这个直觉是对的， σ_{MLE}^2 是有偏估计量，无偏估计需要把分母 N 换成 $N - 1$ ；有兴趣的话可以取 $N = 2$ 的两个具体数值样本代入两种公式，看看差多少）

提示： $\mu_{\text{MLE}} = \frac{1}{N} \sum_n x^{(n)}$, $\sigma_{\text{MLE}}^2 = \frac{1}{N} \sum_n (x^{(n)} - \mu_{\text{MLE}})^2$ 。

进阶题

■ 记号说明

下面的习题中开始使用 $\mathbb{E}[\cdot]$ 记号表示期望值，这与第二章中物理学惯用的 $\langle \cdot \rangle$ 记号是完全相同的运算（对全部可能取值按概率加权求和或积分），只是机器学习文献更习惯前者。本书后续会视语境交替使用这两种记号。

习题 3.3: Fisher 信息与 Cramér–Rao 界

对于参数化的概率分布 $P(x; \theta)$:

- 定义 Fisher 信息 $I(\theta) = \mathbb{E} \left[\left(\frac{\partial \ln P}{\partial \theta} \right)^2 \right]$;
- 证明 $I(\theta) = -\mathbb{E} \left[\frac{\partial^2 \ln P}{\partial \theta^2} \right]$ （假设可以交换求导与积分）;
- 陈述 Cramér–Rao 不等式：对于参数 θ 的任意无偏估计量 $\hat{\theta}$ ，其方差满足 $\text{Var}(\hat{\theta}) \geq \frac{1}{I(\theta)}$;
- 对于高斯分布 $\mathcal{N}(\mu, \sigma^2)$ ，计算关于 μ 和 σ^2 的 Fisher 信息；
- 对于伯努利分布 $\text{Ber}(p)$ ，计算关于 p 的 Fisher 信息。

习题 3.4: 高斯先验下的 MAP：连续版本的“虚拟计数”

§3.4 中用 Beta 先验处理了硬币偏性 p 这一离散参数的 MAP 估计。本题把同样的逻辑用到连续参数上。设数据 $x^{(1)}, \dots, x^{(N)}$ 独立同分布地服从 $\mathcal{N}(\mu, \sigma^2)$ ，其中噪声方差 σ^2 是已知常数（不需要估计），只有均值 μ 未知。为 μ 选取一个高斯先验

$$P(\mu) \propto \exp \left(-\frac{(\mu - \mu_0)^2}{2\sigma_0^2} \right),$$

其中 μ_0, σ_0^2 是预先设定的先验均值与先验方差—— σ_0^2 越小，先验就越强烈地把 μ 拉向 μ_0 （这与 §3.4 中 α, β 越大、先验越强的作用是一回事）。

- 仿照 §3.4 中硬币算例的步骤（取对数、求导、令其为零），推导 μ_{MAP} ，并证明结果可以写成

$$\mu_{\text{MAP}} = \frac{N\sigma_0^2 \bar{x} + \sigma^2 \mu_0}{N\sigma_0^2 + \sigma^2}, \quad \bar{x} \equiv \frac{1}{N} \sum_{n=1}^N x^{(n)};$$

- 验证 $N \rightarrow \infty$ 时 $\mu_{\text{MAP}} \rightarrow \bar{x}$ （即上一题中的 μ_{MLE} ）;
- 验证 $\sigma_0^2 \rightarrow \infty$ （即先验完全“无信息”）时同样有 $\mu_{\text{MAP}} \rightarrow \bar{x}$;
- 把 μ_{MAP} 改写成加权平均的形式 $\mu_{\text{MAP}} = w\bar{x} + (1-w)\mu_0$ ，求出权重 w ，并用 §3.4 中“虚拟观测次数”的语言解释 w 的含义——这里扮演“虚拟样本量”角色的是哪个量？

挑战题

习题 3.5: 自然梯度下降

对于参数化的分布族 $\{P_\theta(x)\}$:

(a) 定义 Fisher 信息矩阵 $F_{ij}(\theta) = \mathbb{E}_{P_\theta} \left[\frac{\partial \ln P_\theta}{\partial \theta_i} \frac{\partial \ln P_\theta}{\partial \theta_j} \right]$;

(b) 证明对于无穷小的参数变化, KL 散度的二阶近似为

$$D_{KL}(P_\theta \| P_{\theta+d\theta}) \approx \frac{1}{2} \sum_{i,j} F_{ij}(\theta) d\theta_i d\theta_j;$$

(c) 定义自然梯度 $\tilde{\nabla}_\theta \mathcal{L} = F^{-1}(\theta) \nabla_\theta \mathcal{L}$;

(d) 对于高斯分布 $\mathcal{N}(\mu, \sigma^2)$, 计算 Fisher 信息矩阵;

(e) 对于逻辑回归 $P(y=1|x) = \sigma(\theta^T x)$, Fisher 信息矩阵与 Hessian 矩阵有什么关系?

(f) 讨论自然梯度下降相比普通梯度下降的优势: 为什么自然梯度在“参数空间的黎曼几何”下是最陡的方向?

损失函数作为能量函数

*Fair is foul, and foul is fair:
Hover through the fog and filthy air.*

—— 莎士比亚《麦克白》第一幕第一场，
三女巫

学习目标

- 理解损失函数与能量函数之间的数学对应关系——“概率模型即玻尔兹曼分布”这一统一视角；
- 通过线性回归、逻辑回归、Softmax 回归三个具体例子，掌握“选定噪声分布 → 写出似然 → 取负对数似然”这一损失函数推导的标准流程；
- 推导均方误差与交叉熵损失的解析形式，理解正规方程的代数与几何意义；
- 理解温度参数如何统一地控制回归模型对误差的敏感度和分类模型输出的确定性。

■ 本章导览

本章回答的问题：均方误差、交叉熵这些机器学习中“看起来是人为设计”的损失函数，究竟从何而来？是否存在一套统一的方法，把它们系统地推导出来，而不是逐一凭经验发明？

统计物理对应：本章建立全书最核心的一组类比——玻尔兹曼分布 $P(\mathbf{x}) \propto e^{-\beta E(\mathbf{x})}$ 与概率模型 $P(y|\mathbf{x}, \theta) \propto e^{-L(y, \mathbf{x}, \theta)}$ 结构完全相同；“损失函数”就是“能量函数”换了一个名字（这句话具体在什么意义上成立、有什么精确条件，见下文“关于‘能量’一行的重要提醒”，请不要只停留在这一句直觉概括上）。

后续预告：第五章将指出，本章刻意回避的一个问题——配分函数 Z 在一般情形下如何计算——才是训练真实模型时最大的困难；本章 Softmax 中出现的“温度”参数，将在第六、七章反复出现，扮演同一种“控制确定性与灵活性平衡”的角色。

第二章建立了“能量 → 玻尔兹曼分布 → 配分函数”这一物理链条；第三章建立了“数据 → 似然函数 → 参数估计”这一机器学习链条。本章的任务是将这两条链条统一起来：机器学习中那些看似“人为设计”的损失函数（均方误差、交叉熵……），实际上都可以从“为概率模型选定一个具体的分布形式，再取负对数似然”这一统一操作中系统地推导出来，而不需要任

何额外的构造技巧。

§4.1 核心类比

现在可以建立第一个重要的类比。首先明确最基本的一组对应：统计物理中的微观状态 $\mathbf{x}$ （一个自旋构型、一个粒子位置组态），对应机器学习中的特征向量 $\mathbf{x}$ 或模型的隐变量/配置——两者都只是“系统当前所处的具体状态”这一个角色的不同名字，取值可以离散也可以连续。这就是第二章表 2.8 第一行承诺要填的内容；比较以下两个表达式，可以立刻看清接下来几行怎么填：

表 4.1: 统计物理与机器学习的核心类比——为第二章表 2.8 填上前四行

统计物理	机器学习
微观状态 $\mathbf{x}$	特征向量 / 隐变量 $\mathbf{x}$ （或模型配置）
玻尔兹曼分布 $P(\mathbf{x}) \propto e^{-\beta E(\mathbf{x})}$	概率模型 $P(y \mathbf{x}, \boldsymbol{\theta}) \propto e^{-\mathcal{L}(y, \mathbf{x}, \boldsymbol{\theta})}$
能量函数 $E(\mathbf{x})$ （指数内的裸量）	损失 $\mathcal{L}(y, \mathbf{x}, \boldsymbol{\theta})$ （指数内的裸量，与上一行同一个 $\mathcal{L}$ ）
逆温度 $\beta = 1/(k_B T)$	通常取 $\beta = 1$ ，或作为正则化参数
配分函数 $Z = \sum e^{-\beta E}$	归一化常数 $Z(\boldsymbol{\theta}) = \sum_y e^{-\mathcal{L}(y, \mathbf{x}, \boldsymbol{\theta})}$
最小化自由能 $F = E - TS$	最小化损失 $\mathcal{L} = -\ln P$

关于“能量”一行的重要提醒：表中“能量函数 $E(\mathbf{x})$ ”与“损失 $\mathcal{L}$ ”这一行配对的是两者在各自指数中扮演的角色，而不是断言“物理里的裸能量数值上等于机器学习里的完整负对数似然”。物理上 $-\ln P(\mathbf{x}) = \beta E(\mathbf{x}) + \ln Z$ （配分函数 Z 一般不等于 1，真实存在）， $E(\mathbf{x})$ 本身并不等于 $-\ln P(\mathbf{x})$ ；机器学习这一侧之所以能直接写 $\mathcal{L} = -\ln P$ ，是因为 $\mathcal{L}$ 按定义就是把归一化项也吸收了进来的完整负对数似然（下面“关键洞察”之后的备注框会把这一点说清楚）。简言之：“ $E(\mathbf{x})$ ”对应的是 $\mathcal{L}$ 在指数里的角色，而不是 $\mathcal{L}$ 本身一定等于物理上那个不含归一化的裸能量。

对照第二章的种子表：“微观状态”“玻尔兹曼分布”“能量函数”“逆温度”“配分函数”这五行，到这里已经全部正式填上；“自由能”这一行仍待第六章补齐——本表最后一行“最小化自由能 = 最小化损失”目前只是提前给出的形式类比，第六章会用变分自由能与证据下界的严格对应关系，把这一类比放在坚实的基础上。

关键洞察：

$$\boxed{\text{损失函数} \leftrightarrow \text{能量函数}} \quad (4.1)$$

这句话的准确含义是：任何一个概率模型 $P(y|\mathbf{x}, \boldsymbol{\theta})$ ，只要将其写成玻尔兹曼形式

$$P(y|\mathbf{x}, \boldsymbol{\theta}) = \frac{1}{Z(\mathbf{x}, \boldsymbol{\theta})} e^{-\mathcal{L}(y, \mathbf{x}, \boldsymbol{\theta})}, \quad Z(\mathbf{x}, \boldsymbol{\theta}) = \sum_y e^{-\mathcal{L}(y, \mathbf{x}, \boldsymbol{\theta})}, \quad (4.2)$$

那么“最大化似然” (§3.3 的主题) 就自动等价于“最小化 $\mathcal{L}$ ”——而这个 $\mathcal{L}$ 从数学结构上看，和 §2.2 中能量函数 $E(\mathbf{x})$ 扮演的是完全相同的角色：概率越大对应 $\mathcal{L}$ 越小，概率越小对应 $\mathcal{L}$ 越大。反过来说，这也意味着任何一个能量函数都自动定义了一个概率模型及与之配套的损失

函数——这正是接下来三节要具体演示的：给定一个“物理系统”（即噪声的具体分布形式），损失函数会被这个分布唯一地推导出来，而非工程师凭经验“发明”出来。

■ 记号提醒：“损失 $\mathcal{L}$ ”与“能量 E ”并非永远同一个对象

式(4.2)中的 $\mathcal{L}$ 是完整的负对数似然 $\mathcal{L} := -\ln P$ ——按此定义， $Z(\mathbf{x}, \boldsymbol{\theta}) = \sum_y e^{-\mathcal{L}(y, \mathbf{x}, \boldsymbol{\theta})} = \sum_y P(y|\mathbf{x}, \boldsymbol{\theta}) \equiv 1$ 对任意 $\boldsymbol{\theta}$ 恒成立（这是概率归一化的直接结果，不是需要额外验证的假设），所以“最大化似然 $\Leftrightarrow$ 最小化 $\mathcal{L}$ ”是一个不依赖于任何条件的重言式。

但从 §4.4 开始，还会出现另一个记号——“能量” E ，它指的是模型打分的裸值（例如 Softmax 中的 $E_k = -\boldsymbol{\theta}_k^T \mathbf{x}$ ），不包含归一化项 $\ln Z$ 。一般地 $\mathcal{L} = E + \ln Z$ ，只有当 $\ln Z$ 不依赖于 $\boldsymbol{\theta}$ （例如线性回归中噪声方差 σ 是固定超参数、不参与优化）时， E 和 $\mathcal{L}$ 才会相差一个与 $\boldsymbol{\theta}$ 无关的常数，此时“最小化 E ”与“最小化 $\mathcal{L}$ ”才是等价的优化问题；一旦 Z （如 Softmax 中）显式依赖 $\boldsymbol{\theta}$ ， E 和 $\mathcal{L}$ 就是两个不同的量，不能互相替代。本表最后一行“损失函数 $\Leftrightarrow$ 能量函数”这一提法，指的始终是完整的 $\mathcal{L}$ ，请留意后文在具体例子中出现的“能量” E 是否还额外带有 $\ln Z$ 项。

■ 思考与验证

根据表 4.1 中的对应关系：如果模型对某个样本给出的损失 $\mathcal{L}(y, \mathbf{x}, \boldsymbol{\theta})$ 非常大，这个样本在模型看来是“极不可能发生”还是“极有可能发生”？这与 §2.2 中“能量很高的微观状态，玻尔兹曼概率是大还是小”是否为同一个问题？

解：由 $P \propto e^{-\mathcal{L}}$ 可知， $\mathcal{L}$ 越大， $e^{-\mathcal{L}}$ 越接近 0，概率越小；损失大 $\Leftrightarrow$ 模型认为该样本“极不可能发生”——这与能量高的状态玻尔兹曼概率低，是完全同一个数学结构在两个领域中的重复出现。

下面通过三个具体例子，将这套“从分布到损失函数”的推导流程完整地走一遍。

§4.2 例子一：线性回归

模型设定

假设真实关系为

$$y = \boldsymbol{\theta}^T \mathbf{x} + \epsilon,$$

其中 $\epsilon \sim \mathcal{N}(0, \sigma^2)$ 是高斯噪声（符号“ $\sim$ ”读作“服从于”： $\epsilon \sim \mathcal{N}(0, \sigma^2)$ 表示 ϵ 是一个随机变量，其取值按均值为 0、方差为 σ^2 的正态分布抽取——这与“ $\epsilon = \mathcal{N}(0, \sigma^2)$ ”不同， ϵ 不是等于某个分布，而是从这个分布中采样得到）。这意味着

$$y | \mathbf{x}, \boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\theta}^T \mathbf{x}, \sigma^2),$$

概率密度为¹

$$P(y|\mathbf{x}, \boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \boldsymbol{\theta}^T \mathbf{x})^2}{2\sigma^2}\right). \quad (4.3)$$

负对数似然的推导

对数似然为（利用 $\ln(ab) = \ln a + \ln b$ 与 $\ln e^x = x$ ，把 $\ln$ 作用到概率密度 (4.3) 的乘积结构上）

$$\begin{aligned} \ln P(y|\mathbf{x}, \boldsymbol{\theta}) &= \ln \frac{1}{\sqrt{2\pi\sigma^2}} + \ln \exp\left(-\frac{(y - \boldsymbol{\theta}^T \mathbf{x})^2}{2\sigma^2}\right) \\ &= -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(y - \boldsymbol{\theta}^T \mathbf{x})^2}{2\sigma^2}. \end{aligned}$$

对于整个数据集：

$$\begin{aligned} \ell(\boldsymbol{\theta}) &= \sum_{n=1}^N \ln P(y^{(n)}|\mathbf{x}^{(n)}, \boldsymbol{\theta}) \\ &= -\frac{1}{2\sigma^2} \sum_{n=1}^N (y^{(n)} - \boldsymbol{\theta}^T \mathbf{x}^{(n)})^2 - \frac{N}{2} \ln(2\pi\sigma^2). \end{aligned}$$

负对数似然（损失函数）为

$$\mathcal{L}(\boldsymbol{\theta}) = -\ell(\boldsymbol{\theta}) = \frac{1}{2\sigma^2} \sum_{n=1}^N (y^{(n)} - \boldsymbol{\theta}^T \mathbf{x}^{(n)})^2 + \text{const.}$$

忽略常数项和常系数，得到均方误差（Mean Squared Error, MSE）：

$$\boxed{\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{2} \sum_{n=1}^N (y^{(n)} - \boldsymbol{\theta}^T \mathbf{x}^{(n)})^2.} \quad (4.4)$$

这一推导中最值得强调的一点是：均方误差并非“设计”出来的损失函数，而是从“假设噪声服从高斯分布”这一物理假设出发，经由负对数似然自动推导得到的。若噪声服从其他分布（如后文两个例子），推导出的损失函数也会完全不同——损失函数的具体形式，实质上是关于“数据如何被噪声污染”这一假设的直接反映。

物理解释

将 MSE 看作能量函数：

$$E(\boldsymbol{\theta}) = \frac{1}{2} \sum_{n=1}^N (y^{(n)} - \boldsymbol{\theta}^T \mathbf{x}^{(n)})^2.$$

- 每个预测误差 $(y^{(n)} - \boldsymbol{\theta}^T \mathbf{x}^{(n)})^2$ 类似于一个“弹簧”的势能；
- 最小化能量对应于找到全部“弹簧”的平衡位置；

¹“ $y|\mathbf{x}, \boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\theta}^T \mathbf{x}, \sigma^2)$ ”这一行只宣告 y （在 $\mathbf{x}, \boldsymbol{\theta}$ 给定的条件下）属于哪一族分布、参数是什么，并不直接给出可以拿来计算的公式； $P(y|\mathbf{x}, \boldsymbol{\theta})$ 则是这句宣告对应的具体函数——把 y 代入后能算出一个数值（概率密度）。两者说的是同一件事：前者简洁，后者是接下来取对数、求导所需要的显式公式，这也是为什么这两行紧挨着出现。

- 噪声标准差 σ 类似于“温度”： σ 大 $\rightarrow$ 系统对误差不敏感（高温，允许大涨落）； σ 小 $\rightarrow$ 系统对误差敏感（低温，要求精确拟合）。

将“ σ 类似温度”这一说法代入具体数值加以验证：设某样本的残差为 $y - \theta^T \mathbf{x} = 5$ （万元），分别在 $\sigma = 2$ （低温，模型“苛刻”）与 $\sigma = 10$ （高温，模型“宽容”）下计算该残差对应的概率密度：

表 4.2: 不同 σ 下残差为 5 万元时对应的概率密度

σ	残差为 5 时的概率密度 $P(y \mathbf{x}, \theta)$
2（低温）	0.0088
10（高温）	0.0352

同样是“5 万元的误差”，在“低温”（要求精确）模型看来相当不可能发生（概率密度很小），而在“高温”（宽容）模型看来则稀松平常（概率密度大 4 倍）——这正是 §2.2 中“温度控制系统对能量高低的敏感程度”这一规律，原封不动地体现在回归问题中。

算例：拟合房价数据

现在，将表 3.1 中的房价数据真正拟合一遍，完整地走一遍式 (4.5) 给出的正规方程 $\theta^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 。取模型 $\hat{y} = \theta_0 + \theta_1 x$ (θ_0 为截距项，相当于将 $\mathbf{x}$ 增广一维恒为 1 的分量)。

第一步：写出设计矩阵与标签向量。把每个样本的特征增广为 $(1, x^{(n)})$ (1 对应截距项)，得到

$$\mathbf{X} = \begin{pmatrix} 1 & 50 \\ 1 & 70 \\ 1 & 90 \\ 1 & 110 \\ 1 & 130 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 150 \\ 205 \\ 260 \\ 310 \\ 365 \end{pmatrix}.$$

第二步：计算 $\mathbf{X}^T \mathbf{X}$ 。按矩阵乘法逐项算出 ($N = 5$):

$$(\mathbf{X}^T \mathbf{X})_{11} = \sum_n 1 \cdot 1 = 5, \quad (\mathbf{X}^T \mathbf{X})_{12} = (\mathbf{X}^T \mathbf{X})_{21} = \sum_n 1 \cdot x^{(n)} = \sum_n x^{(n)},$$

$$(\mathbf{X}^T \mathbf{X})_{22} = \sum_n (x^{(n)})^2.$$

代入表中数据， $\sum_n x^{(n)} = 50 + 70 + 90 + 110 + 130 = 450$ ， $\sum_n (x^{(n)})^2 = 50^2 + 70^2 + 90^2 + 110^2 + 130^2 = 2500 + 4900 + 8100 + 12100 + 16900 = 44500$ ，于是

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 5 & 450 \\ 450 & 44500 \end{pmatrix}.$$

第三步：计算 $\mathbf{X}^T \mathbf{y}$ 。完全类似地，

$$(\mathbf{X}^T \mathbf{y})_1 = \sum_n y^{(n)}, \quad (\mathbf{X}^T \mathbf{y})_2 = \sum_n x^{(n)} y^{(n)}.$$

$\sum_n y^{(n)} = 150 + 205 + 260 + 310 + 365 = 1290$; $\sum_n x^{(n)} y^{(n)} = 50 \times 150 + 70 \times 205 + 90 \times 260 + 110 \times 310 + 130 \times 365 = 7500 + 14350 + 23400 + 34100 + 47450 = 126800$, 于是

$$\mathbf{X}^T \mathbf{y} = \begin{pmatrix} 1290 \\ 126800 \end{pmatrix}.$$

第四步: 对 2×2 矩阵 $\mathbf{X}^T \mathbf{X}$ 求逆。利用 2×2 矩阵求逆公式 $\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$, 先算行列式:

$$\det(\mathbf{X}^T \mathbf{X}) = 5 \times 44500 - 450 \times 450 = 222500 - 202500 = 20000,$$

故

$$(\mathbf{X}^T \mathbf{X})^{-1} = \frac{1}{20000} \begin{pmatrix} 44500 & -450 \\ -450 & 5 \end{pmatrix}.$$

第五步: 代入 $\boldsymbol{\theta}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 。

$$\begin{aligned} \theta_0^* &= \frac{1}{20000} (44500 \times 1290 - 450 \times 126800) = \frac{57,405,000 - 57,060,000}{20000} = \frac{345,000}{20000} = 17.25, \\ \theta_1^* &= \frac{1}{20000} (-450 \times 1290 + 5 \times 126800) = \frac{-580,500 + 634,000}{20000} = \frac{53,500}{20000} = 2.675. \end{aligned}$$

于是解得

$$\theta_0^* = 17.25, \quad \theta_1^* = 2.675.$$

即模型认为: 面积每增加 1 m^2 , 价格大约上涨 2.675 万元, 此外还有一个约 17.25 万元的固定基础价。将这组参数代回, 比较预测值与真实值:

表 4.3: 房价数据的线性回归拟合结果

样本 n	真实价格 $y^{(n)}$	预测价格 $\hat{y}^{(n)} = \theta_0^* + \theta_1^* x^{(n)}$	残差
1	150	151.0	-1.0
2	205	204.5	+0.5
3	260	258.0	+2.0
4	310	311.5	-1.5
5	365	365.0	0.0

对应的“能量”(MSE 损失, 未除以 N) 为 $E(\boldsymbol{\theta}^*) = \frac{1}{2} \sum (\text{残差})^2 = 3.75$ ——这是所有可能的 (θ_0, θ_1) 中能量最低的一组。作为对比, 任取一组“看似合理”的参数 $\theta_0 = 0, \theta_1 = 2.5$ (即简单假设“价格是面积的 2.5 倍, 没有基础价”), 代入得到的预测残差为 25, 30, 35, 35, 40, 对应能量 $E = 2787.5$ ——比最优解的能量整整大了 700 多倍。这具体地展示了“最小化能量”这一操作的实质: 在所有描述数据的方式中, 挑出使总体“违和感”(残差平方和) 最小的那一种。

■ 思考与验证

若将噪声标准差从“低温” $\sigma = 2$ 换成“高温” $\sigma = 10$ ， θ_0^*, θ_1^* 的最优解是否会发生变化？
解：不会。观察 $\mathcal{L}(\theta) = \frac{1}{2\sigma^2} \sum (y - \theta^T \mathbf{x})^2 + \text{const}$ ， σ 只是一个整体缩放常数，并不影响“哪个 θ 能使求和项最小”这一问题的答案。 σ 只影响损失曲面的陡峭程度（进而影响优化的数值行为与给出的置信区间），并不影响最优点本身的位置——这一点在后续讨论优化算法时将会用到。

解析解

在求导之前，先建立一条会被反复用到的向量微积分法则（本节及§4.3逻辑回归的梯度推导都会用到）。

■ 预备法则： $\partial(\theta^T \mathbf{x}) / \partial \theta = \mathbf{x}$

把 $\theta^T \mathbf{x} = \sum_{i=1}^d \theta_i x_i$ 看作 $\theta = (\theta_1, \dots, \theta_d)$ 的多元函数，对第 j 个分量求偏导：

$$\frac{\partial}{\partial \theta_j} \sum_{i=1}^d \theta_i x_i = x_j$$

（因为求和式中只有 $i = j$ 那一项含 θ_j ，其余项对 θ_j 求导为零）。把 d 个分量 $j = 1, \dots, d$ 的结果排成向量，即得

$$\frac{\partial(\theta^T \mathbf{x})}{\partial \theta} = \mathbf{x}.$$

对 θ 求导并令其为零。利用上述法则和复合函数求导（链式法则）：

$$\frac{\partial}{\partial \theta} (y^{(n)} - \theta^T \mathbf{x}^{(n)})^2 = 2(y^{(n)} - \theta^T \mathbf{x}^{(n)}) \cdot \frac{\partial}{\partial \theta} (y^{(n)} - \theta^T \mathbf{x}^{(n)}) = 2(y^{(n)} - \theta^T \mathbf{x}^{(n)}) \cdot (-\mathbf{x}^{(n)}),$$

对式(4.4)中 $\mathcal{L} = \frac{1}{2} \sum_n (\dots)^2$ 求和并利用上式（前面的 $\frac{1}{2}$ 恰好抵消求导带来的因子2）：

$$\frac{\partial \mathcal{L}}{\partial \theta} = - \sum_{n=1}^N (y^{(n)} - \theta^T \mathbf{x}^{(n)}) \mathbf{x}^{(n)} = 0.$$

整理（把求和拆成两部分并移项）：

$$\sum_{n=1}^N y^{(n)} \mathbf{x}^{(n)} = \sum_{n=1}^N (\theta^T \mathbf{x}^{(n)}) \mathbf{x}^{(n)}.$$

右边每一项 $(\theta^T \mathbf{x}^{(n)}) \mathbf{x}^{(n)}$ 中， $\theta^T \mathbf{x}^{(n)} = (\mathbf{x}^{(n)})^T \theta$ 是一个标量，标量与向量相乘可交换次序：

$$(\theta^T \mathbf{x}^{(n)}) \mathbf{x}^{(n)} = \mathbf{x}^{(n)} [(\mathbf{x}^{(n)})^T \theta] = [\mathbf{x}^{(n)} (\mathbf{x}^{(n)})^T] \theta,$$

其中最后一步用到了矩阵乘法的结合律（ $\mathbf{x}^{(n)}$ 是 $d \times 1$ 列向量， $(\mathbf{x}^{(n)})^T$ 是 $1 \times d$ 行向量， $\mathbf{x}^{(n)} (\mathbf{x}^{(n)})^T$ 是 $d \times d$ 矩阵，与 θ 相乘后仍是 $d \times 1$ 列向量，维度自洽）。于是

$$\sum_{n=1}^N y^{(n)} \mathbf{x}^{(n)} = \left[\sum_{n=1}^N \mathbf{x}^{(n)} (\mathbf{x}^{(n)})^T \right] \theta.$$

定义设计矩阵 $\mathbf{X} = [\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}]^T \in \mathbb{R}^{N \times d}$ (第 n 行是 $(\mathbf{x}^{(n)})^T$) 与标签向量 $\mathbf{y} = [y^{(1)}, \dots, y^{(N)}]^T \in \mathbb{R}^N$ 。按矩阵乘法定义逐项核对: $(\mathbf{X}^T \mathbf{X})_{ij} = \sum_n X_{ni} X_{nj} = \sum_n (\mathbf{x}^{(n)})_i (\mathbf{x}^{(n)})_j$, 恰好是 $\sum_n \mathbf{x}^{(n)} (\mathbf{x}^{(n)})^T$ 的第 (i, j) 个元素, 故 $\mathbf{X}^T \mathbf{X} = \sum_n \mathbf{x}^{(n)} (\mathbf{x}^{(n)})^T$; 同理 $(\mathbf{X}^T \mathbf{y})_i = \sum_n X_{ni} y^{(n)} = \sum_n (\mathbf{x}^{(n)})_i y^{(n)}$, 即 $\mathbf{X}^T \mathbf{y} = \sum_n y^{(n)} \mathbf{x}^{(n)}$ 。上式于是可写为

$$\mathbf{X}^T \mathbf{y} = \mathbf{X}^T \mathbf{X} \boldsymbol{\theta}.$$

若 $\mathbf{X}^T \mathbf{X}$ 可逆, 两边左乘 $(\mathbf{X}^T \mathbf{X})^{-1}$, 解为

$$\boxed{\boldsymbol{\theta}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.} \quad (4.5)$$

这是著名的正规方程 (normal equation); 前文手算的房价例子 (表 4.3), 正是这一公式在 $d = 2$ (含截距)、 $N = 5$ 时的具体实例。

几何解释

在 N 维空间中, $\mathbf{y}$ 是一个向量, $\mathbf{X}\boldsymbol{\theta}$ 张成一个 d 维子空间 (列空间)。最优的 $\boldsymbol{\theta}^*$ 使得 $\mathbf{X}\boldsymbol{\theta}^*$ 恰为 $\mathbf{y}$ 在该子空间上的正交投影。残差向量 $\mathbf{y} - \mathbf{X}\boldsymbol{\theta}^*$ 垂直于列空间, 即

$$\mathbf{X}^T (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}^*) = 0.$$

把左边按分配律展开, $\mathbf{X}^T \mathbf{y} - \mathbf{X}^T \mathbf{X} \boldsymbol{\theta}^* = 0$, 即 $\mathbf{X}^T \mathbf{y} = \mathbf{X}^T \mathbf{X} \boldsymbol{\theta}^*$, 这正是式 (4.5) 给出的正规方程——“最优解使残差与列空间正交”和“最优解使损失函数梯度为零”原来是同一件事的两种说法。

§4.3 例子二：逻辑回归

模型设定

对于二分类问题, $y \in \{0, 1\}$, 建模为

$$P(y = 1 | \mathbf{x}, \boldsymbol{\theta}) = \sigma(\boldsymbol{\theta}^T \mathbf{x}), \quad (4.6)$$

其中 $\sigma(z) = \frac{1}{1 + e^{-z}}$ 是 **sigmoid** 函数 (或称逻辑函数)。

Sigmoid 函数的性质

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}.$$

性质:

1. 值域: $\sigma(z) \in (0, 1)$, 适合表示概率。
2. 对称性: $\sigma(-z) = 1 - \sigma(z)$ 。

证明: 分别将 $\sigma(-z)$ 与 $1 - \sigma(z)$ 化简到同一形式。先看 $\sigma(-z)$, 把定义式中的 z 换成 $-z$, 再把分子分母同乘 e^{-z} :

$$\sigma(-z) = \frac{1}{1 + e^z} = \frac{1}{1 + e^z} \cdot \frac{e^{-z}}{e^{-z}} = \frac{e^{-z}}{e^{-z} + e^{-z}e^z} = \frac{e^{-z}}{e^{-z} + 1},$$

这里用到了 $e^{-z}e^z = 1$ 。再看 $1 - \sigma(z)$ ，通分即可：

$$1 - \sigma(z) = 1 - \frac{1}{1 + e^{-z}} = \frac{(1 + e^{-z}) - 1}{1 + e^{-z}} = \frac{e^{-z}}{1 + e^{-z}}.$$

两者化简后是同一个表达式 $\frac{e^{-z}}{1 + e^{-z}}$ ，故

$$\sigma(-z) = \frac{e^{-z}}{1 + e^{-z}} = 1 - \sigma(z). \quad \blacksquare$$

3. 导数： $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ 。

证明：把 $\sigma(z) = (1 + e^{-z})^{-1}$ 看作复合函数，用幂函数求导法则与链式法则：

$$\begin{aligned} \sigma'(z) &= \frac{d}{dz} (1 + e^{-z})^{-1} = -(1 + e^{-z})^{-2} \cdot \frac{d}{dz} (1 + e^{-z}) \quad (\text{幂函数求导 } (u^{-1})' = -u^{-2}u', u = 1 + e^{-z}) \\ &= -(1 + e^{-z})^{-2} \cdot (-e^{-z}) \quad (\text{因 } \frac{d}{dz} e^{-z} = -e^{-z}) \\ &= \frac{e^{-z}}{(1 + e^{-z})^2} = \frac{1}{1 + e^{-z}} \cdot \frac{e^{-z}}{1 + e^{-z}}. \end{aligned}$$

上式第一个因子就是 $\sigma(z)$ ；第二个因子 $\frac{e^{-z}}{1 + e^{-z}}$ 正是上一条性质证明中已经算出的 $1 - \sigma(z)$ ，故

$$\sigma'(z) = \sigma(z) \cdot (1 - \sigma(z)). \quad \blacksquare$$

4. 极限行为： $z \rightarrow +\infty$ 时 $\sigma(z) \rightarrow 1$ ； $z \rightarrow -\infty$ 时 $\sigma(z) \rightarrow 0$ ； $z = 0$ 时 $\sigma(0) = 1/2$ 。

算例：代入具体数值

上述性质较为抽象，下面直接代入一组具体的 z 值，将 sigmoid 函数“S 形曲线”及其导数的形状一并呈现：

表 4.4: Sigmoid 函数及其导数的数值

z	-4	-2	-1	0	1	2	4
$\sigma(z)$	0.018	0.119	0.269	0.500	0.731	0.881	0.982
$\sigma'(z) = \sigma(1 - \sigma)$	0.018	0.105	0.197	0.250	0.197	0.105	0.018

两个现象值得注意：其一， $\sigma(z)$ 在 $z = 0$ 附近变化最快（这是“决策边界”最敏感的区域），远离 $z = 0$ 后迅速趋于平坦，逼近 0 或 1；其二，导数 $\sigma'(z)$ 恰好在 $z = 0$ 处取得最大值 0.25，并向两侧对称衰减——这一“钟形”导数曲线，正是后续讨论神经网络训练时会反复遇到的“梯度消失”现象的源头：当 $|z|$ 很大时， $\sigma'(z)$ 几乎为零，梯度下降几乎无法学到任何信息。

完整的概率模型

$$P(y|\mathbf{x}, \boldsymbol{\theta}) = \sigma(\boldsymbol{\theta}^T \mathbf{x})^y [1 - \sigma(\boldsymbol{\theta}^T \mathbf{x})]^{1-y}. \quad (4.7)$$

该表达式将 $y = 0$ 与 $y = 1$ 两种情形统一起来：当 $y = 1$ 时， $P(y = 1|\mathbf{x}, \boldsymbol{\theta}) = \sigma(\boldsymbol{\theta}^T \mathbf{x})$ ；当 $y = 0$ 时， $P(y = 0|\mathbf{x}, \boldsymbol{\theta}) = 1 - \sigma(\boldsymbol{\theta}^T \mathbf{x})$ 。

这正是 §3.3 中伯努利分布 $P(x|p) = p^x(1-p)^{1-x}$ (式 (3.3)) 的直接推广——区别在于：那里的“硬币偏性” p 是一个固定常数，此处的“偏性” $\sigma(\boldsymbol{\theta}^T \mathbf{x})$ 则依赖于输入特征 $\mathbf{x}$ ，会随 $\mathbf{x}$ 变化而变化。逻辑回归本质上就是“偏性由特征决定”的伯努利模型。

负对数似然的推导

取对数：

$$\ln P(y|\mathbf{x}, \boldsymbol{\theta}) = y \ln \sigma(\boldsymbol{\theta}^T \mathbf{x}) + (1 - y) \ln[1 - \sigma(\boldsymbol{\theta}^T \mathbf{x})].$$

利用 sigmoid 的性质：

$$\ln \sigma(z) = \ln \frac{1}{1 + e^{-z}} = -\ln(1 + e^{-z}), \quad \ln[1 - \sigma(z)] = \ln \frac{e^{-z}}{1 + e^{-z}} = -z - \ln(1 + e^{-z}).$$

代入并逐步整理：

$$\begin{aligned} \ln P(y|\mathbf{x}, \boldsymbol{\theta}) &= -y \ln(1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}) + (1 - y) [-\boldsymbol{\theta}^T \mathbf{x} - \ln(1 + e^{-\boldsymbol{\theta}^T \mathbf{x}})] \\ &= -y \ln(1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}) - (1 - y) \boldsymbol{\theta}^T \mathbf{x} - (1 - y) \ln(1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}) \\ &= -(1 - y) \boldsymbol{\theta}^T \mathbf{x} - \ln(1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}) \\ &= y \boldsymbol{\theta}^T \mathbf{x} - \boldsymbol{\theta}^T \mathbf{x} - \ln(1 + e^{-\boldsymbol{\theta}^T \mathbf{x}}). \end{aligned}$$

利用恒等式 $\ln(1 + e^{-z}) = \ln(e^z + 1) - z$ (证明： $1 + e^{-z} = e^{-z}(e^z + 1)$)，两边取对数， $\ln(1 + e^{-z}) = \ln e^{-z} + \ln(e^z + 1) = -z + \ln(e^z + 1)$ ，即得该恒等式)：

$$\ln P(y|\mathbf{x}, \boldsymbol{\theta}) = y \boldsymbol{\theta}^T \mathbf{x} - \ln(1 + e^{\boldsymbol{\theta}^T \mathbf{x}}).$$

因此，单个样本的负对数似然（交叉熵损失）为

$$\ell(y, \mathbf{x}, \boldsymbol{\theta}) = -\ln P(y|\mathbf{x}, \boldsymbol{\theta}) = -y \boldsymbol{\theta}^T \mathbf{x} + \ln(1 + e^{\boldsymbol{\theta}^T \mathbf{x}}).$$

对整个数据集：

$$\mathcal{L}(\boldsymbol{\theta}) = \sum_{n=1}^N \left[-y^{(n)} \boldsymbol{\theta}^T \mathbf{x}^{(n)} + \ln(1 + e^{\boldsymbol{\theta}^T \mathbf{x}^{(n)}}) \right]. \quad (4.8)$$

这被称为交叉熵损失（cross-entropy loss）或对数损失（log loss）。

物理解释

定义“能量”

$$E^{(n)}(\boldsymbol{\theta}) = -y^{(n)} \boldsymbol{\theta}^T \mathbf{x}^{(n)} + \ln(1 + e^{\boldsymbol{\theta}^T \mathbf{x}^{(n)}}).$$

第一项 $-y^{(n)} \boldsymbol{\theta}^T \mathbf{x}^{(n)}$ ：若 $y^{(n)} = 1$ 且 $\boldsymbol{\theta}^T \mathbf{x}^{(n)}$ 较大（强正预测），能量低（好）；若 $y^{(n)} = 1$ 但 $\boldsymbol{\theta}^T \mathbf{x}^{(n)}$ 较小，能量高（差）。第二项 $\ln(1 + e^{\boldsymbol{\theta}^T \mathbf{x}^{(n)}})$ 的作用类似于“配分函数”，保证概率的归一化。

梯度计算

计算梯度（用于优化）。对式 (4.8) 中的两项分别求导：第一项 $-y^{(n)}\theta^T \mathbf{x}^{(n)}$ 利用“预备法则” $\partial(\theta^T \mathbf{x})/\partial \theta = \mathbf{x}$ (§4.2) 直接得到 $-y^{(n)}\mathbf{x}^{(n)}$ ；第二项 $\ln(1 + e^{\theta^T \mathbf{x}^{(n)}})$ 是复合函数，需要链式法则：把 $u = 1 + e^{\theta^T \mathbf{x}^{(n)}}$ 看作中间变量，

$$\frac{\partial}{\partial \theta} \ln(1 + e^{\theta^T \mathbf{x}^{(n)}}) = \frac{1}{1 + e^{\theta^T \mathbf{x}^{(n)}}} \cdot \frac{\partial}{\partial \theta} (1 + e^{\theta^T \mathbf{x}^{(n)}}) = \frac{1}{1 + e^{\theta^T \mathbf{x}^{(n)}}} \cdot e^{\theta^T \mathbf{x}^{(n)}} \cdot \mathbf{x}^{(n)},$$

这里最后一步再次用到了预备法则 ($\partial e^{\theta^T \mathbf{x}}/\partial \theta = e^{\theta^T \mathbf{x}} \cdot \partial(\theta^T \mathbf{x})/\partial \theta = e^{\theta^T \mathbf{x}} \mathbf{x}$)。两项相加：

$$\frac{\partial \mathcal{L}}{\partial \theta} = \sum_{n=1}^N \left[-y^{(n)}\mathbf{x}^{(n)} + \frac{e^{\theta^T \mathbf{x}^{(n)}}}{1 + e^{\theta^T \mathbf{x}^{(n)}}} \mathbf{x}^{(n)} \right].$$

注意到 $\frac{e^{\theta^T \mathbf{x}}}{1 + e^{\theta^T \mathbf{x}}}$ 正是 $\sigma(\theta^T \mathbf{x})$ ：把分子分母同除以 $e^{\theta^T \mathbf{x}}$,

$$\frac{e^{\theta^T \mathbf{x}}}{1 + e^{\theta^T \mathbf{x}}} = \frac{1}{e^{-\theta^T \mathbf{x}} + 1} = \sigma(\theta^T \mathbf{x}),$$

代入即得

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \theta} &= \sum_{n=1}^N [\sigma(\theta^T \mathbf{x}^{(n)}) - y^{(n)}] \mathbf{x}^{(n)} \\ &= \sum_{n=1}^N [\hat{y}^{(n)} - y^{(n)}] \mathbf{x}^{(n)}, \end{aligned}$$

其中 $\hat{y}^{(n)} = \sigma(\theta^T \mathbf{x}^{(n)})$ 为预测概率。

这是一个简洁的结果：梯度恰为“预测误差乘以输入”，这一形式与线性回归的梯度完全相同，尽管两者的损失函数并不相同。

算例：一步梯度下降

用一个最简单的单特征、单样本例子，将“预测误差乘以输入”这一梯度公式完整地计算一遍。设特征 $x = 2$ （标量），当前参数 $\theta = 0.5$ ，真实标签 $y = 1$ 。

第一步：计算当前预测。

$$z = \theta x = 0.5 \times 2 = 1.0, \quad \hat{y} = \sigma(z) = \sigma(1.0) = 0.731.$$

模型目前认为“ $y = 1$ ”的概率为 0.731，而真实标签确为 1——方向正确，但把握尚不充分。

第二步：计算梯度。

$$\frac{\partial \mathcal{L}}{\partial \theta} = (\hat{y} - y)x = (0.731 - 1) \times 2 = -0.538.$$

梯度为负，意味着：为减小损失（使预测更接近真实值 1）， θ 应当增大（因为梯度下降是“减去”梯度乘以学习率）。

第三步：以学习率 0.1 更新一步。

$$\theta_{\text{new}} = \theta - 0.1 \times (-0.538) = 0.5 + 0.054 = 0.554.$$

第四步：验证效果。用新的 θ 重新计算预测： $z_{\text{new}} = 0.554 \times 2 = 1.108$, $\hat{y}_{\text{new}} = \sigma(1.108) = 0.752$ 。预测概率从 0.731 提高到了 0.752，确实朝真实标签 $y = 1$ 的方向移动——这一步手算，正是每一次神经网络训练迭代中都在发生的事情，只不过实际训练中 θ 是成千上万维的向量，需要借助计算机而非纸笔完成。

■ 思考与验证

回到 §3.1 表 3.2 中垃圾邮件分类的例子。若模型算出某封邮件的 $\theta^T \mathbf{x} = 3$ （较大的正数），则 $\sigma(3) \approx 0.953$ ，该邮件被预测为垃圾邮件的概率很高。若该邮件的真实标签其实是“正常邮件”（ $y = 0$ ），仅凭 sigmoid 的对称性 $\sigma(-z) = 1 - \sigma(z)$ ，能否直接判断梯度 $(\hat{y} - y)\mathbf{x}$ 的符号，并说明参数将被朝哪个方向调整？

解： $\hat{y} = 0.953$, $y = 0$ ，梯度 $= (0.953 - 0)\mathbf{x} = 0.953\mathbf{x}$ ，符号与 $\mathbf{x}$ 相同；梯度下降会把 θ 朝着减小 $\theta^T \mathbf{x}$ 的方向调整，即压低该邮件被判定为垃圾邮件的概率——这正是“预测错得越离谱、修正力度越大”这一直觉在数学上的体现。

§4.4 例子三：Softmax 回归（多分类）

模型设定

对于 K 类分类问题， $y \in \{1, 2, \dots, K\}$ 。为每个类别 k 定义一个权重向量 θ_k ，并建模为

$$P(y = k | \mathbf{x}, \{\theta_j\}_{j=1}^K) = \frac{e^{\theta_k^T \mathbf{x}}}{\sum_{j=1}^K e^{\theta_j^T \mathbf{x}}} \quad (4.9)$$

该表达式称为 **softmax** 函数，是 sigmoid 函数在多类别情形下的推广。

Softmax 的物理解释

式 (4.9) 正是统计物理中的玻尔兹曼分布：“能量” $E_k = -\theta_k^T \mathbf{x}$ ，“配分函数” $Z = \sum_{j=1}^K e^{\theta_j^T \mathbf{x}}$ ，概率 $P(y = k) = e^{-E_k} / Z$ 。类别 k 的概率与其“负能量” $\theta_k^T \mathbf{x}$ 呈指数关系：能量越低（ $\theta_k^T \mathbf{x}$ 越大），概率越高。

算例：三分类的具体数字

取 $K = 3$ ，设某输入 $\mathbf{x}$ 在三个类别上的原始分数（即 $\theta_k^T \mathbf{x}$ ）分别为

$$z_1 = 2.0, \quad z_2 = 1.0, \quad z_3 = -0.5.$$

第一步：计算各项指数： $e^{z_1} = 7.389$, $e^{z_2} = 2.718$, $e^{z_3} = 0.607$ 。第二步：求和得到配分函数： $Z = 7.389 + 2.718 + 0.607 = 10.714$ 。第三步：归一化得到概率：

分数最高的类别 1 获得了最大的概率份额（69%），但并非“赢家通吃”（winner-take-all）——类别 2 仍保有约四分之一的概率。这正是 softmax 相较于“直接取分数最高的类别”（hard argmax）的优势：它保留了模型对次优选项的不确定性信息，而非武断地只给出单一答案。

交叉熵损失的具体数值：若真实标签恰为概率最高的类别 1，损失为 $\mathcal{L} = -z_1 + \ln Z = -2.0 + 2.372 = 0.372$ （较小，模型“猜对了”，代价不高）；若真实标签实为概率最低的类别 3，

表 4.5: 三分类 Softmax 算例的数值结果

类别 k	原始分数 z_k	e^{z_k}	概率 $P(y = k)$
1	2.0	7.389	0.690
2	1.0	2.718	0.254
3	-0.5	0.607	0.057

损失为 $\mathcal{L} = -z_3 + \ln Z = 0.5 + 2.372 = 2.872$ （大得多，模型“猜错了”，代价高昂）。可以验证这两个数字恰好等于 $-\ln P(y = k)$ ： $-\ln(0.690) = 0.372$ ， $-\ln(0.057) = 2.872$ ，分毫不差。

温度参数与确定性的调控

§2.2 中已反复看到“温度”如何控制系统在“探索所有可能性”与“锁定于最低能量态”之间过渡。这一效应在 softmax 中同样存在——只需在指数上引入一个缩放因子 β （对应逆温度）：

$$P_\beta(y = k) = \frac{e^{\beta z_k}}{\sum_j e^{\beta z_j}}. \quad (4.10)$$

用前述分数 $z = (2.0, 1.0, -0.5)$ ，取三个不同的 β 值：

表 4.6: 不同逆温度 β 下的 Softmax 输出

β	概率 (P_1, P_2, P_3)
0.2（高温）	(0.412, 0.338, 0.250)
1.0（基准）	(0.690, 0.254, 0.057)
5.0（低温）	(0.993, 0.007, 0.000)

高温（ $\beta = 0.2$ ）下，三个类别的概率几乎被“抹平”为均匀分布，模型近乎“随机猜测”；低温（ $\beta = 5.0$ ）下，分布几乎完全坍缩至分数最高的类别 1，近似等价于直接取 $\arg\max$ ——这正是 §2.2（二能级系统）与 §2.3（一维伊辛模型）中“高温均匀、低温冻结”这一规律的又一次重现。在实践中，这一 β （有时写作 $1/\tau$ ， τ 称为温度参数）常被用来控制分类器或生成模型输出的“确定性”：温度越低，输出越保守、越集中于最可能的选项；温度越高，输出越多样、越倾向于尝试次优选项。

独热编码（One-Hot Encoding）

为便于处理，将标签 $y \in \{1, \dots, K\}$ 编码为向量 $\mathbf{y} \in \{0, 1\}^K$ ：

$$\mathbf{y} = [y_1, y_2, \dots, y_K],$$

其中若 $y = k$ 则 $y_k = 1$ ，否则 $y_k = 0$ 。例如 $K = 3$ 时：类别 1 对应 $\mathbf{y} = [1, 0, 0]$ ，类别 2 对应 $\mathbf{y} = [0, 1, 0]$ ，类别 3 对应 $\mathbf{y} = [0, 0, 1]$ 。

交叉熵损失

对数似然为

$$\ln P(\mathbf{y}|\mathbf{x}, \{\boldsymbol{\theta}_k\}) = \sum_{k=1}^K y_k \ln P(y = k|\mathbf{x}, \{\boldsymbol{\theta}_k\})$$

(由于 $\mathbf{y}$ 为独热向量, 此求和中仅有一项非零, 即真实类别 k^* 对应的那一项 $y_{k^*} = 1$, 其余 $y_k = 0$)。代入 Softmax 定义 (4.9) 并取对数 ($\ln$ 作用到商上, $\ln(a/b) = \ln a - \ln b$, 再用 $\ln e^x = x$):

$$\begin{aligned} \ln P(\mathbf{y}|\mathbf{x}, \{\boldsymbol{\theta}_k\}) &= \sum_{k=1}^K y_k \left[\boldsymbol{\theta}_k^T \mathbf{x} - \ln \sum_{j=1}^K e^{\boldsymbol{\theta}_j^T \mathbf{x}} \right] \\ &= \sum_{k=1}^K y_k \boldsymbol{\theta}_k^T \mathbf{x} - \left(\sum_{k=1}^K y_k \right) \ln \sum_{j=1}^K e^{\boldsymbol{\theta}_j^T \mathbf{x}}, \end{aligned}$$

这一步把求和拆成两部分: 第一部分 $\sum_k y_k \boldsymbol{\theta}_k^T \mathbf{x}$ 逐项保留 (因为每一项都依赖于 k); 第二部分中 $\ln \sum_j e^{\boldsymbol{\theta}_j^T \mathbf{x}}$ 不依赖于求和指标 k , 可作为公共因子提出, 从而多出一个因子 $\sum_k y_k$ 。由于 $\mathbf{y}$ 是独热向量 (K 个分量中恰有一个为 1、其余为 0), $\sum_k y_k = 1$, 于是这一项直接化简为 $\ln \sum_j e^{\boldsymbol{\theta}_j^T \mathbf{x}}$ 本身:

$$\ln P(\mathbf{y}|\mathbf{x}, \{\boldsymbol{\theta}_k\}) = \sum_{k=1}^K y_k \boldsymbol{\theta}_k^T \mathbf{x} - \ln \sum_{j=1}^K e^{\boldsymbol{\theta}_j^T \mathbf{x}}.$$

负对数似然 (交叉熵损失) 为

$$\mathcal{L}(\{\boldsymbol{\theta}_k\}) = - \sum_{k=1}^K y_k \boldsymbol{\theta}_k^T \mathbf{x} + \ln \sum_{j=1}^K e^{\boldsymbol{\theta}_j^T \mathbf{x}}. \quad (4.11)$$

对整个数据集:

$$\mathcal{L} = \sum_{n=1}^N \left[- \sum_{k=1}^K y_k^{(n)} \boldsymbol{\theta}_k^T \mathbf{x}^{(n)} + \ln \sum_{j=1}^K e^{\boldsymbol{\theta}_j^T \mathbf{x}^{(n)}} \right].$$

与自由能的类比

将该损失函数与统计物理对比: 定义 “能量” $E_y := -\boldsymbol{\theta}_y^T \mathbf{x}$ (与本节开头 “Softmax 的物理解释” 中的定义一致), 于是式 (4.11) 第一项 $-\sum_k y_k \boldsymbol{\theta}_k^T \mathbf{x}$ 恰好是真实类别对应的能量 E_y (因 $\mathbf{y}$ 独热, 求和只留下真实类别 k^* 那一项); 第二项 $\ln \sum_{j=1}^K e^{\boldsymbol{\theta}_j^T \mathbf{x}} = \ln \sum_j e^{-E_j}$ 正是配分函数的对数 $\ln Z$ 。因此严格地有

$$\mathcal{L} = E_y + \ln Z. \quad (4.12)$$

这里需要特别小心一个符号陷阱: 第二章将亥姆霍兹自由能定义为 $F = -\frac{1}{\beta} \ln Z$ (式 (2.11)), 在本章统一取 $\beta = 1$ 的单位下即 $F = -\ln Z$, 也就是说 $\ln Z = -F$, 而不是 $\ln Z = F$ 。代入式 (4.12), 正确的对应关系是

$$\mathcal{L} = E_y + \ln Z = E_y - F. \quad (4.13)$$

即“损失 = 能量 - 自由能”，而非“能量 + 自由能”——差一个符号，但物理意义完全不同：自由能 $F = \langle E \rangle - TS$ 本身通常为负值（因为 $\ln Z > 0$ 在大多数情形下成立），损失 $\mathcal{L}$ 减去一个负的 F ，结果是加上一个正的量，这与损失恒非负（作为负对数似然）是自洽的；若误写成 $\mathcal{L} = E + F$ ，则在 $\ln Z > 0$ 时会得到 $\mathcal{L} = E - \ln Z$ ，这与式 (4.11) 的显式展开式直接矛盾。读者可以用本节“算例：三分类的具体数字”中的数值自行验证： $Z = 10.714$ ， $\ln Z = 2.372$ ， $F = -\ln Z = -2.372$ ；真实标签为类别 1 时 $E_1 = -z_1 = -2.0$ ，代入 $\mathcal{L} = E_1 - F = -2.0 - (-2.372) = 0.372$ ，与之前算出的 $\mathcal{L} = 0.372$ 完全吻合；而若用错误公式 $\mathcal{L} = E_1 + F = -2.0 + (-2.372) = -4.372$ ，则明显不对。

这一形式在后续讨论玻尔兹曼机时将再次出现。术语提醒：本例中的“能量” E_y （裸的负分数 $-\theta_y^T \mathbf{x}$ ）与 §4.1 中定义的完整损失 $\mathcal{L}$ （即 $-\ln P$ 本身）是两个不同层次的对象—— $\mathcal{L} = E_y + \ln Z$ ，两者只有当 $\ln Z$ 可以被当作与 θ 无关的常数时才会重合（例如线性回归中噪声方差 σ 固定、不随 θ 变化的情形）。在 Softmax 这里 Z 显式依赖于全部 $\{\theta_j\}$ ， E_y 和 $\mathcal{L}$ 并不相等，混用这两个概念正是本节容易出错的地方。

■ 小结

线性回归、逻辑回归、Softmax 回归表面上是三个不同的模型，但它们的损失函数都遵循同一套推导流程：选定噪声/随机性的分布形式 → 写出似然 → 取负对数。高斯噪声产出均方误差，伯努利分布产出二分类交叉熵，类别分布（categorical distribution）产出多分类交叉熵。下一章将正面处理这套框架中暂时回避的一个难题：配分函数 Z 在一般情形下究竟有多难计算。

习题

基础题

习题 4.1: 从高斯噪声到均方误差

详细推导为什么高斯噪声假设导致均方误差损失函数。

- 写出假设 $y = f(\mathbf{x}; \boldsymbol{\theta}) + \epsilon$ 且 $\epsilon \sim \mathcal{N}(0, \sigma^2)$ 时的概率模型；
- 对单个数据点 $(\mathbf{x}, y)$ ，写出对数似然 $\ln P(y|\mathbf{x}, \boldsymbol{\theta})$ ；
- 对 N 个数据点，写出总对数似然；
- 证明最大化对数似然等价于最小化均方误差；
- 讨论 σ 的作用：如果 σ 很小或很大，对学习有什么影响？

习题 4.2: Sigmoid 函数的性质

证明 sigmoid 函数 $\sigma(z) = \frac{1}{1 + e^{-z}}$ 的以下性质：

- (a) $\sigma(-z) = 1 - \sigma(z)$;
- (b) $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$;
- (c) $\sigma(z) + \sigma(-z) = 1$;
- (d) $\ln \sigma(z) = -\ln(1 + e^{-z})$ 且 $\ln[1 - \sigma(z)] = -z - \ln(1 + e^{-z})$ 。

习题 4.3: Softmax 的性质

对于 softmax 函数 $p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$:

- (a) 证明 $\sum_k p_k = 1$;
- (b) 证明所有 $p_k \in (0, 1)$;
- (c) 计算 $\frac{\partial p_k}{\partial z_i}$, 分 $i = k$ 和 $i \neq k$ 两种情况;
- (d) 证明 $\frac{\partial p_k}{\partial z_k} = p_k(1 - p_k)$ 且 $\frac{\partial p_k}{\partial z_i} = -p_k p_i$ (当 $i \neq k$)。

提示: 利用 $\frac{\partial}{\partial z_i} \ln \sum_j e^{z_j} = \frac{e^{z_i}}{\sum_j e^{z_j}} = p_i$ 。

进阶题

习题 4.4: 拉普拉斯噪声与 L_1 损失

§4.2 从“噪声 ϵ 服从高斯分布”这一假设, 推导出了均方误差损失。现在改变噪声的分布假设, 重新走一遍“选定噪声分布 $\rightarrow$ 写出似然 $\rightarrow$ 取负对数似然”这一完整流程。设 $y = \theta^T \mathbf{x} + \epsilon$, 其中 ϵ 服从拉普拉斯分布 (Laplace distribution):

$$P(\epsilon) = \frac{1}{2b} \exp\left(-\frac{|\epsilon|}{b}\right), \quad b > 0.$$

- (a) 写出条件概率密度 $P(y|\mathbf{x}, \theta)$;
- (b) 对数据集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 仿照 §4.2 的步骤, 完整推导负对数似然损失函数 $L(\theta)$;
- (c) 证明该损失函数正比于绝对误差之和 (即 L_1 损失): $L(\theta) = \frac{1}{b} \sum_{n=1}^N |y^{(n)} - \theta^T \mathbf{x}^{(n)}| + \text{const}$;
- (d) 拉普拉斯分布相比高斯分布“尾部更重” (即出现远离均值的极端值的概率更大)。从这一点出发, 解释为什么 L_1 损失 (对应拉普拉斯噪声) 比均方误差 (对应高斯噪声) 对训练数据中的异常值 (outlier) 更不敏感——这正是统计学中“稳健回归” (robust regression) 的基本思想。

挑战题

习题 4.5: 广义线性模型与指数族分布

本章通过高斯、伯努利、类别分布三个具体例子，反复使用同一套流程：选定噪声/随机性的分布形式 $\rightarrow$ 写出似然 $\rightarrow$ 取负对数似然 $\rightarrow$ 得到损失函数。这并非巧合——这三个分布都属于统计学中的指数族分布（exponential family），其一般形式为

$$P(y|\eta) = h(y) \exp(\eta y - A(\eta)),$$

其中 η 称为自然参数（natural parameter）， $A(\eta)$ 称为对数配分函数（log-partition function）。

- (a) 查阅资料（或自行推导），验证高斯分布（固定方差 σ^2 ）与伯努利分布都可以写成上述形式，分别写出对应的 $\eta, h(y), A(\eta)$ ；对伯努利分布，说明 η 恰好就是 §4.3 中出现过的“对数几率”（log-odds） $\ln \frac{p}{1-p}$ ；
- (b) 广义线性模型（Generalized Linear Model, GLM）假设自然参数是特征的线性函数， $\eta = \boldsymbol{\theta}^T \mathbf{x}$ 。证明由此导出的负对数似然损失，正是本章线性回归与逻辑回归损失函数的统一形式；
- (c) 证明指数族分布满足 $\mathbb{E}[y] = A'(\eta)$ （对数配分函数的导数给出均值）。这一结果与第二章 $\langle E \rangle = -\partial \ln Z / \partial \beta$ 的推导，在数学结构上是否是同一件事？说明理由；
- (d) 泊松分布（Poisson distribution，常用于建模计数数据，如“一个网页每天的点击次数”）也属于指数族。尝试推导“泊松回归”对应的负对数似然损失函数，并说明它与均方误差、交叉熵相比适合处理哪一类数据。

配分函数与归一化

*O God, I could be bounded in a nutshell
And count myself a king of infinite space.*

—— 莎士比亚《哈姆雷特》第二幕第二场，哈姆雷特

学习目标

- 理解归一化在概率模型中的普遍性，认识到玻尔兹曼分布、Softmax 等此前计算过的例子本质上都是同一个“配分函数”问题；
- 掌握马尔可夫随机场（MRF）的基本语言——团、势函数、局部与全局马尔可夫性质，并理解 Hammersley–Clifford 定理如何将局部条件独立与全局吉布斯分解等价起来；
- 认识配分函数计算随变量数目指数增长的本质困难，并理解这一困难如何具体体现在归一化、边缘化与参数学习（“正相位—负相位”）之中；
- 对蒙特卡洛采样、变分方法、信念传播、重整化群等近似方法建立初步的整体图景。

■ 本章导览

本章回答的问题：为什么“归一化”在概率模型的实际训练中是一个真正的计算难题，而不只是一个形式上的技术细节？马尔可夫随机场（图模型）这套语言，如何帮助我们组织并理解这一困难？

统计物理对应：本章把第二章的一维伊辛模型推广为一般的马尔可夫随机场，Hammersley–Clifford 定理说明“局部相互作用的图结构”与“能量按团分解”本质上是同一件事；参数学习的梯度公式（“正相位减负相位”）直接来自对 $\ln Z(\theta)$ 求导，这是第二章 $\ln Z$ 生成热力学量这一技巧的直接延伸。

后续预告：第六章将展示，当 Z 无法精确计算时，变分方法如何把“精确计算”替换为“寻找一个足够好的近似”——这是一个可以被优化算法求解的问题，而不再是死路一条。

前三章中，我们已经在不知不觉间反复计算过同一个对象：双态系统的 $Z = 1 + e^{-\beta\varepsilon}$ (§2.2)、 $N = 2$ 伊辛链的 $Z = 4 \cosh(\beta J)$ (§2.3)、Softmax 的 $Z = \sum_j e^{z_j}$ (§4.4) ——它们全部都是“配分函数”，只是在不同领域中呈现为不同的形式。本章要正面处理一个此前刻意回避的问题：上述例子之所以能够手算，是因为变量数目很少（2 个自旋、3 个类别）；一旦变量

数目增大到真实问题的规模，配分函数的计算会有多困难？这一困难的根源何在？又应当如何应对？

§5.1 归一化的普遍性

在概率模型中，归一化是必不可少的一环。无论是统计物理的玻尔兹曼分布，还是机器学习的 softmax，都需要一个归一化常数（配分函数）：

$$P(\mathbf{x}) = \frac{1}{Z} f(\mathbf{x}), \quad (5.1)$$

其中 $Z = \sum_{\mathbf{x}} f(\mathbf{x})$ 或 $Z = \int f(\mathbf{x}) d\mathbf{x}$ 。

■ 对照表更新：配分函数一行，从“是什么”到“有多难”

第二章种子表（表 2.8）与第四章都已经把“配分函数 Z ”这一行填过一次： Z 就是归一化常数。本章不再重复这一点，而是深入这一行的反面——填表容易，算表难。本章接下来要说明的是，为什么这一个看似平凡的归一化步骤，在变量数目稍大时就会成为整个框架里最难啃的部分。

回顾此前已经亲手计算过的几个 Z ：

表 5.1: 此前各章中已经计算过的配分函数

出处	系统	配分函数 Z
§2.2	双态系统	$Z = 1 + e^{-\beta\varepsilon}$
§2.3	$N = 2$ 伊辛链	$Z = 4 \cosh(\beta J)$
§4.4	三分类 Softmax	$Z = \sum_{j=1}^3 e^{z_j}$

上述三个例子的变量数目都很小（1、2、3 个“单元”），求和式中最多不过几项，一眼便能写全、算完。真正的困难从来不在于“配分函数是什么”，而在于当变量数目变大之后，求和式中的项数会以指数速度失控——这正是本章接下来要讨论的问题。

§5.2 无向图模型（Markov Random Fields）

为什么需要图模型？联合分布的组合爆炸

设有 N 个随机变量 $X_1, \dots, X_N$ ，每个变量取 K 个离散值。在没有任何结构假设的情况下，联合分布 $P(X_1, \dots, X_N)$ 需要 $K^N - 1$ 个独立参数才能完全指定（减一是因为归一化约束）。

例如， $N = 4$ 个二值变量（ $K = 2$ ）需要 $2^4 - 1 = 15$ 个参数，尚可接受；但 $N = 100$ 时， $2^{100} \approx 1.3 \times 10^{30}$ ——这一数字虽然远小于可观测宇宙中原子数量的估计值（约 10^{80} 量级），但仍远远超出任何现实计算机可以逐项存储或穷举处理的规模：即使以每个原子作为一个存储单元，把地球上全部物质（约 10^{50} 个原子）都用来存这张概率表，也还差 20 个数量级；这样的参数量既无法存储，也不可能从任何现实规模的有限数据中估计出来。

将这一增长速度具体列出，更有直观感受：

表 5.2: 状态总数 2^N 随变量数 N 的增长

N (二值变量数)	2^N
10	1.0×10^3 (千)
20	1.0×10^6 (百万)
30	1.1×10^9 (十亿)
60	1.2×10^{18}
100	1.3×10^{30}

从 $N = 10$ 到 $N = 100$ ，输入规模只增长了 10 倍，状态数目却从“千”膨胀到“ 10^{30} ”——这正是 §2.1“数格子”一例中 $\Omega(k)$ 表格所呈现现象的姐妹版本：那里是“宏观状态对应的微观状态数”随 N 指数增长，这里是“整个系统的状态总数”随 N 指数增长，本质上是同一种组合爆炸。

这一困境对统计物理学家而言并不陌生：它正是“多体问题”的概率论版本。 N 个自旋的联合分布原则上需要 2^N 个数来描述，但物理学告诉我们，绝大多数微观细节对宏观行为并不重要，真正重要的是局部相互作用的结构——例如一个自旋只直接耦合到其最近邻，而非系统中的全部其他自旋。图模型正是把这一物理直觉转化为精确数学语言的工具：图的节点代表随机变量，边代表“直接依赖”，没有边则意味着两个变量之间没有直接相互作用，它们之间的关联（如果存在）必须经由图上的其他变量“传递”。

从马尔可夫链到马尔可夫场：把“局域性”从时间推广到图结构

回顾一维马尔可夫链的定义：对于按时间排列的随机变量序列 $X_1, X_2, \dots, X_T$ （例如“今天天气 $\rightarrow$ 明天天气 $\rightarrow$ 后天天气”），马尔可夫性质为

$$P(X_{t+1} \mid X_t, X_{t-1}, \dots, X_1) = P(X_{t+1} \mid X_t), \quad (5.2)$$

即“未来只依赖于现在，不依赖于过去”。这是一种沿时间方向的局域性假设：每个变量只与时间上紧邻它的那一个变量直接相关。

马尔可夫随机场 (Markov Random Field, MRF) 所做的是同一件事，只是把“时间轴”替换成了任意的图结构——局域性不再是时间上的先后，而是图上的邻接关系。设图 $G = (V, E)$ ，节点集合 $V = \{1, \dots, N\}$ 对应随机变量 $\{X_i\}$ ，边集合 E 编码直接依赖关系。对节点 i ，定义其邻居集合 $N(i) = \{j : (i, j) \in E\}$ 。MRF 满足的局部马尔可夫性质为

$$X_i \perp X_{V \setminus (\{i\} \cup N(i))} \mid X_{N(i)}, \quad (5.3)$$

即“给定 i 的所有图邻居之后， X_i 与图中其余所有变量条件独立”。例如在 $A-B-C$ 、且 B 还连接着 D 这样的图中， A 只需要知道 B 就足够，无需关心 C, D ： $P(A \mid B, C, D) = P(A \mid B)$ 。

图论语言：分离集与条件独立

无向图为条件独立关系提供了一种直观的几何刻画：图上的分离（separation）对应概率上的条件独立。设 $A, B, S \subseteq V$ 是三个互不相交的节点子集；若图中从 A 的任一节点到 B 的任一节点的每一条路径都必须经过 S ，则称 S 分离了 A 与 B 。MRF 的全局马尔可夫性质断言：

$$S \text{ 在图上分离 } A, B \implies X_A \perp X_B \mid X_S. \quad (5.4)$$

最简单的例子仍是链 $A-B-C$ ： B 分离了 A, C ，于是 $X_A \perp X_C \mid X_B$ ——给定 B 之后， A, C 互不提供关于彼此的信息。这正是“没有边就没有直接关联”这一物理直觉最精确的数学表达。

值得注意的是（这一点初学者容易忽略）：MRF 实际上有三个强度递增的马尔可夫性质——两两（pairwise）、局部（local）、全局（global）。由分离的定义可以直接得到“全局 $\Rightarrow$ 局部 $\Rightarrow$ 两两”；但反方向（两两 $\Rightarrow$ 全局）并非自动成立，它需要联合分布处处为正（ $P(\mathbf{x}) > 0$ 对所有构型 $\mathbf{x}$ 成立）这一额外条件（Pearl, 1988）。下文讨论 Hammersley–Clifford 定理时还会再次遇到这一正性条件——它并非无关紧要的技术细节，而是“局部独立性等同于全局能量分解”这一论断背后真正的前提。

团（Clique）：能量函数真正“看到”的基本单元

图的边告诉我们“谁与谁直接相关”，但能量函数实际作用的对象是团（clique）。

定义 5.1: 团（Clique）

图 G 中的节点子集 $c \subseteq V$ 称为一个团，如果 c 中任意两个节点都有边相连（即 c 在 G 中构成完全子图）。若再加入任何一个节点都会破坏这一性质，则称 c 为最大团（maximal clique）。

三角形 $A-B-C$ （三条边两两相连）是一个 3-团；链 $A-B-C$ （只有 $A-B$ 、 $B-C$ 两条边，没有 $A-C$ ）不是一个团——它的最大团是 $\{A, B\}$ 与 $\{B, C\}$ 这两条边。

势函数只定义在（最大）团上，而非整个变量集合上，这正是 MRF 降低参数复杂度的根本机制：与其用单个 $\psi(x_1, \dots, x_N)$ 描述全部 N 个变量的联合相互作用（需要 K^N 个参数），不如将其拆分为若干局域势函数 $\{\psi_c(\mathbf{x}_c)\}_{c \in \mathcal{C}}$ 的乘积，每个 ψ_c 只依赖于一个团内的少数变量——这正是从“组合爆炸”回到“可处理”的关键一步。

Hammersley–Clifford 定理：局部马尔可夫性 $\iff$ 全局吉布斯分解

这是 MRF 理论的核心定理，它将“图上的局部条件独立假设”与“能量函数按团分解”这两件表面上不同的事情严格地等同起来。

定理 5.1: Hammersley–Clifford 定理

设 $\mathbf{X} = (X_1, \dots, X_N)$ 取值于有限集合，且联合分布处处为正： $P(\mathbf{x}) > 0$ 对所有 $\mathbf{x}$ 成立。则 P 满足关于图 G 的马尔可夫性质，当且仅当存在一族正的团势函数 $\{\psi_c(\mathbf{x}_c) > 0\}_{c \in \mathcal{C}}$

定理 5.1 (续)

($\mathcal{C}$ 是图 G 的全部最大团), 使得

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{c \in \mathcal{C}} \psi_c(\mathbf{x}_c) \quad (5.5)$$

成立 (Hammersley & Clifford, 1971; 亦见 Besag, 1974)。

■ 从“势”到“能量”：一次符号上必须做对的转换

式 (5.5) 是乘积形式, ψ_c 本身要求恒正但不要求满足任何加和关系。若想把它改写成统计物理惯用的玻尔兹曼指数形式 $P(\mathbf{x}) = \frac{1}{Z} e^{-E(\mathbf{x})}$, 不能直接令 $E(\mathbf{x}) = \sum_c \psi_c(\mathbf{x}_c)$ ——这是把“乘积里的因子”和“指数里的加项”混为一谈, 量纲上就不对: 右边取对数后应得到 $-E(\mathbf{x}) = \sum_c \ln \psi_c(\mathbf{x}_c)$, 因此正确的定义是

$$E(\mathbf{x}) := - \sum_{c \in \mathcal{C}} \ln \psi_c(\mathbf{x}_c), \quad (5.6)$$

即“每个团势取负对数后再相加”, 而非“直接把势函数本身相加”。代入即可验证 $\prod_c \psi_c(\mathbf{x}_c) = \prod_c e^{-\ln \psi_c(\mathbf{x}_c) \cdot (-1)} = e^{\sum_c \ln \psi_c(\mathbf{x}_c)} = e^{-E(\mathbf{x})}$, 式 (5.5) 与玻尔兹曼形式 $P(\mathbf{x}) = \frac{1}{Z} e^{-E(\mathbf{x})}$ 由此严格等价。下一小节“能量函数表示”即采用式 (5.6) 这一定义。

证明思路。 容易的方向 (吉布斯分解 $\Rightarrow$ 马尔可夫性): 这一方向的直觉十分物理化。若 $P(\mathbf{x}) \propto \prod_c \psi_c(\mathbf{x}_c)$, 计算条件分布 $P(x_i | \mathbf{x}_{-i})$ 时, 所有不包含节点 i 的团势函数都与 x_i 无关, 会在分子分母中完全约去; 只有包含 i (即只依赖于 i 及其邻居) 的团才会留下来。于是 x_i 的条件分布只依赖于邻居 $N(i)$ ——这正是局部马尔可夫性质。

困难的方向 (马尔可夫性 $\Rightarrow$ 吉布斯分解): 标准证明 (Brook 引理) 的核心技巧是: 取一个固定参考构型 $\mathbf{x}^0$, 将 $\ln[P(\mathbf{x})/P(\mathbf{x}^0)]$ 按“ $\mathbf{x}$ 中哪些坐标偏离 $\mathbf{x}^0$ ”做包含-排斥 (Möbius 反演) 式的展开。马尔可夫性质保证了展开式中, 凡涉及非团 (在图上不构成完全子图) 坐标子集的项, 其系数必然恒为零; 幸存下来的项恰好按最大团重新组合——注意这里展开的对象是 $\ln P$ 本身, 所以幸存下来的每一项直接就是式 (5.6) 意义下的团能量 $\phi_c(\mathbf{x}_c) = -\ln \psi_c(\mathbf{x}_c)$, 求和后给出 $E(\mathbf{x}) = \sum_c \phi_c(\mathbf{x}_c) = -\sum_c \ln \psi_c(\mathbf{x}_c)$ 的形式, 与式 (5.5) 的乘积形式 $\prod_c \psi_c(\mathbf{x}_c) = \prod_c e^{-\phi_c(\mathbf{x}_c)}$ 相符。 ■

■ 释疑

正性条件为何不能省略? 若某些构型的概率严格为零, “困难方向”的证明便会失效——Moussouris (1974) 构造了一个具体反例: 一个满足全局马尔可夫性质、却无法写成按团分解吉布斯形式的分布, 根源恰恰在于它把某个本应允许的构型概率设为了零。这提醒我们: 从“局部约束”推出“全局能量分解”这一看似显然的物理直觉, 其严格性实际上依赖于一个常被忽略的前提——这也是形式化思维 (无论是数学证明还是 Lean 这样的证明系统) 真正的价值所在: 把“显然”背后隐藏的假设条件暴露出来。

对统计物理学家而言, 这一定理的意义可以概括为一句话: 任何只含局域相互作用的吉

布斯测度，其条件独立结构必然对应一个图；反过来，任何满足“给定邻居即条件独立”这一直觉的（处处为正的）分布，也必然可以写成局域势函数之积的吉布斯形式。局域性（图的稀疏连接）与能量的可加性（按团分解）本质上是同一件事的两种说法。

能量函数表示

对于无向图模型，按式 (5.6) 定义能量函数

$$E(\mathbf{x}) = - \sum_{c \in \mathcal{C}} \ln \psi_c(\mathbf{x}_c),$$

其中 $\mathcal{C}$ 是图的全部最大团， $\mathbf{x}_c$ 是团 c 中的变量， $\psi_c(\mathbf{x}_c) > 0$ 是定义在团 c 上的势函数。实践中也常常反过来操作：直接给每个团指定一个（可正可负、无需取对数的）“团能量” $\phi_c(\mathbf{x}_c) := -\ln \psi_c(\mathbf{x}_c)$ ，使 $E(\mathbf{x}) = \sum_c \phi_c(\mathbf{x}_c)$ ——下面一维伊辛模型的例子采用的正是这种“直接给能量、而非先给势函数再取对数”的等价写法。联合概率分布为

$$P(\mathbf{x}) = \frac{1}{Z} e^{-E(\mathbf{x})}, \quad (5.7)$$

配分函数为

$$Z = \sum_{\mathbf{x}} e^{-E(\mathbf{x})}.$$

这正是统计物理中的形式——而且根据 Hammersley–Clifford 定理，这并非偶然的相似，而是“局部马尔可夫性”在数学上唯一允许的形式。

案例重访：一维伊辛模型就是一条链状的 MRF

现在可以把 §2.3 的一维伊辛模型严格地纳入 MRF 的语言。将每个自旋 s_i 看作图节点，相邻自旋之间连一条边，得到链状图

$$s_1 - s_2 - s_3 - \cdots - s_N.$$

这条链的最大团恰好是相邻自旋对 $\{s_i, s_{i+1}\}$ （若 $h \neq 0$ ，单节点 $\{s_i\}$ 也是团，对应外场项）。按上一小节“直接指定团能量”的写法，取团能量为

$$\phi_{i,i+1}(s_i, s_{i+1}) = -\beta J s_i s_{i+1}, \quad \phi_i(s_i) = -\beta h s_i,$$

（等价地，对应的团势函数为 $\psi_{i,i+1} = e^{-\phi_{i,i+1}} = e^{\beta J s_i s_{i+1}}$ ， $\psi_i = e^{\beta h s_i}$ ，恒正，满足 Hammersley–Clifford 定理的要求）。代入 $E(\mathbf{s}) = \sum_c \phi_c$ ，立即还原出式 (2.17) 给出的能量函数 $E = -J \sum_i s_i s_{i+1} - h \sum_i s_i$ （此处团能量已吸收了 β 因子，对应 MRF 惯例中“能量”与物理惯例中“ $\beta \times$ 能量”的记号差异）。

这也解释了转移矩阵方法为何行之有效：链状图的团结构（只有最近邻对）正是转移矩阵 $T_{s,s'} = e^{\beta J s s'}$ （式 (2.20)）能将配分函数写成矩阵乘积 $\text{Tr}(\mathbf{T}^N)$ （式 (2.21)）的根本原因——每一步转移恰好对应一个团势函数。从图模型的角度看，转移矩阵方法本质上是沿着 MRF 的链状结构做“团到团”的消元，这正是后续将遇到的信念传播（belief propagation）思想在一维情形下的特例。

同时, 马尔可夫性质 $s_i \perp \{s_j : |j - i| > 1\} \mid s_{i-1}, s_{i+1}$ 在物理上对应一个简单事实: 第 i 个自旋只直接感受到最近邻的局域场, 更远处自旋的影响必须“经由”中间自旋逐步传递——这正是一维链中关联函数 (式 (2.24)) 随距离指数衰减、存在有限关联长度 ξ (式 (2.25)) 的图模型来源。

算例: 三节点 MRF 的配分函数与边缘概率

直接复用 §2.3 已经算过的 $N = 3$ 开链伊辛例子 ($J = 1, k_B T = 1$, 即 $\beta J = 1, h = 0$), 将“边缘化”这一在推断问题中至关重要的操作完整地计算一遍。能量为 $E(s_1, s_2, s_3) = -J(s_1 s_2 + s_2 s_3)$, 玻尔兹曼权重为 $e^{-\beta E} = e^{\beta J(s_1 s_2 + s_2 s_3)}$ 。逐一列出全部 $2^3 = 8$ 个状态:

表 5.3: $N = 3$ 开链伊辛模型 ($\beta J = 1, h = 0$) 的全部微观状态与权重

(s_1, s_2, s_3)	$s_1 s_2 + s_2 s_3$	权重 $e^{\beta J(s_1 s_2 + s_2 s_3)}$
(+, +, +)	2	$e^2 \approx 7.389$
(+, +, -)	0	$e^0 = 1$
(+, -, +)	-2	$e^{-2} \approx 0.135$
(+, -, -)	0	$e^0 = 1$
(-, +, +)	0	$e^0 = 1$
(-, +, -)	-2	$e^{-2} \approx 0.135$
(-, -, +)	0	$e^0 = 1$
(-, -, -)	2	$e^2 \approx 7.389$

将表 5.3 中全部 8 个权重相加, 即得配分函数 (与 §2.3 中转移矩阵方法算出的结果核对):

$$Z = 2 \times 7.389 + 4 \times 1 + 2 \times 0.135 = 14.778 + 4 + 0.270 = 19.048 \approx 19.05.$$

现在提出一个新问题: 如果只关心第一个自旋 s_1 的朝向, 不管 s_2, s_3 具体取值, $s_1 = +1$ 的概率是多少? 这就是边缘概率 $P(s_1)$, 计算方法是将 Z 中所有 $s_1 = +1$ 的状态权重单独加总, 再除以完整的 Z :

$$P(s_1 = +1) = \frac{1}{Z} \sum_{s_2, s_3} e^{-\beta E(+1, s_2, s_3)}.$$

按表 5.3, $s_1 = +1$ 对应前四行, 权重之和为 $7.389 + 1 + 0.135 + 1 = 9.524$, 于是

$$P(s_1 = +1) = \frac{9.524}{19.048} = 0.500.$$

由上下对称性 (§2.3“思考与验证”中已验证过的对称性) 这一结果并不意外: 链两端不对称也不影响这一点, 因为整条链在 $h = 0$ 时翻转所有自旋不改变能量。

更有意思的是条件概率。若已观测到 $s_1 = +1$, s_3 (链的另一端, 隔着 s_2) 取 $+1$ 的概率是否会因此改变? 先算联合概率: $s_1 = +1$ 且 $s_3 = +1$ 对应表 5.3 第一、三行 ((+, +, +) 与 (+, -, +)), 权重之和为 $7.389 + 0.135 = 7.524$, 故

$$P(s_1 = +1, s_3 = +1) = \frac{7.524}{19.048} = 0.395,$$

再按条件概率定义（第三章“预备定义”： $P(A|B) = P(A, B)/P(B)$ ）：

$$P(s_3 = +1 | s_1 = +1) = \frac{P(s_1 = +1, s_3 = +1)}{P(s_1 = +1)} = \frac{0.395}{0.500} = 0.790.$$

对比无条件的 $P(s_3 = +1) = 0.5$ ，观测到 $s_1 = +1$ 之后， $s_3 = +1$ 的概率跳升至 0.79——尽管 s_1 与 s_3 在图上并不直接相连（它们之间没有边，中间隔着 s_2 ），关联信息依然通过 s_2 “传递”了过去。这正是本节开始时强调的“没有边不代表没有关联，只是关联必须经由图上的路径传递”这句话的具体数值印证；也正因如此，计算像 $P(s_1 = +1)$ 这样看似只涉及“一个变量”的简单问题，仍然需要对整个联合分布（此处是全部 8 个状态）求和——这正是 §5.3 即将讨论的“配分函数计算困难”在最小规模上的雏形：哪怕只有 3 个变量，边缘化也已经要求遍历全部状态空间。

■ 思考与验证

上例中， $P(s_2 = +1)$ （中间自旋的边缘概率）应等于多少？不需要重新计算，只需利用对称性论证。

解：同样是 0.5——整条链在 $h = 0$ 时具有“整体翻转不改变能量”的对称性，这一对称性对链上任意位置的自旋都成立，不仅限于两端。

算例：图像分割的 MRF 模型

考虑一个简单的图像分割问题：给定一幅图像，将每个像素分类为“前景”或“背景”。设像素 i 的标签为 $x_i \in \{0, 1\}$ （0=背景，1=前景），全部像素的标签组成向量 $\mathbf{x} = (x_1, \dots, x_N)$ 。

像素排列在二维网格上，每个像素与上下左右四个邻居相连——这是图像处理中常见的 4-邻接 MRF，最大团为单个节点（对应数据项）与相邻像素对（对应平滑项）。按 §5.2“直接指定团能量”的写法，能量函数包含两部分：

数据项 (Data term)：衡量标签与观测的一致性，

$$\phi_i^{\text{data}}(x_i) = -\ln P(\text{观测}_i | x_i).$$

例如，若像素 i 的颜色为 c_i ，可以建模 $P(c_i | x_i = 1) = \mathcal{N}(c_i; \mu_{\text{fg}}, \sigma_{\text{fg}}^2)$ （前景颜色分布）与 $P(c_i | x_i = 0) = \mathcal{N}(c_i; \mu_{\text{bg}}, \sigma_{\text{bg}}^2)$ （背景颜色分布）。

平滑项 (Smoothness term)：鼓励相邻像素取相同标签，

$$\phi_{ij}^{\text{smooth}}(x_i, x_j) = \begin{cases} 0 & \text{若 } x_i = x_j, \\ \lambda & \text{若 } x_i \neq x_j, \end{cases}$$

其中 $\lambda > 0$ 为惩罚参数。总能量为

$$E(\mathbf{x}) = \sum_i \phi_i^{\text{data}}(x_i) + \sum_{(i,j) \in \mathcal{E}} \phi_{ij}^{\text{smooth}}(x_i, x_j)$$

（等价地，对应的团势函数为 $\psi_i^{\text{data}} = e^{-\phi_i^{\text{data}}} = P(\text{观测}_i | x_i)$ ， $\psi_{ij}^{\text{smooth}} = e^{-\phi_{ij}^{\text{smooth}}}$ ，均恒正）。

物理类比：数据项 ϕ_i^{data} 类似“外磁场”（观测数据驱动每个像素的标签）；平滑项 $\phi_{ij}^{\text{smooth}}$ 类似“铁磁耦合”（相邻像素倾向于同向）。

这正是伊辛模型在外磁场中的形式——唯一的区别是，图像分割用的是二维网格图而非一维链，对应二维伊辛模型，而非 §2.3 中用转移矩阵精确求解的一维链。这也提示了一个重要的复杂度事实：一维链可以精确求解，但二维及以上的 **MRF** 一般没有解析解，这正是 §5.3 即将讨论的配分函数计算困难的图论根源。

MRF 与贝叶斯网络：无向 vs 有向

图模型还有另一大类——贝叶斯网络 (Bayesian Network, BN)，它用有向无环图 (DAG) 而非无向图编码依赖关系。将两者对比，可以更清楚地看出 MRF 的特点：

表 5.4: 贝叶斯网络与马尔可夫随机场的比较

	贝叶斯网络 (BN)	马尔可夫随机场 (MRF)
图的类型	有向无环图 (DAG)	无向图
编码的关系	因果生成过程	对称的相互作用
分解方式	$P(\mathbf{x}) = \prod_i P(x_i \text{pa}(i))$ (条件概率表, 自动归一化)	$P(\mathbf{x}) = \frac{1}{Z} \prod_c \psi_c(\mathbf{x}_c)$ (团势函数, 需要配分函数 Z)
局部组件	条件概率表 (CPT)	势函数 (Potential)
典型例子	“下雨 → 草地湿” (因果链)	“下雨 — 草地湿” (相关但不预设方向)

两者的本质区别在于：贝叶斯网络的有向边首先编码的是联合分布按条件概率的分解结构 $P(x_1, \dots, x_N) = \prod_i P(x_i | x_{\text{pa}(i)})$ ，这一分解本身只是一种数学记账方式，并不自动等于因果关系——同一个联合分布往往可以用多种不同方向的 DAG 分解（例如两变量的联合分布 $P(A, B)$ 既可以写成 $P(A)P(B|A)$ ，也可以写成 $P(B)P(A|B)$ ）。只有在额外附加了因果建模的假设（如因果马尔可夫条件、无隐藏混杂变量等，这是因果推断理论的专门内容）之后，箭头才可以被赋予“先有原因、才有结果”这层含义。

相比之下，MRF 的边只表达相互作用的存在性，不预设方向，也不涉及分解顺序的选择。这正是为什么平衡态统计物理（其中相互作用是瞬时、对称的——类似牛顿第三定律的精神）天然地用 MRF/吉布斯测度描述，而非贝叶斯网络；而当系统涉及真实的时间演化过程（例如隐马尔可夫模型、生成式扩散模型的反向去噪链，这里时间先后本身就自然提供了方向）时，有向图模型反而更为自然——这是后续讨论生成模型的章节会重新遇到的对比。

另需指出：贝叶斯网络的条件概率表天然满足归一化 ($\sum_{x_i} P(x_i | \text{pa}(i)) = 1$)，因此不需要配分函数；这恰恰反衬出 MRF 必须引入归一化常数 Z 、并因此面临 §5.3 将讨论的计算困难，根本原因正在于此。

MRF 大家族：统一图景

一旦建立起“图 + 团势函数 + 配分函数”这套语言，会发现统计物理与概率机器学习中相当一部分看似不同的模型，其实都是同一个 MRF 框架的特例：

- 伊辛模型 / Potts 模型：节点为离散自旋变量，团为最近邻对，势函数为耦合项 $-Js_i s_j$ ；

- 玻尔兹曼机 (Boltzmann Machine): 节点为二值神经元, 全连接图, 团为任意一对神经元;
- 受限玻尔兹曼机 (RBM): 可见层与隐藏层之间的二部图, 团只存在于跨层的边上 (层内无连接);
- 条件随机场 (CRF): 在给定观测 $\mathbf{y}$ (如输入特征) 条件下定义的 MRF, 常用于序列标注;
- 图像分割 / 立体视觉 (Stereo Vision): 像素网格图, 数据项 + 平滑项;
- 此外, 纠错编码 (error-correcting codes)、蛋白质折叠的格点模型等, 本质上也是带有特定图结构和团势函数的 MRF。

用一句话总结: **MRF** 是统计物理中 “局域相互作用 $\rightarrow$ 哈密顿量 $\rightarrow$ 玻尔兹曼分布” 这条逻辑链, 在概率图模型语言中的精确对应表达。图编码了 “谁与谁直接相互作用”, 团势函数编码了 “相互作用的强度”, 而 Hammersley–Clifford 定理保证了这一局部刻画与全局吉布斯分布之间严格等价——这正是为什么伊辛模型、玻尔兹曼机、条件随机场等看似来自不同领域的模型, 本质上都属于同一个数学家族, 这一点将在后续讨论 Hopfield 网络、玻尔兹曼机与 RBM 的章节中具体展开。

§5.3 配分函数的计算挑战

计算复杂度

对于一个有 N 个变量的系统, 若每个变量可取 K 个值, 配分函数需要对 K^N 个状态求和:

$$Z = \sum_{x_1=1}^K \sum_{x_2=1}^K \cdots \sum_{x_N=1}^K e^{-E(x_1, \dots, x_N)}.$$

例如: $N = 100$ 个二值变量 ($K = 2$) 对应 $2^{100} \approx 10^{30}$ 个状态; $N = 256 \times 256$ 个像素的图像, 每个像素 2 个可能标签, 则对应 2^{65536} 个状态。这样的计算量是天文数字, 即使是最快的超级计算机也无法穷举。

为什么配分函数如此重要?

虽然计算困难, 配分函数在许多任务中却是必需的。

(1) 归一化概率。要计算任何概率 $P(\mathbf{x})$, 都需要知道 Z 。

(2) 边缘化 (Marginalization)。计算边缘概率 $P(x_i)$:

$$P(x_i) = \sum_{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_N} P(\mathbf{x}) = \frac{1}{Z} \sum_{\mathbf{x}_{-i}} e^{-E(\mathbf{x})},$$

同样需要知道 Z 才能归一化。

(3) 学习 (参数估计)。若能量函数依赖于参数 θ , 即 $E(\mathbf{x}; \theta)$, 则配分函数也依赖于参数: $Z(\theta) = \sum_{\mathbf{x}'} e^{-E(\mathbf{x}'; \theta)}$ 。最大似然估计需要计算对数似然关于 θ 的梯度。

第一步：把 $\ln P$ 拆成两项。对式 (5.7) 中 $P(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{Z(\boldsymbol{\theta})} e^{-E(\mathbf{x}; \boldsymbol{\theta})}$ 取对数 ($\ln(a/b) = \ln a - \ln b$, $\ln e^x = x$):

$$\ln P(\mathbf{x}; \boldsymbol{\theta}) = -E(\mathbf{x}; \boldsymbol{\theta}) - \ln Z(\boldsymbol{\theta}).$$

对 $\boldsymbol{\theta}$ 求导，逐项处理：

$$\frac{\partial}{\partial \boldsymbol{\theta}} \ln P(\mathbf{x}; \boldsymbol{\theta}) = -\frac{\partial E(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} - \frac{\partial \ln Z(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}. \quad (5.8)$$

第一项已经是我們想要的形式；第二项 $\partial \ln Z / \partial \boldsymbol{\theta}$ 还需要单独展开——这与第二章 §2.2 中对 $\ln Z$ 关于 β 求导、从而“生成”平均能量的技巧完全是同一套操作，只是这里求导的对象换成了参数 $\boldsymbol{\theta}$ 。

第二步：展开 $\partial \ln Z / \partial \boldsymbol{\theta}$ 。利用 $\partial(\ln Z) / \partial \boldsymbol{\theta} = (1/Z) \partial Z / \partial \boldsymbol{\theta}$ ，先求 $\partial Z / \partial \boldsymbol{\theta}$ ：对 $Z(\boldsymbol{\theta}) = \sum_{\mathbf{x}'} e^{-E(\mathbf{x}'; \boldsymbol{\theta})}$ 逐项求导（链式法则， $\partial e^{-E(\mathbf{x}'; \boldsymbol{\theta})} / \partial \boldsymbol{\theta} = -\frac{\partial E(\mathbf{x}'; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} e^{-E(\mathbf{x}'; \boldsymbol{\theta})}$ ）：

$$\frac{\partial Z(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \sum_{\mathbf{x}'} \left(-\frac{\partial E(\mathbf{x}'; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right) e^{-E(\mathbf{x}'; \boldsymbol{\theta})}.$$

两边除以 Z ，并把 $e^{-E(\mathbf{x}'; \boldsymbol{\theta})} / Z = P(\mathbf{x}'; \boldsymbol{\theta})$ （式 (5.7)）代入求和式内部：

$$\frac{\partial \ln Z(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \frac{1}{Z} \frac{\partial Z}{\partial \boldsymbol{\theta}} = - \sum_{\mathbf{x}'} P(\mathbf{x}'; \boldsymbol{\theta}) \frac{\partial E(\mathbf{x}'; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = - \left\langle \frac{\partial E}{\partial \boldsymbol{\theta}} \right\rangle, \quad (5.9)$$

最后一步用到了期望值的定义（第二章“预备定义”）：对全部状态按概率加权求和即为期望 $\langle \cdot \rangle$ 。

第三步：代回式 (5.8)。把式 (5.9) 代入，注意其本身带一个负号，与式 (5.8) 中“ $-\partial \ln Z / \partial \boldsymbol{\theta}$ ”的负号相乘，两个负号抵消为正号：

$$\frac{\partial}{\partial \boldsymbol{\theta}} \ln P(\mathbf{x}; \boldsymbol{\theta}) = -\frac{\partial E(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} - \left(- \left\langle \frac{\partial E}{\partial \boldsymbol{\theta}} \right\rangle \right) = -\frac{\partial E(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} + \left\langle \frac{\partial E}{\partial \boldsymbol{\theta}} \right\rangle.$$

对数似然的梯度为

$$\boxed{\frac{\partial \ln P(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\frac{\partial E(\mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} + \left\langle \frac{\partial E}{\partial \boldsymbol{\theta}} \right\rangle}. \quad (5.10)$$

这一公式具有深刻的物理意义：第一项降低观测数据的能量（“正相位”，positive phase）；第二项提高全部状态的平均能量（“负相位”，negative phase）。计算第二项（期望）需要对全部可能状态求和或采样，这正是训练玻尔兹曼机的主要困难。

算例：用 $N = 2$ 伊辛链体会“正相位”与“负相位”

抽象的“正相位减负相位”究竟意味着什么，下面用 §2.3 的 $N = 2$ 伊辛链（ $h = 0$ ，单键 $E = -J s_1 s_2$ ）具体演算一遍。将耦合强度 J 当作待学习的参数 θ ，能量为 $E(s_1, s_2; J) = -J s_1 s_2$ ，因此 $\partial E / \partial J = -s_1 s_2$ 。代入式 (5.10)：

$$\frac{\partial \ln P}{\partial J} = s_1^{\text{data}} s_2^{\text{data}} - \langle s_1 s_2 \rangle_{\text{model}}.$$

$\langle s_1 s_2 \rangle_{\text{model}}$ 的直接推导。这个 $N = 2$ 系统只有两种“对齐方式”：同向（ $s_1 s_2 = +1$ ，对应状态 $(+, +)$ 与 $(-, -)$ ）与反向（ $s_1 s_2 = -1$ ，对应 $(+, -)$ 与 $(-, +)$ ）。按 §2.3 表 2.5 中已经算

出的玻尔兹曼权重，同向两个状态各权重 $e^{\beta J}$ ，反向两个状态各权重 $e^{-\beta J}$ ，故

$$\langle s_1 s_2 \rangle_{\text{model}} = \frac{(+1) \cdot 2e^{\beta J} + (-1) \cdot 2e^{-\beta J}}{2e^{\beta J} + 2e^{-\beta J}} = \frac{e^{\beta J} - e^{-\beta J}}{e^{\beta J} + e^{-\beta J}} = \tanh(\beta J).$$

(这一结果与 §2.3 中对无穷长周期链在热力学极限下导出的关联函数公式 (2.24) 在 $r = 1$ 时的取值恰好一致，但此处的 $N = 2$ 系统只有一条键、不涉及热力学极限，是直接对这个小系统求期望得到的精确结果——两条不同的推导路径在此重合，而非其中一个依赖于另一个。)

代入具体数字：设当前参数为 $J = 0.5$ ($\beta = 1$)，而观测到的数据恰为 $(s_1, s_2) = (+1, +1)$ (“正相位”贡献 $s_1^{\text{data}} s_2^{\text{data}} = 1$)：

$$\langle s_1 s_2 \rangle_{\text{model}} = \tanh(0.5) = 0.462 \quad (\text{“负相位”}),$$

$$\frac{\partial \ln P}{\partial J} = 1 - 0.462 = 0.538 > 0.$$

梯度为正，意味着增大 J 能提高观测数据的对数似然——这完全符合直觉：数据显示两个自旋是对齐的，而当前的 $J = 0.5$ 尚不足以让模型充分偏好对齐构型，因此学习算法会继续增大 J 。

这一过程何时停止？当梯度恰好为零，即“正相位”与“负相位”相等时：

$$s_1^{\text{data}} s_2^{\text{data}} = \langle s_1 s_2 \rangle_{\text{model}}.$$

若训练数据不止一个样本，而是多次观测的经验平均 $\langle s_1 s_2 \rangle_{\text{data}}$ ，收敛条件即为 $\tanh(\beta J^*) = \langle s_1 s_2 \rangle_{\text{data}}$ 。举一个具体的数：若数据中 $\langle s_1 s_2 \rangle_{\text{data}} = 0.6$ （相邻自旋对齐的次数明显多于不对齐），解得

$$\beta J^* = \operatorname{arctanh}(0.6) = \frac{1}{2} \ln \frac{1.6}{0.4} = \frac{1}{2} \ln 4 = \ln 2 \approx 0.693$$

(此处 $\operatorname{arctanh}(0.6) = \ln 2$ 是一个便于手算验证的巧合： $\tanh(\ln 2) = \frac{e^{\ln 2} - e^{-\ln 2}}{e^{\ln 2} + e^{-\ln 2}} = \frac{2 - 0.5}{2 + 0.5} = \frac{1.5}{2.5} = 0.6$ ，恰好吻合)。

■ 释疑

这是一个极其重要、将在后续讨论玻尔兹曼机的章节中反复出现的结论：**MRF 的最大似然解**，本质上是让模型预测的统计量（此处是自旋关联 $\langle s_1 s_2 \rangle$ ）精确匹配训练数据中的经验统计量，这被称为“矩匹配”（moment matching）。“正相位”来自真实数据，“负相位”来自模型自身生成的分布，训练过程就是不断调整参数，直至模型“想象”出的统计规律与数据中“实际观测”到的统计规律完全对齐。玻尔兹曼机训练之所以困难，正是因为“负相位”这一模型自身的期望值，对于复杂网络而言并没有解析公式（不像此处的 $\tanh(\beta J)$ 那样简洁），必须依靠采样来近似——这是后续讨论玻尔兹曼机训练的核心议题之一。

§5.4 近似方法概述

由于精确计算配分函数在一般情况下不可行，需要借助近似方法。这些方法在统计物理与机器学习中都有对应版本：

表 5.5: 配分函数近似方法：统计物理与机器学习的对应

方法	统计物理	机器学习
平均场近似	忽略涨落，用平均值代替	变分推断中的平均场近似
蒙特卡洛采样	Metropolis 算法、Gibbs 采样	MCMC、Gibbs 采样、HMC
变分方法	Bogoliubov 不等式	变分自编码器 (VAE)、变分贝叶斯
信念传播	Transfer matrix、Bethe 近似	Sum-product 算法、Loopy BP
重整化群	粗粒化、相变分析	深度学习的层次结构理解

平均场近似将在第六章系统展开；“蒙特卡洛采样”一行涉及的 MCMC、Gibbs 采样，其正确性依赖于马尔可夫链本身的一套理论——平稳分布、细致平衡、遍历性——这套理论本章不再展开，附录 C“马尔可夫链与 MCMC 基础”给出了理解这一行、以及本章习题中 Gibbs 采样实现题所需要的最小理论基础。

下一章将详细讨论变分方法。

■ 小结

配分函数 Z 在小规模问题上不过是几项求和（本章已反复手算过好几次），但状态数目会随变量个数指数增长，这使得精确计算 Z 对一般的、具有复杂环结构的高维图模型而言，在真实规模的问题上完全不可行。这一困难并非“算力不够”所能解决——即使动用全宇宙的计算资源，也数不完 $N = 100$ 时的 2^{100} 个状态。

需要强调的是，“一般不可行”不等于“处处不可行”：§5.2 已经看到，链状图（一维伊辛模型）借助转移矩阵可以把 Z 精确算到底，这并非偶然——但凡图的树宽（treewidth）较低（链、树本身都是树宽为 1 的特例），变量消元（variable elimination）/信念传播就能在多项式时间内精确求出 Z ；真正让配分函数变得棘手的，是图上出现大量环、树宽随系统尺寸一同增长的情形（例如二维及以上的伊辛模型、稠密的玻尔兹曼机），此时才没有已知的多项式算法。下文“近似方法”针对的正是这一类真正困难的情形。

配分函数之所以绕不开，是因为它同时控制着归一化、边缘概率，以及（通过“正相位减负相位”这一优雅的公式）参数学习的梯度。下一章将正面处理这一困难：通过引入变分自由能，把“精确计算 Z ”这一（对一般图而言）不可能的任务，替换为“寻找一个足够好的近似分布”这一可以优化求解的任务。

习题

基础题

习题 5.1: 更强耦合下的 $N = 3$ 开链伊辛模型

§5.2 中“边缘化”算例考察了 $N = 3$ 开链伊辛模型 ($J = 1$, $k_B T = 1$, 即 $\beta J = 1$, $h = 0$)。现在取更强的耦合 $\beta J = 2$ (其余设定不变), 重复同样的计算。

- 仿照表 5.3 的方式, 列出全部 $2^3 = 8$ 个微观状态 (s_1, s_2, s_3) 及其玻尔兹曼权重 $e^{\beta J(s_1 s_2 + s_2 s_3)}$;
- 求配分函数 Z , 并利用第二章开链公式 $Z_{\text{开链}}(N) = 2(2 \cosh(\beta J))^{N-1}$ 核对结果;
- 求边缘概率 $P(s_1 = +1)$ 与条件概率 $P(s_3 = +1 | s_1 = +1)$;
- 正文中 $\beta J = 1$ 时算出 $P(s_3 = +1 | s_1 = +1) = 0.790$ 。在耦合更强的 $\beta J = 2$ 下, 你预期这一条件概率会更接近 1 还是更接近 0.5? 先给出物理直觉上的预测, 再用 (c) 的结果验证。

习题 5.2: 树状图上的团与条件独立

考虑 5 个二值随机变量 A, B, C, D, E , 构成如下无向图: B 与 A, C, D 三点各有一条边相连; D 另外还与 E 有一条边相连 (即 $A-B-C$ 构成一条“分支”, $B-D-E$ 构成另一条“分支”, 整张图不含任何环)。

- 写出这张图的全部最大团 (§5.2 中团的定义);
- 按局部马尔可夫性质 (5.3): 给定 B 的全部邻居之后, A 与图中哪些变量条件独立? 给定 D 的全部邻居之后, E 与哪些变量条件独立?
- 利用全局马尔可夫性质中“分离”的概念 (§5.2“图论语言”一小节): $\{B, D\}$ 是否分离了 A 与 E ? 由此判断 $X_A \perp X_E | X_B, X_D$ 是否成立;
- 这张图不含任何环, 树宽为 1 (§5.4 小结中提到的概念)。即使 $A, \dots, E$ 每个变量能取的值很多 (比如 $K = 10$), 配分函数 Z 是否仍然可以精确计算? 为什么 (提示: §5.2“案例重访”中一维伊辛链的转移矩阵方法, 对树状图同样适用, 只是矩阵要沿着树的每条分支分别相乘)?

进阶题

习题 5.3: 同时学习耦合强度与外场

§5.3 中“正相位减负相位”的算例只处理了 $h = 0$ 、只学习耦合强度 J 的情形。现在考虑同一个 $N = 2$ 伊辛链, 但外场 $h \neq 0$, 能量为

$$E(s_1, s_2; J, h) = -J s_1 s_2 - h(s_1 + s_2),$$

把 J 和 h 同时当作待学习的参数。

- (a) 写出配分函数 $Z(J, h)$ (对全部 4 个状态 $(s_1, s_2) \in \{\pm 1\}^2$ 求和), 并求出 $\langle s_1 s_2 \rangle_{\text{model}}$ 与 $\langle s_1 + s_2 \rangle_{\text{model}}$ 关于 J, h 的表达式;
- (b) 利用式 (5.10) (对数似然梯度公式), 分别写出 $\partial \ln P / \partial J$ 与 $\partial \ln P / \partial h$ 的“正相位减负相位”表达式;
- (c) 设训练数据给出的经验统计量为 $\langle s_1 s_2 \rangle_{\text{data}} = 0.6$, $\langle s_1 + s_2 \rangle_{\text{data}} = 0.4$, 写出 (无需解出数值解, 只需列出) 确定最优 J^*, h^* 的自治方程组;
- (d) 讨论: 为什么这里得到的是一个方程组, 而不能像正文 $h = 0$ 的情形那样直接解出 J 的闭式解? 这对训练规模更大、参数更多的玻尔兹曼机意味着什么?

习题 5.4: 用具体数字验证 Hammersley–Clifford “容易方向”

§5.2 “证明思路”一段用一般性论证说明了“吉布斯分解 $\Rightarrow$ 局部马尔可夫性”这一方向; 本题用 $N = 3$ 开链伊辛模型 (§5.2 “算例: 三节点 MRF”, $\beta J = 1$, 表 5.3 中已经算出的权重) 把这个抽象论证落实成具体数字。

- (a) 利用表 5.3 中的权重, 计算 $P(s_1 = +1 \mid s_2 = +1, s_3 = +1)$ 与 $P(s_1 = +1 \mid s_2 = +1, s_3 = -1)$ 这两个条件概率的具体数值;
- (b) 比较 (a) 中的两个数值: 它们是否相等? 这说明了什么 (提示: 局部马尔可夫性质是否成立, 即 s_1 是否真的条件独立于 s_3 , 只要给定 s_2)?
- (c) 直接从能量函数 $E(s_1, s_2, s_3) = -J(s_1 s_2 + s_2 s_3)$ 出发, 用代数方法证明: 对任意固定的 s_3 , $P(s_1 \mid s_2, s_3)$ 都不依赖于 s_3 的取值 (提示: 把 $e^{-\beta E}$ 按 s_1 的依赖关系拆成两个因子, 找出哪个因子与 s_1 无关, 从而在条件概率的分子分母中被约去);
- (d) 把 (c) 中的代数操作, 和 “证明思路” Remark 中 “所有不包含节点 i 的团势函数都会在分子分母中完全约去” 这句话对应起来——这里 “不包含节点 s_1 的团势” 具体指的是哪一项?

挑战题

习题 5.5: Gibbs 采样与图像分割

§5.2 用一个简化的图像分割 MRF 模型 (数据项 + 平滑项) 说明了 MRF 在计算机视觉中的应用, 但没有给出如何实际求解这一模型。做本题前建议先阅读附录 C “马尔可夫链与 MCMC 基础”, 了解 “为什么反复采样最终会收敛到目标分布” 这一理论背景。

- (a) 实现: 编程实现 Gibbs 采样算法, 对正文定义的能量函数 $E(\mathbf{x}) = \sum_i \phi_i^{\text{data}}(x_i) + \sum_{(i,j)} \phi_{ij}^{\text{smooth}}(x_i, x_j)$, 逐个像素、按其条件概率 $P(x_i \mid \mathbf{x}_{-i})$ 采样更新, 反复迭代直至收敛;
- (b) 实验: 在一张简单的合成图像上测试你的实现 (例如白色圆形前景 + 黑色背景, 叠加

高斯噪声)，观察随迭代次数增加，分割结果如何从“完全由数据项主导的噪声”逐渐被“平滑项”正则化；

(c) 参数扫描：改变平滑项强度 λ ，讨论 λ 过大和过小分别会导致什么问题；

(d) 拓展阅读：§5.2 中“思考与验证”提到，Hammersley–Clifford 定理“局部 $\Rightarrow$ 全局”这一方向的证明依赖于分布处处为正这一条件，并提到 Moussouris (1974) 构造了一个反例。查阅资料，理解这个反例的构造思路，并说明它为什么恰好依赖于“某些构型概率为零”这一点。

自由能与损失函数的深层联系

By indirections find directions out.

—— 莎士比亚《哈姆雷特》第二幕第一场，波洛涅斯

学习目标

- 掌握变分自由能的推导，证明其为真实自由能的严格上界，并理解这一上界与 KL 散度之间的等价关系；
- 掌握机器学习中证据下界（ELBO）的推导，理解其与统计物理变分自由能在数学结构上的严格对应；
- 通过具体算例验证变分原理，理解“变分族越大、近似越精确”这一原则，以及变分下界的可靠性保证；
- 掌握平均场近似的推导与自洽方程，并通过一维伊辛模型的例子理解平均场近似在低维系统中可能给出定性错误结论的原因。

■ 本章导览

本章回答的问题：当配分函数无法精确计算时，物理学与机器学习各自独立发展出了同一种应对方法——变分推断。这两者真的是同一个数学定理吗？如果是，它们共享的核心证明是什么？

统计物理对应：变分自由能的上界 $F[Q] \geq F_{\text{true}}$ 与机器学习证据下界 ELBO 的不等式 $\mathcal{L}[Q] \leq \ln P(\mathbf{v})$ ，是同一个不等式的两种说法，共享同一个基于 KL 散度非负性的证明；平均场近似对应“变量间彼此独立”这一因子化假设，其推导方法是普通的拉格朗日乘数法，而非需要新工具的变分法（见 §6.4“预备说明”）。

后续预告：第七章将从最大熵原理的角度，再一次重新审视贯穿本书的玻尔兹曼分布——这是与本章变分论证平行的另一条独立推导路径，标志着第一部分理论框架的完成。

第5章表明，配分函数 Z 在真实规模的问题上不可能精确算出，边缘化与参数学习的梯度都因此陷入停滞。本章给出统计物理与机器学习共同采用的解决方案——变分方法：与其硬算 Z ，不如放弃“精确”，转而在一族容易处理的分布中，寻找一个“足够接近”真实分布的近

似。这一思路在物理中称为“变分自由能”，在机器学习中称为“证据下界”（Evidence Lower Bound, ELBO），二者实为同一数学定理在不同领域的两种称呼。

§6.1 变分自由能的物理推导

动机

当配分函数 $Z = \sum_{\mathbf{x}} e^{-\beta E(\mathbf{x})}$ 无法精确计算时，我们希望找到它的一个可计算的上界或下界。变分方法的核心思想是：引入一个简单的试探分布 $Q(\mathbf{x})$ ，通过优化 Q 来逼近真实分布 $P(\mathbf{x})$ 。

变分自由能的定义

对于试探分布 $Q(\mathbf{x})$ ，定义变分自由能：

$$F[Q] = \langle E(\mathbf{x}) \rangle_Q - TS[Q], \quad (6.1)$$

其中 $\langle E(\mathbf{x}) \rangle_Q = \sum_{\mathbf{x}} Q(\mathbf{x}) E(\mathbf{x})$ 是能量的期望值， $S[Q] = -k_B \sum_{\mathbf{x}} Q(\mathbf{x}) \ln Q(\mathbf{x})$ 是分布 Q 的熵（为简化记号，以下设 $k_B = 1$ ，即 $\beta = 1/T$ ）。

变分原理的证明

定理 6.1: 变分自由能是真实自由能的上界

对任意试探分布 $Q(\mathbf{x})$ ，

$$F[Q] \geq F_{\text{true}} = -T \ln Z,$$

等号成立当且仅当 $Q(\mathbf{x}) = P(\mathbf{x}) = \frac{1}{Z} e^{-E(\mathbf{x})/T}$ 。

证明. 在证明主定理之前，先证明一个将被反复使用的基础事实：**KL 散度非负**（*Gibbs 不等式*）。

■ 预备工具：Jensen 不等式与 Gibbs 不等式

若 f 是凸函数（即函数图像上任意两点连线都不低于函数本身，直观上“向上弯”），**Jensen 不等式**断言：对任意随机量 X ，

$$\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$$

（“先平均再取函数值”不小于“先取函数值再平均”，因为凸函数把“分散”的点向上抬）。
 $-\ln$ 是凸函数（ $(-\ln x)'' = 1/x^2 > 0$ ），故对 $-\ln$ 应用 Jensen 不等式， $\mathbb{E}[-\ln X] \geq -\ln \mathbb{E}[X]$ ，即 $\mathbb{E}[\ln X] \leq \ln \mathbb{E}[X]$ 。

利用这一点证明 $D_{KL}(Q\|P) = \sum_{\mathbf{x}} Q(\mathbf{x}) \ln \frac{Q(\mathbf{x})}{P(\mathbf{x})} \geq 0$ ：把求和写成关于分布 Q 的期望，令随机量 $X = P(\mathbf{x})/Q(\mathbf{x})$ （其中 $\mathbf{x}$ 按 Q 分布抽取），则

$$D_{KL}(Q\|P) = -\sum_{\mathbf{x}} Q(\mathbf{x}) \ln \frac{P(\mathbf{x})}{Q(\mathbf{x})} = -\mathbb{E}_Q[\ln X] \geq -\ln \mathbb{E}_Q[X],$$

其中最后一步用到了刚才由 *Jensen* 不等式导出的 $\mathbb{E}[\ln X] \leq \ln \mathbb{E}[X]$ 。而

$$\mathbb{E}_Q[X] = \sum_{\mathbf{x}} Q(\mathbf{x}) \cdot \frac{P(\mathbf{x})}{Q(\mathbf{x})} = \sum_{\mathbf{x}} P(\mathbf{x}) = 1,$$

(对 $\mathbf{x}$ 求和的项中 $Q(\mathbf{x})$ 恰好约去, 剩下 $P(\mathbf{x})$ 对全部状态求和, 按归一化等于 1), 故 $-\ln \mathbb{E}_Q[X] = -\ln 1 = 0$, 代入上式即得

$$D_{KL}(Q\|P) \geq 0,$$

等号成立当且仅当 *Jensen* 不等式取等号, 而这要求 $X = P(\mathbf{x})/Q(\mathbf{x})$ 对 Q 几乎处处为常数, 结合归一化 $\mathbb{E}_Q[X] = 1$ 可知该常数只能是 1, 即 $P(\mathbf{x}) = Q(\mathbf{x})$ (对一切使 $Q(\mathbf{x}) > 0$ 的 $\mathbf{x}$ 成立)。■

(本章末尾习题 “KL 散度的非负性” 要求读者独立重做一遍这一证明, 用于巩固。)

有了 $D_{KL}(Q\|P) \geq 0$ 这一工具, 现在证明主定理。定义 KL 散度

$$D_{KL}(Q\|P) = \sum_{\mathbf{x}} Q(\mathbf{x}) \ln \frac{Q(\mathbf{x})}{P(\mathbf{x})}. \quad (6.2)$$

将 $P(\mathbf{x}) = \frac{1}{Z} e^{-E(\mathbf{x})/T}$ 代入并展开:

$$\begin{aligned} D_{KL}(Q\|P) &= \sum_{\mathbf{x}} Q(\mathbf{x}) \ln \frac{Q(\mathbf{x})}{\frac{1}{Z} e^{-E(\mathbf{x})/T}} \\ &= \sum_{\mathbf{x}} Q(\mathbf{x}) \left[\ln Q(\mathbf{x}) - \ln \left(\frac{1}{Z} e^{-E(\mathbf{x})/T} \right) \right] \quad (\text{利用 } \ln(a/b) = \ln a - \ln b) \\ &= \sum_{\mathbf{x}} Q(\mathbf{x}) \left[\ln Q(\mathbf{x}) - \ln \frac{1}{Z} - \ln e^{-E(\mathbf{x})/T} \right] \quad (\text{再次利用 } \ln(ab) = \ln a + \ln b, \text{ 取负号}) \\ &= \sum_{\mathbf{x}} Q(\mathbf{x}) \left[\ln Q(\mathbf{x}) + \ln Z + \frac{E(\mathbf{x})}{T} \right] \quad (\text{利用 } \ln(1/Z) = -\ln Z \text{ 与 } \ln e^{-E/T} = -E/T) \\ &= \sum_{\mathbf{x}} Q(\mathbf{x}) \ln Q(\mathbf{x}) + \frac{1}{T} \sum_{\mathbf{x}} Q(\mathbf{x}) E(\mathbf{x}) + \ln Z \sum_{\mathbf{x}} Q(\mathbf{x}) \\ &= -S[Q] + \frac{1}{T} \langle E \rangle_Q + \ln Z. \end{aligned}$$

因此

$$D_{KL}(Q\|P) = \frac{1}{T} [\langle E \rangle_Q - TS[Q]] + \ln Z = \frac{1}{T} F[Q] + \ln Z.$$

由刚才证明的 $D_{KL}(Q\|P) \geq 0$, 得 $\frac{1}{T} F[Q] + \ln Z \geq 0$, 即

$$F[Q] \geq -T \ln Z = F_{true}. \quad \blacksquare$$

变分原理的意义:

1. $F[Q]$ 提供了真实自由能的一个上界;
2. 最小化 $F[Q]$ 等价于最小化 $D_{KL}(Q\|P)$, 即使 Q 逼近 P ;
3. 可以在一族简单分布中搜索最优的 Q , 从而绕过直接计算 Z 的困难。

算例：用双态系统验证变分原理

抽象的不等式 $F[Q] \geq F_{\text{true}}$ 究竟意味着什么，下面用 §2.2 的双态系统 ($E_0 = 0$, $E_1 = \varepsilon = 1$, $k_B T = 1$) 具体验证一遍。回忆当时算出的精确解：

$$P_0 = 0.731, \quad P_1 = 0.269, \quad F_{\text{true}} = -T \ln Z = -0.313.$$

现在，假设不知道精确解，只允许在一族简单的变分分布中搜索：取 $Q(0) = q$, $Q(1) = 1 - q$ ($q \in (0, 1)$ 是唯一的变分参数)，代入定义直接计算

$$F[Q] = \langle E \rangle_Q - TS[Q] = (1 - q)\varepsilon - T[-q \ln q - (1 - q) \ln(1 - q)] :$$

表 6.1: 双态系统变分算例：不同 q 下的 $F[Q]$ 与 D_{KL}

q	$\langle E \rangle_Q$	$S[Q]$	$F[Q]$	$D_{KL}(Q \ P) = F[Q] - F_{\text{true}}$
0.300	0.700	0.611	0.089	0.402
0.500	0.500	0.693	-0.193	0.120
0.600	0.400	0.673	-0.273	0.040
0.700	0.300	0.611	-0.311	0.002
0.731	0.269	0.582	-0.313	0.000
0.800	0.200	0.500	-0.300	0.013
0.900	0.100	0.325	-0.225	0.088

表 6.1 把“变分自由能是真实自由能的上界”这句话变成了看得见的数字：无论 q 取何值， $F[Q]$ 都不小于 -0.313 ；而当 q 恰好取到精确解 $P_0 = 0.731$ 时， $F[Q]$ 精确“触底”，等于 F_{true} ，对应的 KL 散度归零。换言之，“在变分族中最小化 $F[Q]$ ”这一操作，若做得足够彻底（搜遍所有可能的 q ），最终会自动找回精确解——这是因为此处的变分族 $\{Q(0) = q, Q(1) = 1 - q : q \in (0, 1)\}$ 恰好覆盖了双态系统全部可能的分布，没有做任何近似简化。

■ 释疑

在真实应用中（例如 §6.4），变分族通常达不到这么“充分”——我们会人为限制 Q 的形式（例如强制要求不同变量之间相互独立），此时最优的 Q^* 就不再能精确等于 P ， $D_{KL}(Q^* \| P) > 0$ 会成为一个无法消除的“近似误差”。但无论变分族多受限， $F[Q] \geq F_{\text{true}}$ 这一不等式永远成立——这正是变分方法作为一种“有质量保证的近似”方法的可靠之处：也许不知道 F_{true} 具体是多少，但可以确切地知道 $F[Q]$ 给出的答案不会比真实值更“乐观”。

■ 思考与验证

表 6.1 中 $q = 0.5$ (即假设两个状态等概率) 给出 $F[Q] = -0.193$ ，明显大于 $F_{\text{true}} = -0.313$ 。这一“过高估计”主要是因为 $q = 0.5$ 时能量期望 $\langle E \rangle_Q$ 偏高，还是熵 $S[Q]$ 偏低？

解：对比 $q = 0.5$ 与 $q = 0.731$ 两行——熵其实是 $q = 0.5$ 更高 ($0.693 > 0.582$ ，均匀分布

的熵本来就最大), 真正“吃亏”的是能量: $q = 0.5$ 给激发态分配了过多概率 ($1 - q = 0.5$, 而真实的 P_1 只有 0.269), 导致 $\langle E \rangle_Q = 0.5$ 远高于真实的 0.269。这说明 $F[Q]$ 的误差不仅可能来自熵不够“集中”, 能量项估计不准同样是重要的误差来源, 具体哪一项占主导需要具体问题具体分析。

§6.2 机器学习中的变分推断

问题设定

在机器学习中, 我们常常面对包含隐变量的模型。设 $\mathbf{v}$ 为可见变量 (观测数据), $\mathbf{h}$ 为隐变量 (潜在结构), θ 为模型参数, 联合概率为 $P(\mathbf{v}, \mathbf{h}; \theta)$ 。目标有二: 推断——给定 $\mathbf{v}$, 计算后验 $P(\mathbf{h}|\mathbf{v}; \theta)$; 学习——根据数据 $\{\mathbf{v}^{(n)}\}$ 估计参数 θ 。两者都涉及边缘化:

$$P(\mathbf{v}; \theta) = \sum_{\mathbf{h}} P(\mathbf{v}, \mathbf{h}; \theta),$$

这一求和通常难以计算, 其困难与配分函数的计算困难同源。

证据下界 (ELBO)

引入变分分布 $Q(\mathbf{h})$ 来近似后验 $P(\mathbf{h}|\mathbf{v})$ 。定义证据下界 (Evidence Lower BOund, ELBO):

$$\mathcal{L}[Q] = \sum_{\mathbf{h}} Q(\mathbf{h}) \ln \frac{P(\mathbf{v}, \mathbf{h})}{Q(\mathbf{h})}. \quad (6.3)$$

■ 记号提醒: $\mathcal{L}$ 的第三重含义

第三章用 $\mathcal{L}$ 表示似然函数 (越大越好); 第四章用同一个符号表示损失函数 (负对数似然, 越小越好, 两章已经在那里提醒过一次)。这里的 $\mathcal{L}[Q]$ 是第三种、完全独立的含义——证据下界, 同样是越大越好, 但它是变分分布 Q 的泛函, 而非某个点的函数值。三者字母相同, 仅因为都源自 “likelihood/loss” 的首字母习惯, 并无更深的数学联系; 请始终以方括号 $\mathcal{L}[\cdot]$ (本节记号) 与圆括号 $\mathcal{L}(\cdot)$ (第三、四章记号) 加以区分。

展开:

$$\begin{aligned} \mathcal{L}[Q] &= \sum_{\mathbf{h}} Q(\mathbf{h}) [\ln P(\mathbf{v}, \mathbf{h}) - \ln Q(\mathbf{h})] \\ &= \sum_{\mathbf{h}} Q(\mathbf{h}) \ln P(\mathbf{v}, \mathbf{h}) + H[Q(\mathbf{h})], \end{aligned}$$

其中 $H[Q] = -\sum_{\mathbf{h}} Q(\mathbf{h}) \ln Q(\mathbf{h})$ 是熵。

ELBO 与对数证据的关系

定理 6.2: ELBO 是对数证据的下界

对任意变分分布 $Q(\mathbf{h})$,

$$\mathcal{L}[Q] \leq \ln P(\mathbf{v}),$$

等号成立当且仅当 $Q(\mathbf{h}) = P(\mathbf{h}|\mathbf{v})$ 。

证明. 首先证明恒等式

$$\ln P(\mathbf{v}) = \mathcal{L}[Q] + D_{KL}(Q(\mathbf{h}) \| P(\mathbf{h}|\mathbf{v})). \quad (6.4)$$

由定义 (6.3):

$$\begin{aligned} \mathcal{L}[Q] &= \sum_{\mathbf{h}} Q(\mathbf{h}) \ln \frac{P(\mathbf{v}, \mathbf{h})}{Q(\mathbf{h})} \\ &= \sum_{\mathbf{h}} Q(\mathbf{h}) \ln \frac{P(\mathbf{h}|\mathbf{v})P(\mathbf{v})}{Q(\mathbf{h})} \quad (\text{第三章“预备定义”: 条件概率 } P(\mathbf{h}|\mathbf{v}) = P(\mathbf{v}, \mathbf{h})/P(\mathbf{v}) \text{ 给出 } P(\mathbf{v}, \mathbf{h}) = P(\mathbf{h}|\mathbf{v})P(\mathbf{v})) \\ &= \sum_{\mathbf{h}} Q(\mathbf{h}) [\ln P(\mathbf{v}) + \ln P(\mathbf{h}|\mathbf{v}) - \ln Q(\mathbf{h})] \\ &= \ln P(\mathbf{v}) \sum_{\mathbf{h}} Q(\mathbf{h}) + \sum_{\mathbf{h}} Q(\mathbf{h}) \ln \frac{P(\mathbf{h}|\mathbf{v})}{Q(\mathbf{h})} \\ &= \ln P(\mathbf{v}) - D_{KL}(Q(\mathbf{h}) \| P(\mathbf{h}|\mathbf{v})), \end{aligned}$$

最后一步用到了 $Q(\mathbf{h})$ 作为概率分布满足归一化 $\sum_{\mathbf{h}} Q(\mathbf{h}) = 1$, 故第一项中 $\ln P(\mathbf{v}) \sum_{\mathbf{h}} Q(\mathbf{h}) = \ln P(\mathbf{v}) \cdot 1 = \ln P(\mathbf{v})$, 直接给出常数项; 第二项则恰为 KL 散度定义 (6.2) 的负号形式。整理即得式 (6.4)。由 $D_{KL} \geq 0$ (已在 §6.1 中证明), 立即得到 $\mathcal{L}[Q] \leq \ln P(\mathbf{v})$ 。 ■

变分推断的策略:

1. 推断: 给定模型参数 θ 和数据 $\mathbf{v}$, 在变分族 $\mathcal{Q}$ 中寻找最优的 Q^* :

$$Q^*(\mathbf{h}) = \arg \max_{Q \in \mathcal{Q}} \mathcal{L}[Q];$$

2. 学习: 最大化 ELBO 关于参数 θ 的期望:

$$\theta^* = \arg \max_{\theta} \sum_n \mathcal{L}[Q^{(n)}],$$

其中 $Q^{(n)}$ 是针对数据点 $\mathbf{v}^{(n)}$ 的变分分布。

■ 思考与验证

对照恒等式 (6.4): 若某次训练中 ELBO $\mathcal{L}[Q]$ 一直在上升, 能否说明真实的对数似然 $\ln P(\mathbf{v})$ (真正想要最大化的量) 也一定在上升?

解: 不一定。式 (6.4) 是一个恒等式, $\ln P(\mathbf{v})$ 本身不随 Q 变化 (Q 只是引入的辅助变分分布), 因此固定参数 θ 、仅优化 Q 时, ELBO 上升只能说明 D_{KL} 在下降 (Q 越来越接

近真实后验), $\ln P(\mathbf{v})$ 本身不变。

若同时优化 θ , 情况需要更小心: 一般地, 从 $(Q_{\text{old}}, \theta_{\text{old}})$ 变到 $(Q_{\text{new}}, \theta_{\text{new}})$ 使 $\mathcal{L}[Q_{\text{new}}, \theta_{\text{new}}] > \mathcal{L}[Q_{\text{old}}, \theta_{\text{old}}]$, 并不能单独推出 $\ln P(\mathbf{v}; \theta_{\text{new}}) \geq \ln P(\mathbf{v}; \theta_{\text{old}})$ ——因为 $D_{KL}(Q \| P(\mathbf{h}|\mathbf{v}; \theta))$ 这个间隙本身也会随 θ 一起改变, ELBO 的增量有可能只是把间隙填大了, 而不是把 $\ln P(\mathbf{v})$ 抬高了。

真正能保证单调性的, 是标准 EM 算法的特定操作顺序:

1. **E 步**: 将 Q 设为当前参数下的精确后验, $Q_{\text{new}}(\mathbf{h}) = P(\mathbf{h} | \mathbf{v}; \theta_{\text{old}})$ ——此时式 (6.4) 中的 KL 间隙恰好为零, 即 $\mathcal{L}[Q_{\text{new}}, \theta_{\text{old}}] = \ln P(\mathbf{v}; \theta_{\text{old}})$ (间隙填满);

2. **M 步**: 固定这个 Q_{new} , 对 θ 做精确的 ELBO 最大化, $\theta_{\text{new}} = \arg \max_{\theta} \mathcal{L}[Q_{\text{new}}, \theta]$ 。

此时才有 $\ln P(\mathbf{v}; \theta_{\text{new}}) \geq \mathcal{L}[Q_{\text{new}}, \theta_{\text{new}}] \geq \mathcal{L}[Q_{\text{new}}, \theta_{\text{old}}] = \ln P(\mathbf{v}; \theta_{\text{old}})$ (第一步用式 (6.4) 与 $D_{KL} \geq 0$, 第二步用 M 步的最大化性质), 从而严格证明证据不会下降。这正是 §6.2 “学习” 这一步理论基础的精确版本: 只有当 Q 在每一步都被重新设为精确后验时, ELBO 上升才自动保证证据不下降; 若只做近似 E 步 (Q 停留在某个变分族内、并非精确后验), 则单调性不再是自动的数学结论, 而需要针对具体变分族另行分析。

§6.3 物理—机器学习对应表

将统计物理的变分自由能与机器学习的 ELBO 明确对比——这也正式填上了第二章种子表 (表 2.8) 中 “自由能” 一行, 以及 “熵” 一行的前半部分 (另一半留给第七章的最大熵原理):

表 6.2: 变分自由能与 ELBO 的对应关系——为第二章表 2.8 填上 “自由能” 一行

统计物理	机器学习
真实分布 $P(\mathbf{x}) = \frac{1}{Z} e^{-\beta E(\mathbf{x})}$	后验分布 $P(\mathbf{h} \mathbf{v})$
试探分布 $Q(\mathbf{x})$	变分分布 $Q(\mathbf{h})$
变分自由能 $F[Q] = \langle E \rangle_Q - TS[Q]$	负 ELBO $-\mathcal{L}[Q] = -\langle \ln P(\mathbf{v}, \mathbf{h}) \rangle_Q - H[Q]$
能量 $E(\mathbf{x})$	负对数联合概率 $-\ln P(\mathbf{v}, \mathbf{h})$
熵 $S[Q]$	熵 $H[Q]$
最小化 $F[Q]$	最大化 $\mathcal{L}[Q]$
$F[Q] \geq -T \ln Z$	$\mathcal{L}[Q] \leq \ln P(\mathbf{v})$
KL 散度 $D_{KL}(Q \ P) = [F[Q] - F_{\text{true}}]/T$	KL 散度 $D_{KL}(Q \ P(\cdot \mathbf{v})) = \ln P(\mathbf{v}) - \mathcal{L}[Q]$

核心洞察:

$$\boxed{\text{最小化自由能 (物理)} \iff \text{最大化 ELBO (学习)}} \quad (6.5)$$

这不仅是数学上的类比, 而是同一个变分原理在不同领域中的应用。

§6.4 平均场近似

平均场理论是变分方法的一个重要特例，在统计物理与机器学习中都被广泛使用。

平均场假设

假设变分分布可以因子分解为独立的单变量分布：

$$Q(\mathbf{x}) = \prod_{i=1}^N Q_i(x_i). \quad (6.6)$$

这一假设忽略了变量之间的相关性，但大大简化了计算。

平均场方程的推导

目标是最小化变分自由能（或最大化 ELBO），约束条件是每个 Q_i 归一化：

$$\min_{Q_1, \dots, Q_N} F[Q] \quad \text{s.t.} \quad \sum_{x_i} Q_i(x_i) = 1, \forall i.$$

■ 预备说明：这其实是一个普通的拉格朗日乘数法问题

乍看之下，“对函数 $Q_i(\cdot)$ 求变分”像是需要变分法（泛函分析）这类新工具。但只要 x_i 取值于一个有限集合（例如 $x_i \in \{1, \dots, K\}$ ，本书中始终如此——自旋 ± 1 、类别标签等）， Q_i 就根本不是一个“抽象的函数”，而只是 K 个实数 $Q_i(1), \dots, Q_i(K)$ 排成的一个向量，唯一的约束是它们之和为 1。“对 $Q_i(\cdot)$ 求变分并令其为零”，因此就是普通微积分中对有限多个实变量、在一个约束下求极值的问题——与《高等数学》或《经典力学》中“周长固定，求矩形面积最大”这类带约束极值问题、或处理完整约束时用到的拉格朗日乘数法，是完全相同的技巧，只是变量个数从 2 个变成了 K 个。下面全部使用普通的偏导数记号 $\partial/\partial Q_i(x_i)$ ，不引入任何新概念。

这里还需要一个贯穿始终的关键事实：由于 $Q_i(1), \dots, Q_i(K)$ 是 K 个相互独立的实变量（如同直角坐标系中 K 个独立的坐标轴），

$$\frac{\partial Q_i(x'_i)}{\partial Q_i(k)} = \delta_{x'_i, k} = \begin{cases} 1 & x'_i = k, \\ 0 & x'_i \neq k, \end{cases}$$

即：只有当 x'_i 恰好取到我们正在对其求导的那个值 k 时，导数才不为零。这与多元函数中 $\partial y_a / \partial y_b = \delta_{ab}$ 是同一件事。

固定其他所有 Q_j ($j \neq i$)，只把 $Q_i(1), \dots, Q_i(K)$ 看作待求的 K 个实变量，构造拉格朗日函数

$$\Lambda = \mathcal{L}[Q] + \mu_i \left(\sum_{k=1}^K Q_i(k) - 1 \right),$$

其中 μ_i 是对应归一化约束的拉格朗日乘数， $\mathcal{L}[Q]$ 是与自由能等价（相差一个常数与符号）的

ELBO 形式的目标函数:

$$\mathcal{L}[Q] = \sum_{\mathbf{x}} Q(\mathbf{x}) \ln P(\mathbf{x}) + \sum_{\mathbf{x}} Q(\mathbf{x}) \ln Q(\mathbf{x})^{-1} = \sum_{\mathbf{x}} Q(\mathbf{x}) \ln P(\mathbf{x}) - \sum_{\mathbf{x}} Q(\mathbf{x}) \ln Q(\mathbf{x}),$$

这里第二项用到 $\ln Q(\mathbf{x})^{-1} = -\ln Q(\mathbf{x})$ 。又由 $Q(\mathbf{x}) = \prod_j Q_j(x_j)$ 可知 $\ln Q(\mathbf{x}) = \sum_j \ln Q_j(x_j)$ (乘积的对数等于对数之和), 故上式中第二项就是分布 $Q(\mathbf{x})$ 自身的负熵, 无需另外展开成 $\sum_k \ln Q_k(x_k)$ 的形式。

下面对固定的 $k \in \{1, \dots, K\}$, 逐项计算 $\partial \Lambda / \partial Q_i(k)$, 令其为零。

第一项 (能量项) $\sum_{\mathbf{x}} Q(\mathbf{x}) \ln P(\mathbf{x})$ 的导数。利用乘积法则和 $Q(\mathbf{x}) = Q_i(x_i) \prod_{j \neq i} Q_j(x_j)$:

$$\frac{\partial Q(\mathbf{x})}{\partial Q_i(k)} = \frac{\partial Q_i(x_i)}{\partial Q_i(k)} \prod_{j \neq i} Q_j(x_j) = \delta_{x_i, k} \prod_{j \neq i} Q_j(x_j)$$

(其余因子 $Q_j(x_j)$ ($j \neq i$) 不依赖于 $Q_i(k)$, 求导为零; 上面用到了“预备说明”中的关键事实)。于是对全部 $\mathbf{x}$ 求和时, $\delta_{x_i, k}$ 把 x_i 的求和“筛选”为只剩 $x_i = k$ 这一项, 其余变量 $\mathbf{x}_{-i}$ 照常求和:

$$\frac{\partial}{\partial Q_i(k)} \sum_{\mathbf{x}} Q(\mathbf{x}) \ln P(\mathbf{x}) = \sum_{\mathbf{x}_{-i}} \left[\prod_{j \neq i} Q_j(x_j) \right] \ln P(x_i=k, \mathbf{x}_{-i}). \quad (6.7)$$

第二项 (熵项) $-\sum_{\mathbf{x}} Q(\mathbf{x}) \ln Q(\mathbf{x})$ 的导数。这一项比第一项多一层复杂性: $Q_i(k)$ 同时出现在权重 $Q(\mathbf{x})$ 和对数 $\ln Q(\mathbf{x})$ 之中, 须用乘积法则展开为两部分:

$$\begin{aligned} \frac{\partial}{\partial Q_i(k)} [Q(\mathbf{x}) \ln Q(\mathbf{x})] &= \underbrace{\frac{\partial Q(\mathbf{x})}{\partial Q_i(k)}}_{=\delta_{x_i, k} \prod_{j \neq i} Q_j(x_j)} \ln Q(\mathbf{x}) + Q(\mathbf{x}) \cdot \underbrace{\frac{\partial \ln Q(\mathbf{x})}{\partial Q_i(k)}}_{=\frac{1}{Q(\mathbf{x})} \frac{\partial Q(\mathbf{x})}{\partial Q_i(k)}} \\ &= \delta_{x_i, k} \left[\prod_{j \neq i} Q_j(x_j) \right] \ln Q(\mathbf{x}) + \delta_{x_i, k} \prod_{j \neq i} Q_j(x_j) \\ &= \delta_{x_i, k} \left[\prod_{j \neq i} Q_j(x_j) \right] [\ln Q(\mathbf{x}) + 1]. \end{aligned}$$

对全部 $\mathbf{x}$ 求和, $\delta_{x_i, k}$ 同样把 x_i 筛选为 k :

$$\frac{\partial}{\partial Q_i(k)} \sum_{\mathbf{x}} Q(\mathbf{x}) \ln Q(\mathbf{x}) = \sum_{\mathbf{x}_{-i}} \left[\prod_{j \neq i} Q_j(x_j) \right] [\ln Q(x_i=k, \mathbf{x}_{-i}) + 1].$$

再用 $\ln Q(x_i=k, \mathbf{x}_{-i}) = \ln Q_i(k) + \sum_{j \neq i} \ln Q_j(x_j)$ (还是“乘积的对数等于对数之和”) 展开中括号:

$$\begin{aligned} &= \ln Q_i(k) \underbrace{\sum_{\mathbf{x}_{-i}} \prod_{j \neq i} Q_j(x_j)}_{=1} + \underbrace{\sum_{\mathbf{x}_{-i}} \left[\prod_{j \neq i} Q_j(x_j) \right] \sum_{j \neq i} \ln Q_j(x_j)}_{\equiv C \text{ (与 } k \text{ 无关的常数)}} + \underbrace{\sum_{\mathbf{x}_{-i}} \prod_{j \neq i} Q_j(x_j)}_{=1} \\ &= \ln Q_i(k) + C + 1. \end{aligned}$$

上面用到了每个 Q_j ($j \neq i$) 各自归一化 ($\sum_{x_j} Q_j(x_j) = 1$), 故它们的乘积对全部 $\mathbf{x}_{-i}$ 求和等于 1 (这是若干个独立归一化分布的乘积求和为 1 这一事实的直接推广: 两个变量时 $\sum_{x_j, x_l} Q_j(x_j) Q_l(x_l) = [\sum_{x_j} Q_j(x_j)] [\sum_{x_l} Q_l(x_l)] = 1 \times 1 = 1$, 更多变量时同理); 而

$C = \sum_{\mathbf{x}_{-i}} [\prod_{j \neq i} Q_j(x_j)] \sum_{j \neq i} \ln Q_j(x_j)$ 完全不依赖于 k (求和已经把 x_i 积掉, k 无处出现), 是一个纯粹的常数——这正是原本 “+const” 一句话背后的确切来源。

合并三项, 令 $\partial \Lambda / \partial Q_i(k) = 0$ 。把能量项 (6.7)、熵项 (带负号) 与约束项 μ_i 相加:

$$\sum_{\mathbf{x}_{-i}} \left[\prod_{j \neq i} Q_j(x_j) \right] \ln P(x_i=k, \mathbf{x}_{-i}) - [\ln Q_i(k) + C + 1] + \mu_i = 0.$$

解出 $\ln Q_i(k)$:

$$\ln Q_i(k) = \sum_{\mathbf{x}_{-i}} \left[\prod_{j \neq i} Q_j(x_j) \right] \ln P(x_i=k, \mathbf{x}_{-i}) + \underbrace{(\mu_i - C - 1)}_{\text{与 } k \text{ 无关的常数}}.$$

两边取指数, 与 k 无关的常数项 $e^{\mu_i - C - 1}$ 整体地变成比例系数 (其数值由归一化条件 $\sum_k Q_i(k) = 1$ 事后确定, 无需单独求解 μ_i):

$$Q_i(k) \propto \exp \left(\sum_{\mathbf{x}_{-i}} \left[\prod_{j \neq i} Q_j(x_j) \right] \ln P(x_i=k, \mathbf{x}_{-i}) \right).$$

右边指数中的求和, 按第二章 “预备定义” 给出的期望值记号, 恰好就是 $\ln P(\mathbf{x})$ 关于 “除 x_i 外全部变量、按各自的 Q_j 独立分布” 这一联合分布的期望值。把 k 换回一般记号 x_i , 即得最优的 Q_i^* :

$$Q_i^*(x_i) \propto \exp \left(\mathbb{E}_{\prod_{j \neq i} Q_j} [\ln P(\mathbf{x})] \right). \quad (6.8)$$

物理解释: 每个变量 x_i 感受到来自其他所有变量的 “平均场”, $Q_i(x_i)$ 正是这一平均场中的玻尔兹曼分布。

迭代求解

平均场方程是耦合的: Q_i 依赖于全部 Q_j ($j \neq i$), 需通过迭代求解:

1. 初始化全部 Q_i (例如取均匀分布);
2. 重复直到收敛: 对每个 i , 固定其他 Q_j ($j \neq i$), 更新 Q_i ;
3. 输出最终的 $Q = \prod_i Q_i$ 。

这一过程类似于坐标下降 (coordinate descent) 算法。

例子: 伊辛模型的平均场解

考虑外磁场中的伊辛模型:

$$E(\{s_i\}) = -J \sum_{\langle i, j \rangle} s_i s_j - h \sum_i s_i.$$

平均场近似下, 假设 $Q(\{s_i\}) = \prod_i Q_i(s_i)$, 并定义每个自旋的磁化 $m_i = \langle s_i \rangle_{Q_i}$ 。下面把一般公式 (6.8) 代入这个具体的能量函数, 推导出 Q_i^* 的显式形式。

第一步: 写出 $\ln P(\mathbf{s})$ 中依赖于 s_i 的部分。由 $P(\mathbf{s}) = e^{-\beta E(\mathbf{s})} / Z$, $\ln P(\mathbf{s}) = -\beta E(\mathbf{s}) - \ln Z = \beta J \sum_{\langle k, l \rangle} s_k s_l + \beta h \sum_k s_k - \ln Z$ 。耦合项 $\sum_{\langle k, l \rangle} s_k s_l$ 中, 含有 s_i 的项恰好是 s_i 与它的每一个

近邻 $j \in \mathcal{N}(i)$ 各配对一次，即 $s_i \sum_{j \in \mathcal{N}(i)} s_j$ ；外场项中含 s_i 的部分是 $h s_i$ 。把不含 s_i 的项统一归入常数（对 s_i 求期望时不受影响），得到

$$\ln P(\mathbf{s}) = \beta s_i \left[J \sum_{j \in \mathcal{N}(i)} s_j + h \right] + (\text{不含 } s_i \text{ 的项}).$$

第二步：对除 s_i 外的全部自旋取期望。按公式 (6.8)，需要计算 $\mathbb{E}_{\prod_{j \neq i} Q_j}[\ln P(\mathbf{s})]$ ，即对上式中每个 s_j ($j \neq i$) 分别按其平均场分布 Q_j 求期望。期望是线性运算，直接把每个 s_j 换成它的期望值 $\langle s_j \rangle_{Q_j} = m_j$ （“不含 s_i 的项”作为一个整体常数，求期望后仍是与 s_i 无关的常数）：

$$\mathbb{E}_{\prod_{j \neq i} Q_j}[\ln P(\mathbf{s})] = \beta s_i \left[J \sum_{j \in \mathcal{N}(i)} m_j + h \right] + \text{const} = \beta s_i h_i^{\text{eff}} + \text{const},$$

其中定义了有效场

$$h_i^{\text{eff}} = h + J \sum_{j \in \mathcal{N}(i)} m_j, \quad (6.9)$$

即每个自旋 i 实际感受到的“场”，是外场 h 与全部近邻磁化 m_j 通过耦合 J 贡献的“平均”内场之和——这正是“平均场”这一名称的来源：真实的近邻涨落被替换成了它们各自的平均值 m_j 。

第三步：代入公式 (6.8)，识别出双态系统。于是

$$Q_i^*(s_i) \propto \exp(\beta s_i h_i^{\text{eff}}), \quad s_i = \pm 1,$$

这正是 §2.2 中“双态系统”（此处两个态是 $s_i = +1$ 与 $s_i = -1$ ，能量差由 $-h_i^{\text{eff}}$ 与 $+h_i^{\text{eff}}$ 给出）与第五章 $N = 2$ 伊辛链算例中已经反复处理过的形式：一个自旋处于“等效外场” h_i^{eff} 中的玻尔兹曼分布。归一化后

$$Q_i^*(s_i = +1) = \frac{e^{\beta h_i^{\text{eff}}}}{e^{\beta h_i^{\text{eff}}} + e^{-\beta h_i^{\text{eff}}}}, \quad Q_i^*(s_i = -1) = \frac{e^{-\beta h_i^{\text{eff}}}}{e^{\beta h_i^{\text{eff}}} + e^{-\beta h_i^{\text{eff}}}}.$$

按第五章推导 $\langle s_1 s_2 \rangle_{\text{model}} = \tanh(\beta J)$ 时完全相同的计算（把 J 换成 h_i^{eff} ），磁化为

$$m_i = \langle s_i \rangle_{Q_i^*} = (+1)Q_i^*(+1) + (-1)Q_i^*(-1) = \frac{e^{\beta h_i^{\text{eff}}} - e^{-\beta h_i^{\text{eff}}}}{e^{\beta h_i^{\text{eff}}} + e^{-\beta h_i^{\text{eff}}}} = \tanh(\beta h_i^{\text{eff}}).$$

在均匀系统中（全部 m_i 相同），记 $m_i = m$ ，则式 (6.9) 中 $h^{\text{eff}} = h + z J m$ ($z = |\mathcal{N}(i)|$ 是每个自旋的近邻数，对均匀系统每个近邻的 m_j 都等于同一个 m ，故 $\sum_{j \in \mathcal{N}(i)} m_j = z m$)。于是 $m_i = \tanh(\beta h_i^{\text{eff}})$ 本身又依赖于 m （通过 h^{eff} ），给出自洽方程：

$$m = \tanh(\beta h^{\text{eff}}) = \tanh[\beta(h + z J m)]. \quad (6.10)$$

称其为“自洽”，是因为等式两边都含有待求的 m ： m 一方面决定了有效场 h^{eff} ，另一方面又是这个有效场下双态系统给出的磁化，必须同时满足这两重身份。

相变。在 $h = 0$ 时，方程简化为 $m = \tanh(\beta z J m)$ ：高温 ($\beta z J < 1$) 时只有平凡解 $m = 0$ ；低温 ($\beta z J > 1$) 时出现非零解 $m \neq 0$ （自发磁化）。临界温度为

$$T_c = \frac{zJ}{k_B}. \quad (6.11)$$

这是平均场理论预测的相变点。虽不精确（忽略了涨落），但捕捉了相变的本质。

算例：数值求解自洽方程

取一维链的配位数 $z = 2$ (每个自旋恰有左右两个近邻)、 $J = 1$, 平均场理论预测 $T_c = zJ = 2$ 。自洽方程 $m = \tanh(\beta z J m) = \tanh(2m/T)$ 可用不动点迭代直接数值求解：任取一个初始猜测 m_0 , 反复代入 $m_{n+1} = \tanh(2m_n/T)$, 直至数值不再变化。结果如下：

表 6.3: 一维链平均场自洽方程的数值解 ($z = 2, J = 1$)

T	$\beta z J = 2/T$	迭代收敛到的 m
3.0	0.667	0.000
2.5	0.800	0.000
1.5	1.333	0.776
1.0	2.000	0.958
0.5	4.000	0.999

数值结果与前述判据完全吻合： $T > T_c = 2$ 时，无论初始猜测为何，迭代总是收敛回 $m = 0$ (顺磁相，无自发磁化)； $T < T_c$ 时，迭代收敛到一个非零的 m ，且 T 越低磁化越接近饱和值 1 (铁磁相，自旋几乎全部排齐)。

平均场理论在一维为何失效

这里有一处非常值得深究之处。平均场理论对这里所取的一维链 ($z = 2$) 给出了一个明确的有限温度相变： $T_c = 2$ 。但 §2.3 已用转移矩阵精确求解过一维伊辛链，结论是关联长度 $\xi(T)$ (式 (2.25)) 在任何有限温度下都是有限的，只有当 $T \rightarrow 0$ 时才发散——也就是说，一维伊辛链在任何有限温度下都不存在真正的相变！平均场理论在此处的预测与精确解定性不一致。

问题出在哪里？回顾平均场近似的核心假设 $Q(\{s_i\}) = \prod_i Q_i(s_i)$ ：它把每个自旋当作独立变量处理，用“周围自旋的平均磁化”这一数值代替“周围自旋的真实涨落”，这本质上抹去了涨落对系统的破坏作用。在高维度 (例如三维晶格， $z = 6$)，每个自旋有较多近邻，涨落的破坏效果会被“多个近邻共同分摊”而相对削弱，因此平均场理论在高维通常给出定性正确、定量粗糙的预测；但在一维 ($z = 2$, 近邻最少)，涨落效应强大到足以摧毁任何有限温度下的长程有序——这一物理效应，恰恰被平均场近似完全忽略。

■ 小结

这是理解一切近似方法都应牢记的一课：变分方法保证的是 $F[Q] \geq F_{\text{true}}$ 这一不等式方向上的严格性，但并不保证近似解在定性行为 (例如“是否存在相变”) 上一定正确——这取决于所选择的变分族 (此处是“变量间彼此独立”的因子化假设) 在多大程度上抓住了真实系统的关键物理机制。在使用任何近似方法之前，弄清楚它在哪些情形下会失效、又在哪些情形下管用，同样重要。

习题

基础题

习题 6.1: KL 散度的非负性

证明对于任意两个概率分布 P 和 Q :

$$D_{KL}(P\|Q) = \sum_x P(x) \ln \frac{P(x)}{Q(x)} \geq 0,$$

等号成立当且仅当 $P = Q$ 。

提示: 使用 Jensen 不等式: 对于凸函数 f , 有 $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$, 注意 $-\ln$ 是凸函数。

进阶题

习题 6.2: 变分推断的 EM 算法

对于包含隐变量的模型 $P(\mathbf{v}, \mathbf{h}; \theta)$:

- 写出 ELBO 的表达式 $\mathcal{L}[Q, \theta]$;
- 证明 $\ln P(\mathbf{v}; \theta) = \mathcal{L}[Q, \theta] + D_{KL}(Q \| P(\mathbf{h}|\mathbf{v}; \theta))$;
- E 步**: 固定 θ , 最大化 $\mathcal{L}[Q, \theta]$ 关于 Q , 证明最优的 $Q^* = P(\mathbf{h}|\mathbf{v}; \theta)$;
- M 步**: 固定 Q^* , 最大化 $\mathcal{L}[Q^*, \theta]$ 关于 θ , 写出目标函数;
- 证明 EM 算法的每次迭代都增加 (或保持不变) 对数似然 $\ln P(\mathbf{v}; \theta)$ 。

习题 6.3: 平均场近似的伊辛模型

考虑外磁场中的伊辛模型:

$$E(\{s_i\}) = -J \sum_{\langle i,j \rangle} s_i s_j - h \sum_i s_i,$$

在 d 维立方晶格上, 每个自旋有 $2d$ 个近邻。

- 写出平均场近似下的自洽方程;
- 在 $h = 0$ 情况下, 找出相变的临界温度 T_c ;
- 对于 $d = 1$ (一维链), 平均场预测的 T_c 是多少? 与精确结果 ($T_c = 0$) 比较;
- 对于 $d = 2, 3$, 平均场预测的 T_c 是多少?
- 讨论平均场近似的局限性: 为什么它会高估 T_c ?

挑战题

习题 6.4: 信息瓶颈理论

信息瓶颈目标函数为

$$\max_{P(t|x)} [I(T; Y) - \beta I(T; X)],$$

其中 T 是表示, X 是输入, Y 是输出。

(a) 写出互信息 $I(T; Y)$ 和 $I(T; X)$ 的定义;

(b) 使用变分法, 证明最优分布 $P^*(t|x)$ 满足

$$P^*(t|x) = \frac{P(t)}{Z(x, \beta)} \exp\left(\beta \mathbb{E}_{P(y|x)} [\ln P(y|t)]\right),$$

其中 $Z(x, \beta)$ 是归一化常数;

(c) 证明这导致自洽方程

$$P(t) = \sum_x P(t|x)P(x), \quad P(y|t) = \frac{1}{P(t)} \sum_x P(y|x)P(t|x)P(x);$$

(d) 讨论 $\beta \rightarrow 0$ 和 $\beta \rightarrow \infty$ 的极限情况;

(e) 将信息瓶颈与自编码器进行比较: VAE 的损失函数如何与信息瓶颈目标相关联?

习题 6.5: 相变与学习

考虑一个简化的学习场景: 一个两层神经网络学习一个二分类任务。

(a) 建模: 假设训练数据来自一个“教师”网络, “学生”网络试图学习。将学生的泛化误差 ϵ_g 看作“序参量” (order parameter);

(b) 在不同的训练样本数 N (类比温度) 下, ϵ_g 如何变化? 是否存在一个临界样本数 N_c , 使得学生网络从“无法泛化”突变到“成功泛化”?

(c) 文献中的结果: 对于某些简单模型, 泛化误差确实表现出相变行为, 讨论这种相变的物理机制;

(d) 在真实的深度学习中, “双下降”现象 (模型复杂度增加, 先过拟合后又泛化变好) 如何用相变语言理解?

(e) 思考: 深度学习中的“涌现能力” (emergence, 如大语言模型突然获得少样本学习能力) 是否可以看作某种相变?

最大熵原理

I love your Majesty

According to my bond, no more nor less.

—— 莎士比亚《李尔王》第一幕第一场，
科迪莉亚

学习目标

- 掌握用拉格朗日乘数法从最大熵原理推导玻尔兹曼分布的完整过程，理解这是与物理直觉完全独立的另一条推导路径；
- 通过骰子与双态系统两个具体算例，验证“给定约束、最大化熵”与“系统和热库交换能量”这两条逻辑截然不同的道路殊途同归；
- 理解最大熵模型（对数线性模型）与 Softmax 回归之间的等价关系；
- 掌握最小交叉熵原理作为最大熵原理的推广，并理解其与 MAP 估计中“先验拉向自身”这一逻辑的一致性。

■ 本章导览

本章回答的问题：前几章已经从不只一个彼此独立的方向反复推出了同一个玻尔兹曼分布，这只是巧合，还是背后有更深的原因？是否存在一条完全不依赖物理直觉、纯粹从信息论出发的独立推导路径？

统计力学对应：最大熵原理表明，玻尔兹曼分布并非一个物理假设，而是“在满足已知约束的前提下，选择最不做额外假设的分布”这一信息论公理的必然结果；本章末尾的“统计力学与机器学习对应表”是全书六章论证链条的压缩摘要，而不是一份用于死记硬背的速查表。

后续预告：第一部分到此结束。讲义第二部分“神经网络的物理模型”将把这里建立的全部数学语言——能量、玻尔兹曼分布、配分函数、变分方法——应用于 Hopfield 网络与玻尔兹曼机等具体的神经网络模型；第三部分“优化与动力学”则会回到第一章提出、却始终悬而未答的问题：训练过程中“不断调整参数”这件事，究竟应该怎样系统地完成。

本章走到这里，玻尔兹曼分布已经通过两条彼此独立的推导反复出现：§2.2 从“系统与热

库交换能量”这一物理图景推出它；§6.1 通过熵正则化的变分目标函数，从优化的角度再次推出它。（§4.1 “损失函数即能量函数”这一观察性质有所不同：它对任何正概率分布都恒成立——只需取 $E(\mathbf{x}) \equiv -\ln P(\mathbf{x})$ ， $P(\mathbf{x}) = e^{-E(\mathbf{x})}$ 就自动成立，这是一个记号上的恒等式，而非物理或信息论意义上需要证明的结论。但正是这一恒等式，让前面两条推导路径的结论，能够原封不动地应用到任意一个机器学习概率模型上，而不只停留在纯物理系统里——它是桥梁，而不是第三个独立源头。）

本章要展示的，是完全不依赖物理直觉、纯粹从信息论出发的第三条独立推导路径：只需要一句信息论原理——“在满足已知约束的前提下，选择最不做额外假设的分布”——就能将玻尔兹曼分布推导出来。

三条彼此独立的道路殊途同归，这并非巧合，而是在提示我们：在接受“最大熵原理”作为信息不充分条件下的推断公理这一前提下，玻尔兹曼分布或许根本不是一个物理假设，而是这条推断公理与平均能量约束共同作用下的必然结果——但这一必然性依赖于接受最大熵原理本身作为出发点，它是一条关于“如何在信息不足时做推断”的方法论公理（Jaynes 的观点），而非概率论内部可以独立证明的定理；关于是否应当接受这条公理作为“唯一合理”的推断原则，统计学与哲学界至今仍有争论，本书对此不作定论，只呈现这条推导路径本身的数学结构。

§7.1 统计力学中的最大熵原理

■ 历史：熵，一个借来的名字

1948 年，Claude Shannon 在贝尔实验室发表“通信的数学理论”，为衡量一条消息里到底含有多少“不确定性”，定义了 $H = -\sum_i p_i \log p_i$ （式 (2.15) 正是这一表达式在物理语境下的样子）。据一则广为流传、但 Shannon 本人从未正式证实的轶事，他原本想把这个量称为“不确定性”（uncertainty），是冯·诺依曼建议他改称“熵”——理由是这个表达式的形式，与统计力学中早已存在的熵（正是本书第二章式 (2.15)、可回溯到玻尔兹曼的 H 函数与本节之前吉布斯给出的表达式）完全相同，“反正没人真正搞懂熵是什么，这会让你在辩论里永远占上风”。无论轶事真假，数学事实是确定的：热力学熵与信息熵，是同一个函数在两个相隔近一个世纪、彼此独立发展的领域中被各自发现。E. T. Jaynes 本人是物理学家，正是这一“借用”促使他反过来发问：如果两个领域用的是同一个数学对象，那么统计力学的整套框架，是否原本就可以从纯粹的信息论原理导出，而不需要预设任何关于原子或分子的物理图像？下面“Jaynes 的洞察”要回答的，正是这个问题。

Jaynes 的洞察

E. T. Jaynes 在 1957 年提出了一个深刻的思想：统计力学的基础不是微观动力学，而是信息论。

核心问题：给定一些宏观约束（如平均能量），什么分布最“合理”或最“无偏”？

答案：在满足约束的所有分布中，熵最大的分布最合理。

直观理由：

- 熵度量不确定性或“信息缺失”；

- 选择熵最大的分布，意味着除给定约束外不引入任何额外假设；
- 这是一种“奥卡姆剃刀”：不引入未观测到的结构。

数学表述

问题设定：给定 m 个约束条件：

$$\langle f_k(\mathbf{x}) \rangle = \bar{f}_k, \quad k = 1, 2, \dots, m, \quad (7.1)$$

以及归一化条件：

$$\sum_{\mathbf{x}} P(\mathbf{x}) = 1, \quad (7.2)$$

求使熵最大的分布 $P(\mathbf{x})$ ：

$$\max_P S = - \sum_{\mathbf{x}} P(\mathbf{x}) \ln P(\mathbf{x}). \quad (7.3)$$

用拉格朗日乘数法求解

构造拉格朗日函数：

$$\mathcal{F} = - \sum_{\mathbf{x}} P(\mathbf{x}) \ln P(\mathbf{x}) + \lambda_0 \left(1 - \sum_{\mathbf{x}} P(\mathbf{x}) \right) + \sum_{k=1}^m \lambda_k \left(\bar{f}_k - \sum_{\mathbf{x}} P(\mathbf{x}) f_k(\mathbf{x}) \right).$$

与第六章推导平均场方程时相同 (§6.4“预备说明”)，只要 $\mathbf{x}$ 取有限个离散值， $P(\mathbf{x})$ 就不是一个抽象的“函数”，而是若干个独立实数 $\{P(\mathbf{x})\}_{\mathbf{x}}$ （每一个状态对应一个实数）。“对 $P(\mathbf{x})$ 求变分”因此就是对每一个具体状态 $\mathbf{x}'$ ，将 $P(\mathbf{x}')$ 当作普通实变量求偏导数 $\partial \mathcal{F} / \partial P(\mathbf{x}')$ ，其余 $P(\mathbf{x})$ ($\mathbf{x} \neq \mathbf{x}'$) 视为与之无关的独立变量——这正是普通的拉格朗日乘数法，不需要变分法。逐项计算：

- 第一项： $\frac{\partial}{\partial P(\mathbf{x}')} [-P(\mathbf{x}') \ln P(\mathbf{x}')] = -\ln P(\mathbf{x}') - P(\mathbf{x}') \cdot \frac{1}{P(\mathbf{x}')} = -\ln P(\mathbf{x}') - 1$ （乘积法则，求和中只有 $\mathbf{x} = \mathbf{x}'$ 那一项依赖于 $P(\mathbf{x}')$ ）；
- 第二项： $\frac{\partial}{\partial P(\mathbf{x}')} [\lambda_0 (1 - \sum_{\mathbf{x}} P(\mathbf{x}))] = -\lambda_0$ ；
- 第三项： $\frac{\partial}{\partial P(\mathbf{x}')} \left[\sum_k \lambda_k (\bar{f}_k - \sum_{\mathbf{x}} P(\mathbf{x}) f_k(\mathbf{x})) \right] = -\sum_k \lambda_k f_k(\mathbf{x}')$ 。

三项相加并令其为零（把 $\mathbf{x}'$ 重新记为 $\mathbf{x}$ ）：

$$\frac{\partial \mathcal{F}}{\partial P(\mathbf{x})} = -\ln P(\mathbf{x}) - 1 - \lambda_0 - \sum_{k=1}^m \lambda_k f_k(\mathbf{x}) = 0.$$

解得：

$$P(\mathbf{x}) = \exp \left(-1 - \lambda_0 - \sum_{k=1}^m \lambda_k f_k(\mathbf{x}) \right).$$

利用归一化条件 $\sum_{\mathbf{x}} P(\mathbf{x}) = 1$ 确定 λ_0 ：把与 $\mathbf{x}$ 无关的因子 $e^{-1-\lambda_0}$ 从求和中提出，

$$1 = \sum_{\mathbf{x}} P(\mathbf{x}) = \sum_{\mathbf{x}} e^{-1-\lambda_0} \exp \left(- \sum_{k=1}^m \lambda_k f_k(\mathbf{x}) \right) = e^{-1-\lambda_0} \sum_{\mathbf{x}} \exp \left(- \sum_{k=1}^m \lambda_k f_k(\mathbf{x}) \right),$$

两边同乘 $e^{1+\lambda_0}$ ，即

$$e^{1+\lambda_0} = \sum_{\mathbf{x}} \exp\left(-\sum_{k=1}^m \lambda_k f_k(\mathbf{x})\right) \equiv Z.$$

把 $P(\mathbf{x}) = e^{-1-\lambda_0} \exp(-\sum_k \lambda_k f_k(\mathbf{x}))$ 中的 $e^{-1-\lambda_0} = 1/Z$ 代入，因此：

$$P(\mathbf{x}) = \frac{1}{Z} \exp\left(-\sum_{k=1}^m \lambda_k f_k(\mathbf{x})\right), \quad (7.4)$$

其中：

$$Z = \sum_{\mathbf{x}} \exp\left(-\sum_{k=1}^m \lambda_k f_k(\mathbf{x})\right).$$

定义能量函数：

$$E(\mathbf{x}) = \sum_{k=1}^m \lambda_k f_k(\mathbf{x}),$$

即得

$$P(\mathbf{x}) = \frac{1}{Z} e^{-E(\mathbf{x})}. \quad (7.5)$$

这正是玻尔兹曼分布！

特殊情况：正则系综

如果唯一的约束是平均能量：

$$\langle E(\mathbf{x}) \rangle = \bar{E},$$

则最大熵分布为

$$P(\mathbf{x}) = \frac{1}{Z} e^{-\beta E(\mathbf{x})},$$

其中 β 是拉格朗日乘数，可通过约束条件确定：

$$\bar{E} = -\frac{\partial \ln Z}{\partial \beta}.$$

在热力学中， $\beta = 1/(k_B T)$ 与温度相关；但从信息论角度看， β 只是强制平均能量约束的拉格朗日乘数。

哲学意义：最大熵原理表明，玻尔兹曼分布并非一个基本假设，而是从信息论原理推导出来的——它是在给定宏观约束下最“无偏”的分布。

算例：一枚不均匀的骰子（Jaynes 的经典例子）

上面的推导较为抽象，下面用 Jaynes 本人 1957 年论文中所用的例子将其彻底具体化：一枚六面骰子，每面朝上的概率 $P(i)$ ($i = 1, \dots, 6$) 未知，仅知道平均点数 $\langle X \rangle$ 这一约束，求最大熵分布。

根据前述通用结果， $P(i) \propto e^{-\lambda i}$ ，其中 λ 由约束条件 $\sum_i i P(i) = \langle X \rangle$ 确定。取三个不同的约束值，数值求解 λ （求解过程是标准的一维方程求根，此处略去，仅列结果）：

表 7.1 第一行是一个很好的自检：如果约束恰好是“公平骰子本来就有”的均值 3.5，最大熵原理给出 $\lambda = 0$ ，即均匀分布——这完全合理：若除“平均点数为 3.5”之外一无所知，而这

表 7.1: 不同约束 $\langle X \rangle$ 下骰子的最大熵分布

约束 $\langle X \rangle$	λ	$P(1)$	$P(2)$	$P(3)$	$P(4)$	$P(5)$	$P(6)$
3.5 (公平骰子的均值)	0.000	0.167	0.167	0.167	0.167	0.167	0.167
4.5	-0.371	0.054	0.079	0.114	0.165	0.240	0.348
5.0	-0.630	0.021	0.038	0.072	0.136	0.255	0.478

恰好是均匀分布本身满足的均值，那么没有理由认为某一面比另一面更容易朝上，最大熵原理精确地给出了这一“不做额外假设”的答案。第二、三行则展示了约束如何“扭曲”分布：一旦要求平均点数明显高于 3.5（如 4.5 或 5.0），最大熵分布会自动向高点数一侧倾斜——且概率并非均匀地被“抬高”，而是随点数指数式增长（6 点的概率比 1 点高出约 6 到 23 倍），这正是拉格朗日乘数法解出的 $P(i) \propto e^{-\lambda i}$ 这一指数形式的直接体现。这枚骰子，其实就是“能量” $E(i) = i$ 、“温度”由约束隐含决定的一个微缩版玻尔兹曼分布。

算例：反推双态系统的“温度”，验证殊途同归

现在做一个更能体现本节核心论点的验证。回忆 §2.2 的双态系统 ($E_0 = 0, E_1 = \varepsilon = 1$)：从物理推导出发，假设它与一个 $k_B T = 1$ ($\beta = 1$) 的热库接触，算出了精确的平均能量 $\langle E \rangle = 0.269$ 。

现在反过来：假装完全不知道“温度”或“热库”这些物理概念，只知道一个孤立的约束——“这个系统的平均能量是 0.269”，套用本节刚推出的最大熵公式 $P(x) \propto e^{-\lambda E(x)}$ ，数值求解满足约束的 λ ：

$$\text{数值求解得：} \quad \lambda = 1.000000.$$

这一数字精确地等于 §2.2 中假设的 $\beta = 1/(k_B T) = 1$ ！两条完全不同的推导路径——一条从“系统与热库交换能量”的物理图像出发，一条纯粹从“给定约束、最大化熵”的信息论原理出发——在数值上分毫不差地收敛到了同一个分布。这正是 Jaynes 想要表达的：温度、配分函数、玻尔兹曼分布，与其说是热力学系统“必须具有”的物理属性，不如说是“在给定信息量下做推断”这一更普遍的逻辑问题的最优解；统计力学只是这一逻辑问题在“约束是平均能量”这一特定情形下的应用。

■ 思考与验证

如果骰子的约束换成“至少要有两个不同的矩约束”，比如同时给定 $\langle X \rangle$ 和 $\langle X^2 \rangle$ ，能否根据 §7.1 的一般推导（ m 个约束对应 m 个拉格朗日乘数）推断出最大熵分布的形式？

解： $P(i) \propto \exp(-\lambda_1 i - \lambda_2 i^2)$ ——指数上会同时出现一次项和二次项。这一形式并不陌生：这正是（离散版的）高斯分布的形式——连续变量、只约束均值和方差时的最大熵分布，正是正态分布，这也是高斯分布在统计学中如此“特殊”的原因：它是“只知道均值和方差”这一信息状态下唯一无偏的选择。

§7.2 最大熵在机器学习中的应用

最大熵模型 (MaxEnt Models)

在机器学习中，最大熵原理可用于构建分类器。

问题设定：给定训练数据 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}$ ，学习条件概率分布 $P(y|\mathbf{x})$ 。

约束条件：模型的期望特征与数据的经验特征匹配：

$$\sum_{\mathbf{x}, y} \tilde{P}(\mathbf{x}) P(y|\mathbf{x}) f_k(\mathbf{x}, y) = \sum_{\mathbf{x}, y} \tilde{P}(\mathbf{x}, y) f_k(\mathbf{x}, y), \quad (7.6)$$

其中 $\tilde{P}(\mathbf{x}, y)$ 是训练数据的经验分布， $f_k(\mathbf{x}, y)$ 是特征函数。

目标：在满足约束的所有分布中，选择条件熵最大的：

$$\max_{P(y|\mathbf{x})} H(Y|X) = - \sum_{\mathbf{x}, y} \tilde{P}(\mathbf{x}) P(y|\mathbf{x}) \ln P(y|\mathbf{x}). \quad (7.7)$$

解：这一问题与 §7.1 中求解的最大熵问题结构相似，但有两处不同，需要重新走一遍拉格朗日乘数法：其一，这里要归一化的是条件分布，对每一个 $\mathbf{x}$ 单独要求 $\sum_y P(y|\mathbf{x}) = 1$ ，因此每个 $\mathbf{x}$ 需要各自一个拉格朗日乘数 $\nu(\mathbf{x})$ ；其二，目标函数 (7.7) 与约束 (7.6) 中的每一项都带有经验边际分布 $\tilde{P}(\mathbf{x})$ 作为权重。构造拉格朗日函数：

$$\begin{aligned} \mathcal{F} = & - \sum_{\mathbf{x}, y} \tilde{P}(\mathbf{x}) P(y|\mathbf{x}) \ln P(y|\mathbf{x}) + \sum_{\mathbf{x}} \nu(\mathbf{x}) \left(1 - \sum_y P(y|\mathbf{x}) \right) \\ & + \sum_k \lambda_k \left(\sum_{\mathbf{x}, y} \tilde{P}(\mathbf{x}) P(y|\mathbf{x}) f_k(\mathbf{x}, y) - \sum_{\mathbf{x}, y} \tilde{P}(\mathbf{x}, y) f_k(\mathbf{x}, y) \right). \end{aligned}$$

和 §7.1 中完全相同的道理：把每一个 $P(y|\mathbf{x})$ （对固定的一对 $(\mathbf{x}, y) = (\mathbf{x}', y')$ ）当作独立实变量求偏导。逐项计算：

- 第一项：只有 $(\mathbf{x}, y) = (\mathbf{x}', y')$ 这一项依赖于 $P(y'|\mathbf{x}')$ ，乘积法则给出 $-\tilde{P}(\mathbf{x}') [\ln P(y'|\mathbf{x}') + 1]$ ；
- 第二项：只有 $\mathbf{x} = \mathbf{x}'$ 这一项依赖，给出 $-\nu(\mathbf{x}')$ ；
- 第三项：给出 $\tilde{P}(\mathbf{x}') \sum_k \lambda_k f_k(\mathbf{x}', y')$ （这里取与 §7.1 相反的符号约定，是为了让最终结果里 λ_k 前面带正号，与机器学习文献中对数线性模型的通行写法一致； λ_k 本身仍是待定的自由参数，符号约定不影响物理内容）。

三项相加并令其为零：

$$-\tilde{P}(\mathbf{x}') [\ln P(y'|\mathbf{x}') + 1] - \nu(\mathbf{x}') + \tilde{P}(\mathbf{x}') \sum_k \lambda_k f_k(\mathbf{x}', y') = 0.$$

两边除以 $-\tilde{P}(\mathbf{x}')$ （假设 $\tilde{P}(\mathbf{x}') > 0$ ，即该输入在训练集中确实出现过）：

$$\ln P(y'|\mathbf{x}') = -1 - \frac{\nu(\mathbf{x}')}{\tilde{P}(\mathbf{x}')} + \sum_k \lambda_k f_k(\mathbf{x}', y').$$

右边前两项之和 $-1 - \nu(\mathbf{x}')/\tilde{P}(\mathbf{x}')$ 不依赖于 y' （对固定的 $\mathbf{x}'$ ，它只是一个待定常数），故取指数后， $P(y'|\mathbf{x}')$ 作为 y' 的函数正比于 $\exp(\sum_k \lambda_k f_k(\mathbf{x}', y'))$ ，其比例系数由该常数决定、并最终

由归一化条件 $\sum_{y'} P(y'|\mathbf{x}') = 1$ 确定 (把 $\mathbf{x}', y'$ 重新记为 $\mathbf{x}, y$):

$$P(y|\mathbf{x}) = \frac{1}{Z(\mathbf{x})} \exp\left(\sum_k \lambda_k f_k(\mathbf{x}, y)\right), \quad (7.8)$$

其中

$$Z(\mathbf{x}) = \sum_{y'} \exp\left(\sum_k \lambda_k f_k(\mathbf{x}, y')\right).$$

这正是对数线性模型 (log-linear model) !

例子：文本分类

假设根据文档 $\mathbf{x}$ (表示为词频向量) 预测其类别 y (如“体育”、“政治”等)。定义特征函数:

$$f_{w,c}(\mathbf{x}, y) = \begin{cases} x_w & \text{若 } y = c, \\ 0 & \text{否则,} \end{cases}$$

其中 x_w 是词 w 在文档中的出现次数, c 是类别。最大熵模型为

$$P(y = c|\mathbf{x}) = \frac{\exp(\sum_w \lambda_{w,c} x_w)}{\sum_{c'} \exp(\sum_w \lambda_{w,c'} x_w)} = \frac{\exp(\boldsymbol{\lambda}_c^T \mathbf{x})}{\sum_{c'} \exp(\boldsymbol{\lambda}_{c'}^T \mathbf{x})}.$$

这正是 Softmax 回归!

结论: Softmax 回归可以看作最大熵原理在分类问题中的应用。

§7.3 最小交叉熵原理

最大熵原理有一个重要的推广: 最小相对熵原理 (也称最小 KL 散度原理)。

问题: 给定一个先验分布 $Q(\mathbf{x})$ 和约束条件, 求使 $D_{KL}(P\|Q)$ 最小的分布 P 。

■ 记号提醒: P, Q 的角色与第六章相反

第六章讨论变分自由能时, P 始终指“真实但难以计算的目标分布”, Q 是在一个变分族中搜索、用来逼近 P 的试探分布。本节沿用最大熵原理一贯的记号习惯, P 是待求解的答案 (即本节要最终解出的分布), Q 才是给定、固定不变的先验——两章的 P, Q 恰好互换了角色。这不是排版失误, 而是两套记号传统 (变分推断 vs. 最大熵/最小交叉熵) 各自独立形成、在本书中同时保留的结果; 阅读时请以“哪个分布是待求的未知量”为准, 而不要依赖字母本身。

动机: 当我们持有先验信息时, 不应完全忽略它。最小化 KL 散度意味着在满足新约束的同时, 尽可能保持接近先验。

解: 同样用拉格朗日乘数法, 只是这次要最小化 $D_{KL}(P\|Q) = \sum_{\mathbf{x}} P(\mathbf{x}) \ln \frac{P(\mathbf{x})}{Q(\mathbf{x})}$ (Q 是给定的先验分布, 不参与优化)。构造拉格朗日函数:

$$\mathcal{F} = \sum_{\mathbf{x}} P(\mathbf{x}) \ln \frac{P(\mathbf{x})}{Q(\mathbf{x})} + \lambda_0 \left(1 - \sum_{\mathbf{x}} P(\mathbf{x})\right) + \sum_k \lambda_k \left(\sum_{\mathbf{x}} P(\mathbf{x}) f_k(\mathbf{x}) - \bar{f}_k\right).$$

与 §7.1 中同样的做法，对固定的 $\mathbf{x}'$ 将 $P(\mathbf{x}')$ 当作独立实变量求偏导：第一项由乘积法则给出 $\ln \frac{P(\mathbf{x}')}{Q(\mathbf{x}')} + P(\mathbf{x}') \cdot \frac{1}{P(\mathbf{x}')} = \ln \frac{P(\mathbf{x}')}{Q(\mathbf{x}')} + 1$ ($Q(\mathbf{x}')$ 是固定的先验，视为常数，对 $P(\mathbf{x}')$ 求导时不产生额外项)；第二项给出 $-\lambda_0$ ；第三项给出 $\sum_k \lambda_k f_k(\mathbf{x}')$ 。三项相加并令其为零：

$$\ln \frac{P(\mathbf{x}')}{Q(\mathbf{x}')} + 1 - \lambda_0 + \sum_k \lambda_k f_k(\mathbf{x}') = 0 \implies \ln \frac{P(\mathbf{x}')}{Q(\mathbf{x}')} = (\lambda_0 - 1) - \sum_k \lambda_k f_k(\mathbf{x}').$$

两边取指数， $(\lambda_0 - 1)$ 不依赖于 $\mathbf{x}'$ ，取指数后成为比例常数，把 $\mathbf{x}'$ 重新记为 $\mathbf{x}$ ：

$$P(\mathbf{x}) = Q(\mathbf{x}) \cdot e^{\lambda_0 - 1} \cdot \exp\left(-\sum_k \lambda_k f_k(\mathbf{x})\right) \propto Q(\mathbf{x}) \exp\left(-\sum_k \lambda_k f_k(\mathbf{x})\right).$$

把比例常数记为 $1/Z$ （由归一化 $\sum_{\mathbf{x}} P(\mathbf{x}) = 1$ 确定，做法与式 (7.4) 完全相同），即得最小 KL 散度的解仍为指数族形式：

$$P(\mathbf{x}) = \frac{1}{Z} Q(\mathbf{x}) \exp\left(-\sum_k \lambda_k f_k(\mathbf{x})\right). \quad (7.9)$$

与 §7.1 中最大熵解 (7.4) 相比，唯一的区别是多了一个先验因子 $Q(\mathbf{x})$ ——这与推导中“第一项对 $Q(\mathbf{x}')$ 视为常数”完全对应：先验的作用，就是在纯粹的指数族权重之外，再乘上一个不随约束变化的“底色”。

特殊情况：若先验为均匀分布 $Q(\mathbf{x}) = \text{const}$ ，则回到最大熵分布。

■ 思考与验证

结合前述骰子的例子：若对骰子还有一个先验知识——比如它是老式手工骰子，做工不算精良，先验地相信“6 点因为开孔较多、材质较轻，天然地比其他面略容易朝上”（即先验 $Q(6)$ 略大于其他面）——在同样“平均点数为 4.5”的约束下，最小交叉熵给出的解，与假设先验均匀（即纯粹的最大熵解）相比， $P(6)$ 应更大还是更小？

解：更大。最小化 $D_{KL}(P\|Q)$ 意味着在满足约束的同时要“尽量贴近先验”，若先验本身已偏向 6，最终解会在“约束要求的倾斜”之上，再叠加“先验带来的倾斜”， $P(6)$ 会比纯最大熵解更为突出。这与 §3.4“先验把估计拉向自身”的逻辑完全一致——最小交叉熵原理，可以看作是 MAP 中“先验 + 似然”这套逻辑，从“参数估计”推广到了“整个分布的选择”之上。

在机器学习中的应用

正则化的信息论解释：在最大后验估计 (MAP) 中，有

$$\max_{\theta} [P(\mathcal{D}|\theta)P(\theta)],$$

这等价于

$$\min_{\theta} \left[\underbrace{-\ln P(\mathcal{D}|\theta)}_{\text{数据拟合项}} - \underbrace{\ln P(\theta)}_{\text{正则化项}} \right]. \quad (7.10)$$

这里正则化项就是负对数先验 $-\ln P(\theta)$ 本身，不需要、也不应该再借助 KL 散度来改写它—— θ 是一个参数点，而 D_{KL} 的定义要求两个自变量都是概率分布， $D_{KL}(\theta\|P_{\text{prior}})$ 这种写法字面

上没有良定义的数学含义，即便加上“启发式记号”的说明也容易在使用中被当真，故本书不采用这一写法。式 (7.10) 已经是最终、精确的形式，例如对高斯先验 $P(\boldsymbol{\theta}) \propto e^{-\lambda \|\boldsymbol{\theta}\|^2/2}$ ，直接代入即得 $-\ln P(\boldsymbol{\theta}) = \frac{\lambda}{2} \|\boldsymbol{\theta}\|^2 + \text{const}$ ，也就是 L^2 正则化（岭回归）——这正是 §3.4 中“虚拟计数”例子的连续参数版本，不需要经过 KL 散度这一步。

与第一项的类比（同样需要注意适用范围）：若将 $-\ln P(\mathcal{D}|\boldsymbol{\theta})$ 对整个数据分布取期望（而不是对有限训练集求和），即 $\mathbb{E}_{\mathbf{x}, y \sim P_{\text{data}}}[-\ln P_{\boldsymbol{\theta}}(y|\mathbf{x})]$ ，这一总体交叉熵才严格等于 $H(P_{\text{data}}) + D_{KL}(P_{\text{data}}\|P_{\boldsymbol{\theta}})$ ($H(P_{\text{data}})$ 不依赖 $\boldsymbol{\theta}$ ，可并入常数)；训练时实际最小化的是在有限数据集上的经验平均，是这个总体量的一个（依赖于样本量的）估计，两者严格相等只在数据量趋于无穷的极限下成立。

物理类比（在上述精确含义下成立）：

- $-\ln P(\mathcal{D}|\boldsymbol{\theta})$ ：数据拟合项，类似“能量”，数据量趋于无穷时趋于 $D_{KL}(P_{\text{data}}\|P_{\boldsymbol{\theta}}) + \text{const}$ ；
- $-\ln P(\boldsymbol{\theta})$ ：正则化项，类似“外场”把参数拉向先验偏好的区域（并非严格意义上的“熵惩罚”，熵惩罚特指变分推断中 $D_{KL}(Q\|P)$ 里的 $-\ln Q$ 那一项，两者不应混同）。

这再次展示了信息论、统计力学与机器学习之间的深刻联系。

■ 小结

本节用最抽象、最不依赖物理直觉的方式，重新推出了贯穿全书的玻尔兹曼分布——只需要“在满足约束的前提下选熵最大的分布”这一条信息论公理。我们用骰子例子看到约束如何把均匀分布“扭曲”成指数分布，又用双态系统的数值反推，亲眼验证了这条信息论路径和 §2.2 的物理路径殊途同归。这也让我们能够回头审视全书至此的核心论点：“系统与热库交换能量” (§2.2)、“寻找配分函数的下界”（第六章）、“在约束下追求最大的无偏性”（本章）——三条彼此独立的出发点，都指向同一个数学对象—— $P(\mathbf{x}) \propto e^{-E(\mathbf{x})}$ ；而“给概率模型一个损失函数”（第四章）这一步，则是让这一结论对机器学习同样成立的桥梁，而不是第四个独立源头。这并非巧合，而是物理、优化与信息论在骨子里共享着同一套数学结构。

习题

基础题

习题 7.1: 用最大熵原理反推另一个双态系统的“温度”

§7.1“算例：反推双态系统的温度”中，用能级为 $E_0 = 0, E_1 = \varepsilon = 1$ 、与 $k_B T = 1$ 热库接触的双态系统算出精确的 $\langle E \rangle = 0.269$ ，再反过来只用“约束是 $\langle E \rangle = 0.269$ ”这一条信息，通过最大熵原理验证得到的 λ 恰好等于 $\beta = 1$ 。现在换一个双态系统：能级为 $E_0 = 0, E_1 = \varepsilon = 2$ ，与 $k_B T = 2$ 的热库接触。

- 用第二章双态系统的玻尔兹曼分布公式，直接算出精确的 $\langle E \rangle$ （保留三位小数）；
- 现在假装不知道“温度”这一物理概念，只知道约束“平均能量等于 (a) 中算出的数

值”，写出最大熵分布 $P(x) \propto e^{-\lambda E(x)}$ 的表达式 ($x \in \{0, 1\}$, $E(0) = 0, E(1) = 2$)；

(c) 代入 (a) 中的约束值，数值求解 λ ；

(d) 验证你算出的 λ 是否恰好等于 $\beta = 1/(k_B T) = 1/2$ ，从而像正文一样，再次确认“信息论路径”与“物理路径”殊途同归。

习题 7.2: 用一个最简单的例子验证矩匹配约束

§7.2 推导最大熵分类器时，约束条件 (7.6) 写得比较抽象。本题用一个只有一个输入、两个类别的极简设定，把这条约束的含义彻底具体化。设训练集里只出现过一种输入 $\mathbf{x}$ （即经验分布 $\tilde{P}(\mathbf{x}) = 1$ ），其中标签 $y = 1$ 的比例是 0.7， $y = 0$ 的比例是 0.3。取特征函数 $f(\mathbf{x}, y) = \mathbb{I}[y = 1]$ （即 $y = 1$ 时取值 1，否则取值 0）。

(a) 写出约束方程 (7.6) 在这一具体设定下的样子（提示：由于只有一个 $\mathbf{x}$ ，对 $\mathbf{x}$ 的求和可以直接去掉）；

(b) 按式 (7.8)，两类问题里 $P(y = 1|\mathbf{x}) = \frac{e^\lambda}{e^\lambda + e^0}$ ，也就是 sigmoid 函数 $\sigma(\lambda)$ （回忆第四章的 sigmoid 定义）。把 (a) 中的约束代入，解出 λ ；

(c) 验证：解出的 $P(y = 1|\mathbf{x})$ 是否恰好等于训练数据里 $y = 1$ 的经验比例 0.7？这说明了什么——在只有一个输入、一个指示特征的最简单情形下，“模型的期望特征与数据的经验特征匹配”这条抽象约束，退化成了一件多么朴素的事情？

进阶题

习题 7.3: 最大熵分布的推导

(a) 在约束 $\sum_x P(x) = 1$ 和 $\sum_x P(x) x = \mu$ 下，求使熵 $H = -\sum_x P(x) \ln P(x)$ 最大的分布。

提示：使用拉格朗日乘数法。

(b) 证明结果是指数分布（对连续情况）或几何分布（对离散情况）；

(c) 在约束 $\sum_x P(x) = 1$, $\sum_x P(x) x = \mu$, $\sum_x P(x) x^2 = \sigma^2 + \mu^2$ 下，求最大熵分布；

(d) 证明结果是高斯分布 $\mathcal{N}(\mu, \sigma^2)$ ；

(e) 一般地，给定 m 个矩约束，最大熵分布的形式是什么？

习题 7.4: 带先验的骰子：最小交叉熵的具体算例

§7.3“思考与验证”中定性讨论了先验偏向 6 点对解的影响，本题把它变成一个可以算到

底的具体例子。设骰子的先验分布为

$$Q(1) = Q(2) = Q(3) = Q(4) = Q(5) = 0.15, \quad Q(6) = 0.25,$$

约束仍是平均点数 $\langle X \rangle = 4.5$ 。

- (a) 按式 (7.9)，最小交叉熵解的形式为 $P(i) \propto Q(i)e^{-\lambda i}$ ；先计算 $\lambda = 0$ （即 $P = Q$ ，不作任何调整）时对应的 $\langle X \rangle_Q$ ；
- (b) 将 (a) 中算出的 $\langle X \rangle_Q$ 与约束要求的 4.5 比较，由此判断满足约束所需的 λ 应为正还是为负（提示： $P(i) \propto Q(i)e^{-\lambda i}$ 中， λ 的符号决定了指数因子把权重推向点数大的一侧还是小的一侧）；
- (c)（数值计算，可借助计算器或编程）数值求解满足约束的 λ ，并算出完整的 $P(1), \dots, P(6)$ ；
- (d) 将 (c) 的结果与正文表 7.1 中“先验为均匀分布、同样约束 $\langle X \rangle = 4.5$ ”的解相比：哪一个分布的 $P(6)$ 更大？这是否符合“先验本身已经偏向 6”这一直觉？

挑战题

习题 7.5: 从最大熵原理推导巨正则系综

§7.1 从“平均能量”这一个约束，推出了正则系综的玻尔兹曼分布。统计力学中还有一种更一般的系综——巨正则系综（grand canonical ensemble），允许系统与热库同时交换能量与粒子数，此时约束除了平均能量 $\langle E \rangle = \bar{E}$ ，还多了一条平均粒子数 $\langle N \rangle = \bar{N}$ 。

- (a) 类比 §7.1 的推导，写出这一约束优化问题对应的拉格朗日函数（现在有两个拉格朗日乘数，习惯上分别记为 β 和 $-\beta\mu$ ，其中 μ 称为化学势）；
- (b) 仿照式 (7.4) 的推导，证明最大熵分布的形式为

$$P(\mathbf{x}, N) \propto e^{-\beta[E(\mathbf{x}, N) - \mu N]},$$

- (c) 查阅资料：这一分布中 $E - \mu N$ 这一组合通常被称为“巨正则势”或“有效能量”，它在哪些物理情境下（如半导体物理中的费米能级、玻色-爱因斯坦凝聚）被广泛使用？
- (d) 开放思考：机器学习中是否存在类似“系统与外界交换粒子数”这样的场景——例如输出长度可变的模型（如语言模型生成不定长度的句子，或点云、分子结构生成模型中原子数目可变）？这种类比能否启发出一个“变长度生成模型的巨正则系综描述”？它是否有意义？

第一部分总结：统计力学与机器学习的数学桥梁

在这一部分中，我们建立了统计力学与机器学习之间的数学桥梁。以下回顾贯穿全部六章的核心思想。

核心对应关系

第二章结尾埋下过一张种子表（表 2.8）：七行统计力学词汇，机器学习一栏留白，只写着“将在何处揭晓”。现在可以逐行核对承诺是否兑现：“微观状态”“玻尔兹曼分布”“能量函数”“逆温度”在第四章填上 (§4.1)；“配分函数”在第四章给出定义、第五章揭示其计算困难；“自由能”与“熵”的前半部分在第六章填上 (§6.3)；“熵”的后半部分与本章新增的“最大熵原理”，就在下表的最后几行完成。种子表里没有一行被遗漏，也没有提前透支——这正是下表能够成立的原因，而不是相反。

表 7.2 最右一列标出了每一行对应关系的性质：“定义”指两侧本就是同一个数学操作换了一套名词（例如“能量函数”与“损失”都只是“指数里那个待定的裸量”的两种叫法，见第四章 §4.1 的记号提醒）；“严格证明”指该行在正文中有完整的定理证明，可以查到具体章节回溯；“类比”指该行提供了有用的直觉和结构相似性，但不构成可以直接代入使用的等式（例如“逆温度 $\leftrightarrow$ 正则化参数”：两者都控制着“分布有多集中/多分散”，但不存在一个自然的、放之四海而皆准的公式把二者互相换算）。特别提醒：上表把“自由能 F ”这一行改成了“变分自由能 $F[Q] \leftrightarrow$ 负 ELBO”，而没有采用“ $F \leftrightarrow -\ln Z$ ”（即“负对数证据”）这一更简单但更容易误导的写法——后者只有在机器学习的证据 $P(\mathbf{v})$ 恰好充当某个能量模型的配分函数时才严格成立，作为普遍陈述并不准确；真正被证明过的严格对应，是 §6.3 中变分自由能 $F[Q]$ 与负证据下界 $-\text{ELBO}[Q]$ 之间的不等式，这一行才是可以放心引用的“严格证明”。

表 7.2 中标为“定义”和“严格证明”的每一行，都在前六章中被逐一严格推导过，可以查到具体出处：能量与损失的对应见第四章；配分函数的计算困难见第五章；变分自由能与 ELBO 的等价见第六章；最大熵与玻尔兹曼分布的关系见第七章。标为“类比”的少数几行（逆温度、平均场近似）则如实标出，不冒充为等式。这张表因此不是一份把类比和定理混为一谈的“速查表”，而是全书论证链条的压缩摘要，并且诚实地标出了哪些是可以直接代入使用的数学结论、哪些只是有益的直觉——这也是第二章那张空表，走完整整五章之后长成的样子。

类比的边界：这套语言在哪里不再适用

表 7.2 诚实地标出了“定义”“严格证明”“类比”三种不同强度的对应关系，但这三种强度共同的前提是：总还存在某种对应。这里要说的是更进一步的一件事——本书建立的这套统计力学语言，有几个地方连“类比”都谈不上，直接失效。知道语言在哪里停止生效，和知道语言本身讲了什么，同样重要。

1. 损失函数不一定是物理能量。第四章证明“损失 = 能量”，前提是概率模型确实写成了玻尔兹曼形式 $P(y|\mathbf{x}, \boldsymbol{\theta}) \propto e^{-\mathcal{L}}$ 。但现实中大量损失函数是直接被设计出来的优化目标（某个业务指标的代理、几个子任务损失的加权和），并不来自“先写概率模型、再取负对数似然”这一构造过程。这时“损失函数 $\leftrightarrow$ 能量函数”这套语言仍然可以作为优化算法

表 7.2: 统计力学与机器学习的核心对应关系——第二章种子表的完整版本

统计力学	机器学习	数学形式	类型
微观状态 $\mathbf{x}$	模型配置 / 隐变量	离散或连续变量	定义
能量函数 $E(\mathbf{x})$ (裸量)	损失 $\mathcal{L}$ (裸量, 指数内)	均出现在 $\propto e^{-\langle \cdot \rangle}$ 的指数中	定义
玻尔兹曼分布	概率模型	$P(\mathbf{x}) \propto e^{-\beta E(\mathbf{x})}$	定义
配分函数 Z	归一化常数	$\sum_{\mathbf{x}} e^{-\beta E(\mathbf{x})}$	定义
负对数 (配分函数归一化后的分布)	完整损失 / 负对数似然	$-\ln P = \beta E + \ln Z$	定义
逆温度 β	正则化参数	控制随机性 / 涨落	类比
熵 S	熵 / 模型复杂度	$-\sum P \ln P$	定义
变分自由能 $F[Q]$	负证据下界 $-\text{ELBO}[Q]$	$\langle E \rangle_Q - TS[Q]$	严格证明 (第六章)
最小化 $F[Q]$	最大化 $\text{ELBO}[Q]$	同一个不等式 $F[Q] \geq F_{\text{true}}$ 的两种说法	严格证明 (第六章)
平均场近似	变分推断的特例	因子化假设	类比 (第六章讨论了适用范围)
最大熵原理 + 能量约束	最大熵模型 / Softmax	在约束下熵最大 $\Rightarrow$ 玻尔兹曼形式	严格证明 (第七章, 见 §7.1 的公理前提说明)

的语言使用——第三部分会讨论损失函数景观与优化动力学——但它不再对应一个具体的、有明确温度和熵的物理系统。

2. 训练过程不是热平衡过程。随机梯度下降的更新规则 $\theta_{t+1} = \theta_t - \eta \nabla \mathcal{L}(\theta_t) + (\text{小批量带来的噪声})$ ，表面上很像粒子在能量景观里做带噪声的下降运动（类似 Langevin 动力学）。但 SGD 并不满足细致平衡：噪声结构由小批量采样方式决定，与损失景观 $\mathcal{L}(\theta)$ 的具体形状之间，不存在物理系统里“温度决定噪声大小”那种普适关系；训练收敛后参数是否严格服从 $P(\theta) \propto e^{-\beta \mathcal{L}(\theta)}$ ，也不是本书证明过的定理，而是一个仍在研究中的问题。
3. 参数空间不是物理构型空间。统计力学里的微观状态 $\mathbf{x}$ 通常可以被物理测量区分；神经网络参数 θ 却可能存在大量冗余——不同的 $\theta_1 \neq \theta_2$ 可以给出完全相同的函数 $f_{\theta_1} = f_{\theta_2}$ （例如交换某一层里两个神经元的编号，或把一层权重同时放大 k 倍、下一层同时缩小 k 倍）。这意味着“参数空间的体积”和“可实现函数的体积”是两个不同的量：对参数空间做积分算出来的配分函数 $Z = \int e^{-\beta \mathcal{L}(\theta)} d\theta$ ，会把物理上不可区分的冗余点重复计数，而这在真实物理系统中通常不会发生（除非系统本身带有对称性，那时需要额外除以对称群的大小）。
4. 热力学极限未必对应网络的 $N \rightarrow \infty$ 。物理里“ $N \rightarrow \infty$ ”之所以重要，是因为大量独立或弱关联的自由度会让涨落相对于平均值趋于零。神经网络理论里也大量讨论宽度趋于无穷的极限（例如神经切线核理论），但这个极限是否具有物理热力学极限那种“涨落消失”的性质，取决于具体的网络结构与初始化方式，不能想当然地把物理热力学极限的结论整套平移过来。
5. “温度”可能只是一个数学参数。本书里出现的 β 或“温度” T ，在 Softmax、模拟退火等场景里是一个可以自由选择超参数，调节的只是概率分布的尖锐程度。它和物理系统里由能量均分定理、热库耦合决定的真实温度，只在数学形式上一致（都写成 $P \propto e^{-\beta E}$ ），没有理由、也没有证据表明二者在数值或物理意义上可以互相换算。

这五点都不是对前六章任何结论的否定——第四、五、六、七章证明过的东西依然成立，只是那些证明都有明确的适用条件。这五点要说的是：这套语言的边界在哪里，超出边界之后，“统计力学”就只是一个方便的比喻，不再是一个可以直接代入使用的定理来源。

更多语言：同一个对象，优化与信息论怎么称呼它

表 7.2 只对照了统计物理与机器学习两种语言。但书中反复出现的这几个数学对象，其实同时也是优化理论与信息论里的标准对象，只是换了一套名字。下表只挑出对应关系确实经得起推敲的几行——不是每一行都能同样干脆地翻译成五种语言，凡是关联比较勉强的（例如“逆温度”在优化里没有干净的独立对应物），宁可不列，也不强行凑数：

这张表不是新的证明，只是提醒读者：本书用“统计物理”这一种语言讲完的故事，在优化理论和信息论的教材里，往往是用完全不同的名词讲同一件事——如果读者以后翻开一本凸优化或信息论的教材，认出这里的某一行，那正是这张表存在的意义。

表 7.3: 同一个数学对象，优化理论与信息论中的名字

数学对象	优化理论中的名字	信息论中的名字
能量函数 $E(\mathbf{x})$	目标函数 (objective)	自信息 $-\log P(\mathbf{x})$
配分函数 Z (的对数)	凸函数，其导数生成矩	累积量生成函数
熵 S	熵正则化项	不确定性的度量 (Shannon 熵)
自由能 F / 变分自由能	待最小化的目标 / 其上界	$-\ln Z$ / 负 ELBO
$D_{KL}(Q\ P)$	变分方法中被最小化的间隙	相对熵，两个分布之间的“距离”
最大熵原理	带约束的凸优化 (拉格朗日对偶)	最小化对先验的偏离

关键洞察

1. 能量-损失等价：统计力学中的能量函数对应于机器学习中的损失函数（负对数似然）。最小化能量对应于最大化概率——第四章通过线性回归、逻辑回归、Softmax 回归三个具体例子，展示了这一等价关系如何将“设计损失函数”转化为“选择噪声分布”这一更基本的问题。
2. 配分函数的普遍困难：无论在物理还是学习中，计算归一化常数（配分函数）都是核心挑战。状态数目随变量个数指数增长，这一困难无法通过增加算力根本解决，只能借助近似方法绕过——这正是第五章引入马尔可夫随机场语言、系统梳理这一困难的原因。
3. 变分原理的统一：变分自由能（物理）和证据下界（学习）是同一数学对象。最小化自由能等价于最大化 ELBO，两者共享同一个基于 KL 散度非负性的证明——第六章给出了这一证明，并通过平均场近似展示了变分方法在实践中的具体运用（以及其局限性）。
4. 最大熵的基础性：玻尔兹曼分布不是假设，而是从最大熵原理推导出来的。第七章表明，物理直觉（系统与热库交换能量）、变分原理（第六章）、信息论约束（本章）——三条独立的推导路径最终收敛到同一个数学对象；损失函数视角（第四章）则说明了这一结论为何能够不加改动地覆盖任意一个机器学习模型，而非第四个独立源头。这为统计力学和机器学习提供了共同的信息论基础。
5. 温度的多重角色：温度这一参数在不同语境下反复出现，却始终扮演同一种数学角色——控制“确定性”与“灵活性”之间的平衡：
 - 物理：控制热涨落的剧烈程度；
 - 学习：控制模型输出的随机性、正则化的强度（第四章 Softmax 的温度参数）；
 - 优化：控制探索与利用之间的平衡。

6. 熵-能量权衡：系统在最小化能量（精确拟合）和最大化熵（保持灵活性）之间寻找平衡，这一权衡由自由能 $F = E - TS$ （第二章）统一刻画。在物理中，这一权衡的方向由热力学第二定律给出；在机器学习中，这与偏差-方差权衡（bias-variance trade-off）具有相似的“拟合精度 $\leftrightarrow$ 复杂度”结构——但这只是结构上的类比，不是数学等价：偏差-方差分解是对期望预测误差的一个独立的精确分解，其中的“方差”项和这里的熵 S 并非同一个数学对象，本书未曾证明二者存在严格对应（这也是上一小节“类比的边界”要强调的事情之一）。

为什么这些联系重要？

1. 概念迁移：物理学的成熟工具（相变理论、重整化群、响应函数等）可以应用于机器学习中尚未被充分理解的现象。
2. 算法启发：许多现代机器学习算法（玻尔兹曼机、变分自编码器、模拟退火）直接源于统计力学，理解其物理起源有助于理解算法为何有效、又在何时失效。
3. 深层理解：物理视角揭示了机器学习方法背后的内在结构、限制和可能性，而不仅仅是“经验上有效的技巧”。
4. 新方向：物理与机器学习的交叉正在催生新的研究方向，包括神经网络的相变与临界现象、深度学习的统计力学理论、量子机器学习，以及神经标度律（neural scaling laws）等。

延伸思考

以下问题没有标准答案，留给读者在学习后续内容的过程中持续思考：

1. 类比的边界：“核心对应关系”之后的“类比的边界”一节列出了五个已知会失效的地方（损失不必是能量、训练不是热平衡、参数空间有冗余、热力学极限未必对应、温度可能只是数学参数）。除了这五点，还有哪些机器学习现象，是你认为物理语言目前描述不了、或者描述起来很勉强的？
2. 因果 vs. 关联：统计力学通常处理平衡态，但机器学习涉及学习动力学（训练过程本身是一个时间演化）。这种时间演化应当如何在物理框架中理解？
3. 量子视角：经典统计力学已经与机器学习建立了深刻联系。量子统计力学又能为量子机器学习提供什么样的洞察？
4. 实际应用：这些理论洞察如何转化为实用的算法改进？物理启发的方法在哪些具体问题上具有优势？

推荐阅读

入门教材

- **Mehta et al. (2019).** *A High-Bias, Low-Variance Introduction to Machine Learning for Physicists*. arXiv:1803.08823. ——专为物理学家撰写的机器学习教程，包含大量统计力学类比。
- **MacKay (2003).** *Information Theory, Inference, and Learning Algorithms*. ——信息论与机器学习的经典教材，物理视角贯穿全书。
- **Murphy (2012).** *Machine Learning: A Probabilistic Perspective*. ——概率机器学习的权威教材。

进阶阅读

- **Carleo et al. (2019).** “Machine Learning and the Physical Sciences.” *Reviews of Modern Physics*. ——物理与机器学习交叉领域的综述。
- **Engel & Van den Broeck (2001).** *Statistical Mechanics of Learning*. ——学习理论的统计力学方法。
- **Opper & Saad (2001).** *Advanced Mean Field Methods: Theory and Practice*. ——平均场理论在机器学习中的应用。

经典论文

- **Jaynes (1957).** “Information Theory and Statistical Mechanics.” *Physical Review*. ——最大熵原理的开创性论文，见第七章。
- **Landauer (1961).** “Irreversibility and Heat Generation in the Computing Process.” *IBM Journal*. ——信息处理的物理成本，见习题 2.3。
- **Hinton & Sejnowski (1986).** “Learning and Relearning in Boltzmann Machines.” ——玻尔兹曼机的原始论文。
- **Amari (1998).** “Natural Gradient Works Efficiently in Learning.” *Neural Computation*. ——自然梯度与信息几何，见习题 3.5。
- **Tishby et al. (2000).** “The Information Bottleneck Method.” arXiv:physics/0004057. ——信息瓶颈理论，见习题 6.4。

在线资源

- **Stanford CS229:** *Machine Learning* (Andrew Ng) ——经典的机器学习课程。
- **Princeton COS 597F:** *Advanced Topics in Machine Learning: Physics for Machine Learning* ——物理与机器学习的交叉课程。
- **Blog:** *The Science of Deep Learning* (Francis Bach 等人的系列博客)。

下一部分预告

在第二部分中，我们将从这些基本概念出发，研究具体的神经网络模型及其物理对应：

- **Hopfield** 网络：如何用伊辛模型理解联想记忆？
- 玻尔兹曼机：如何用统计采样进行学习？
- 受限玻尔兹曼机 (**RBM**)：深度学习的早期成功。
- 深度学习的统计力学理论：为什么深度网络能够泛化？

我们将看到，第一部分建立的数学框架如何应用于理解真实的神经网络，以及物理直觉如何指导算法设计。

常用记号与公式速查

§A.1 概率论与数学工具记号

本节汇总全书通用、不依赖某一章具体主题的两类基础记号——概率论记号，以及求导、对数等数学工具记号。后面三节（图与马尔可夫随机场记号、变分自由能与 KL 散度、拉格朗日乘数法）则分别对应第五、六、七章的专门内容，与本节性质不同。

表 A.1: 概率论基本记号

概念	公式	详见
归一化（离散）	$P(x) \geq 0, \sum_x P(x) = 1$	§2.1
归一化（连续）	$P(x) \geq 0, \int P(x) dx = 1$	第三、四章
联合、边缘概率	$P(x) = \sum_y P(x, y)$	第三章“预备定义”
条件概率	$P(x y) = \frac{P(x, y)}{P(y)} (P(y) > 0)$	§3.2
独立性	$X \perp Y \Leftrightarrow P(x, y) = P(x)P(y)$	§3.2
条件独立性	$X \perp Y Z \Leftrightarrow P(x, y z) = P(x z)P(y z)$	第五章（图上的分离）
贝叶斯定理	$P(x y) = \frac{P(y x)P(x)}{P(y)}$	式 (3.10)，第三章
期望值	$\langle A \rangle = \sum_x P(x)A(x)$	第二章“预备定义”
方差	$\text{Var}(A) = \langle A^2 \rangle - \langle A \rangle^2$	第二章“预备定义”
i.i.d. 似然	$P(\mathcal{D} \theta) = \prod_n P(y^{(n)} \mathbf{x}^{(n)}, \theta)$	§3.2

§A.2 图与马尔可夫随机场记号

使用提醒：“局部 $\Rightarrow$ 全局”这一方向的等价性不是无条件成立的，需要联合分布处处为正 ($P(\mathbf{x}) > 0$) 这一额外条件，见 §5.2 中对 Moussouris (1974) 反例的讨论。附录 C 补充了马尔可夫链（按时间排列，而非按图排列的马尔可夫性质）及其收敛理论，与本节的马尔可夫场是两个不同但相关的概念，请勿混淆。

表 A.2: 全书反复用到的数学恒等式

工具	公式	详见
对数恒等式	$\ln(ab) = \ln a + \ln b, \ln(a/b) = \ln a - \ln b$	全书反复使用
泰勒展开 (一元)	$g(a + \delta) = g(a) + \delta g'(a) + \frac{1}{2} \delta^2 g''(a) + \dots$	§2.2
$\ln Z$ 生成矩	$\langle E \rangle = -\frac{\partial \ln Z}{\partial \beta}, \text{Var}(E) = \frac{\partial^2 \ln Z}{\partial \beta^2}$	§2.2
梯度记号	$\nabla_{\theta} L = \left(\frac{\partial L}{\partial \theta_1}, \dots, \frac{\partial L}{\partial \theta_d} \right)$	第三、四章
Hessian 记号	$H_{ij} = \frac{\partial^2 L}{\partial \theta_i \partial \theta_j}$	第三章习题 (Fisher 信息)
向量求导	$\frac{\partial(\boldsymbol{\theta}^T \mathbf{x})}{\partial \boldsymbol{\theta}} = \mathbf{x}$	§4.2“预备法则”

表 A.3: 图论与 MRF 基本记号

概念	公式/定义	详见
图	$G = (V, E)$, V 为节点集, E 为边集	§5.2
邻域	$N(i) = \{j \in V : (i, j) \in E\}$	§5.2
团 (clique)	$c \subseteq V$, c 内任意两节点均相邻	定义 5.1
局部马尔可夫性质	$X_i \perp X_{V \setminus (\{i\} \cup N(i))} \mid X_{N(i)}$	§5.2
全局马尔可夫性质	S 分离 $A, B \Rightarrow X_A \perp X_B \mid X_S$	§5.2
Gibbs 分解	$P(\mathbf{x}) = \frac{1}{Z} \prod_{c \in C} \psi_c(\mathbf{x}_c) = \frac{1}{Z} e^{-E(\mathbf{x})}$	定理 5.1 (Hammersley–Clifford)

§A.3 变分自由能与 KL 散度主公式

全书“变分”相关的全部结论，最终都归结为下面这一条不等式及其等号条件：

$$D_{KL}(Q \| P) = \frac{1}{T} F[Q] + \ln Z \geq 0 \implies F[Q] \geq F_{\text{true}} = -T \ln Z,$$

等号成立当且仅当 $Q = P$ 。其中 $D_{KL} \geq 0$ (Gibbs 不等式) 本身由 Jensen 不等式导出，完整证明见定理 6.1 的证明过程。机器学习语境下的对应版本 (ELBO) 为：

$$\ln P(\mathbf{v}) = \mathcal{L}[Q] + D_{KL}(Q(\mathbf{h}) \| P(\mathbf{h}|\mathbf{v})) \implies \mathcal{L}[Q] \leq \ln P(\mathbf{v}),$$

详见定理 6.2。表 A.4 汇总了两套语言的对应关系。

表 A.4: 变分自由能与 ELBO 的记号对照

统计物理（第六章 §6.1）	机器学习（第六章 §6.2）
$F[Q] \geq F_{\text{true}}$	$\mathcal{L}[Q] \leq \ln P(\mathbf{v})$
最小化 $F[Q]$	最大化 $\mathcal{L}[Q]$
$Q(\mathbf{x}) \rightarrow P(\mathbf{x})$	$Q(\mathbf{h}) \rightarrow P(\mathbf{h} \mathbf{v})$

§A.4 拉格朗日乘数法（用于带约束的熵极值问题）

第六章（平均场方程）与第七章（最大熵原理）都需要在归一化约束（有时还有矩约束）下，对 $-\sum_x P(x) \ln P(x)$ 这一类熵泛函求极值。由于本书中的状态空间始终离散， $P(x)$ 本质上是有限个独立实数，“对 $P(\cdot)$ 求变分”因此就是普通多元微积分中的拉格朗日乘数法，而非需要额外工具的变分法——完整的方法论说明见第六章 §6.4“预备说明”。一般格式：

$$\Lambda = \left[-\sum_x P(x) \ln P(x) \right] + \lambda_0 \left(1 - \sum_x P(x) \right) + \sum_k \lambda_k \left(\bar{f}_k - \sum_x P(x) f_k(x) \right),$$

对每个 $P(x')$ （视为独立实变量）求偏导并令其为零，解得的极值分布必为指数族形式 $P(x) \propto \exp(-\sum_k \lambda_k f_k(x))$ ——具体推导见第七章 §7.1。

常见概率分布与统计量表

本附录汇总全书用到的概率分布，只给出定义、均值与方差，不重复推导——每个分布对应的负对数似然损失，都已经在正文对应章节里从第一性原理推导过一遍，这里的作用仅仅是查阅。

§B.1 常见概率分布

表 B.1: 离散分布汇总

分布	概率质量函数	均值 / 方差	出现于
伯努利 (Bernoulli)	$P(x) = p^x(1-p)^{1-x}, x \in \{0, 1\}$	$\langle x \rangle = p$ $\text{Var}(x) = p(1-p)$	§3.3、§4.3
二项 (Binomial)	$P(k) = \mathcal{C}_N^k p^k (1-p)^{N-k}$	$\langle k \rangle = Np$ $\text{Var}(k) = Np(1-p)$	§3.3 (抛硬币 N 次)
类别 (Categorical)	$P(y = k) = \pi_k, \sum_k \pi_k = 1$	—	§4.4 (Softmax)
泊松 (Poisson)	$P(k) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots$	$\langle k \rangle = \lambda$ $\text{Var}(k) = \lambda$	第四章习题 (泊松回归)

表 B.2: 连续分布汇总

分布	概率密度函数	均值 / 方差	出现于
高斯 (Gaussian)	$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$	$\langle x \rangle = \mu$ $\text{Var}(x) = \sigma^2$	§4.2 (噪声模型)
拉普拉斯 (Laplace)	$p(x) = \frac{1}{2b} \exp\left(-\frac{ x-\mu }{b}\right)$	$\langle x \rangle = \mu$ $\text{Var}(x) = 2b^2$	第四章习题 (L_1 损失)

■ 为什么这两张表里都没有“配分函数”这一列？

细心的读者可能已经注意到：本表中每一个分布的归一化常数（ $\frac{1}{\sqrt{2\pi}\sigma^2}$ 、 $\frac{1}{2b}$ 、 $\binom{N}{k}$ 等）扮演的角色，正是第二章反复强调的“配分函数” Z 的倒数——只是在概率论教材里，这个角色通常不被单独命名。伯努利分布是第二章“双态系统”最直接的机器学习版本；高斯、拉普拉斯这类连续分布的“能量” $E(x) = -\ln p(x)$ ，就是第四章损失函数推导的起点。把这两张表和第二章的种子表（表 2.8）对照着看，能更清楚地看到“分布” $\leftrightarrow$ “能量”——这一对应关系在每一行都成立——不论离散还是连续。

§B.2 一般定义（不限于特定分布）

表 B.3: 期望、方差、协方差的一般定义

量	定义	详见
期望	$\langle X \rangle = \sum_x P(x) x$ （或 $\int p(x) x dx$ ）	第二章“预备定义”
方差	$\text{Var}(X) = \langle X^2 \rangle - \langle X \rangle^2$	第二章“预备定义”
协方差	$\text{Cov}(X, Y) = \langle XY \rangle - \langle X \rangle \langle Y \rangle$	未在正文单独定义，随时可用

■ 指数族：贯穿本表的隐藏结构

表 B.1 与表 B.2 中的全部分布，都可以写成统一的指数族（exponential family）形式 $P(y|\eta) = h(y) \exp(\eta y - A(\eta))$ ——这正是第四章挑战题“广义线性模型与指数族分布”要求读者独立验证的内容。若你在做那道习题时需要用到某个具体分布的公式，直接查阅本附录，而不必翻回各章正文。

马尔可夫链与 MCMC 基础

第五章 §5.2 借用了马尔可夫链（按时间排列）的定义，引出马尔可夫场（按图排列）；这是两个相关但不同的概念，本附录要处理的是前者——不是“图上的局部性”，而是“反复随机游走，最终会走向哪里”这个问题。第五章 §5.4 提到的 MCMC、Gibbs 采样，以及附录中“Gibbs 采样与图像分割”这道习题，都需要用到这里的结果。

§C.1 平稳分布：反复游走的终点

考虑一个在有限状态集合 $\{x\}$ 上随机跳转的过程：在时刻 t 处于状态 x ，以概率 $T(x \rightarrow x')$ 跳转到 x' （ T 称为转移概率，满足 $\sum_{x'} T(x \rightarrow x') = 1$ ）。若时刻 t 的状态分布为 $P_t(x)$ ，则时刻 $t+1$ 的分布为

$$P_{t+1}(x') = \sum_x P_t(x) T(x \rightarrow x'). \quad (\text{C.1})$$

一个分布 $\pi(x)$ 称为这条链的平稳分布（stationary distribution），如果把它代入式 (C.1) 后自身不再改变：

$$\pi(x') = \sum_x \pi(x) T(x \rightarrow x'). \quad (\text{C.2})$$

MCMC 方法的核心想法是：反过来使用这一关系——不是先有转移规则、再问“稳定在哪个分布”，而是先指定想要采样的目标分布（例如玻尔兹曼分布 $P(x) = e^{-\beta E(x)} / Z$ ），再设计一套转移规则 T ，使得这个目标分布恰好是它的平稳分布。只要设计得当，从任意初始状态出发反复按 T 跳转，跳转足够多次之后，状态出现的频率就会逼近目标分布——而这一切都不需要先算出难以计算的 Z ，因为 T 的构造中 Z 会自动约掉（下文很快会看到这一点）。

§C.2 细致平衡：一个容易验证的充分条件

直接验证式 (C.2) 通常很麻烦。一个更容易操作、也更常用的充分条件是细致平衡（detailed balance）：

$$\pi(x) T(x \rightarrow x') = \pi(x') T(x' \rightarrow x), \quad \forall x, x'. \quad (\text{C.3})$$

直观上，这说明“从 x 流向 x' 的概率流”与“从 x' 流回 x 的概率流”完全相等，处处平衡，不存在净流动。

■ 验证：细致平衡蕴含平稳性

将式 (C.3) 两边对 x 求和：

$$\sum_x \pi(x) T(x \rightarrow x') = \sum_x \pi(x') T(x' \rightarrow x) = \pi(x') \sum_x T(x' \rightarrow x) = \pi(x'),$$

最后一步用到了转移概率的归一化 $\sum_x T(x' \rightarrow x) = 1$ 。这正是式 (C.2)，即 π 是平稳分布。 ■

注意这只是充分条件，不是必要条件——存在平稳分布不满足细致平衡的马尔可夫链，但满足细致平衡的链，其平稳性总是可以像上面这样直接代数验证，这正是它在实践中被广泛使用的原因。

§C.3 Metropolis 算法：让细致平衡自动成立

给定目标分布 $\pi(x) = e^{-\beta E(x)} / Z$ ，Metropolis 算法按以下方式构造转移概率：从当前状态 x 出发，

(1) 用一个对称的提议分布 $g(x \rightarrow x') = g(x' \rightarrow x)$ 提出一个候选状态 x' （例如“等概率地提议翻转任意一个自旋”）；

(2) 以接受概率

$$A(x \rightarrow x') = \min \left(1, \frac{\pi(x')}{\pi(x)} \right) = \min(1, e^{-\beta[E(x') - E(x)]}) \quad (\text{C.4})$$

接受这一候选（否则停留在原状态 x ）。

式 (C.4) 的关键之处在于： $\pi(x')/\pi(x) = e^{-\beta E(x')}/e^{-\beta E(x)}$ ，配分函数 Z 在比值中被约掉了——这正是 MCMC 方法能够绕开“ Z 难以计算”这一第五章反复强调的困难的根本原因：采样从不需要知道 Z ，只需要知道能量差。

■ 验证：Metropolis 转移满足细致平衡

设 $\pi(x') \geq \pi(x)$ （另一种情形同理）。此时 $T(x \rightarrow x') = g(x \rightarrow x') \cdot 1$ （式 (C.4) 中比值 ≥ 1 ，接受概率取 1），而 $T(x' \rightarrow x) = g(x' \rightarrow x) \cdot \frac{\pi(x)}{\pi(x')}$ 。代入细致平衡条件左右两边：

$$\begin{aligned} \pi(x) T(x \rightarrow x') &= \pi(x) g(x \rightarrow x'), \\ \pi(x') T(x' \rightarrow x) &= \pi(x') g(x' \rightarrow x) \frac{\pi(x)}{\pi(x')} = \pi(x) g(x' \rightarrow x). \end{aligned}$$

由 g 对称（ $g(x \rightarrow x') = g(x' \rightarrow x)$ ），两式相等。细致平衡对任意能量函数 $E(x)$ 自动成立，这正是 Metropolis 算法的巧妙之处：接受概率的设计专门为了让式 (C.3) 恒成立。 ■

完全手算的例子：回到第二章的双态系统

用第二章表 2.4 中 $E_0 = 0, E_1 = \varepsilon = 1, k_B T = 1$ （即 $\beta = 1$ ）的双态系统，把 Metropolis 算法从头到尾算一遍。已知精确解为 $\pi(0) = P_0 = 0.731$ ， $\pi(1) = P_1 = 0.269$ 。系统只有两个状态，

提议分布是平凡的（“提议跳到另一个状态”， $g = 1$ ，自动对称）。

从状态 0 提议跳到状态 1： $\Delta E = E_1 - E_0 = 1$ ，接受概率 $A(0 \rightarrow 1) = \min(1, e^{-1}) = e^{-1} \approx 0.368$ 。

从状态 1 提议跳到状态 0： $\Delta E = E_0 - E_1 = -1$ ，接受概率 $A(1 \rightarrow 0) = \min(1, e^1) = 1$ 。

于是转移概率为 $T(0 \rightarrow 1) = 0.368$ ， $T(0 \rightarrow 0) = 0.632$ ， $T(1 \rightarrow 0) = 1$ ， $T(1 \rightarrow 1) = 0$ 。
验证细致平衡：

$$\pi(0)T(0 \rightarrow 1) = 0.731 \times 0.368 = 0.269, \quad \pi(1)T(1 \rightarrow 0) = 0.269 \times 1 = 0.269,$$

两者相等，细致平衡成立。验证平稳性（直接代入式 (C.2) 核对）：

$$\pi(0)T(0 \rightarrow 0) + \pi(1)T(1 \rightarrow 0) = 0.731 \times 0.632 + 0.269 \times 1 = 0.462 + 0.269 = 0.731 = \pi(0),$$

$$\pi(0)T(0 \rightarrow 1) + \pi(1)T(1 \rightarrow 1) = 0.731 \times 0.368 + 0.269 \times 0 = 0.269 = \pi(1),$$

丝毫不差。也就是说：即使完全不知道“双态系统的精确解是 0.731, 0.269”这件事，只要按 Metropolis 规则反复对这两个状态做随机游走——多数时候停在能量较低的状态 0，偶尔以概率 0.368 跳到能量较高的状态 1，跳上去之后又几乎必然（概率 1）跳回来——长期来看，处于每个状态的时间比例就会自动收敛到 0.731 : 0.269，与第二章从配分函数算出的精确解完全一致。这正是 MCMC 方法“用采样代替精确求和”这一思想最简单、也最可以亲眼验证的例子。

§ C.4 Gibbs 采样：一种特殊的、接受概率恒为 1 的 Metropolis 算法

第五章习题要求实现的 Gibbs 采样，是 Metropolis 算法在“多变量联合分布”场景下的一个特例。给定联合分布 $P(\mathbf{x}) = P(x_1, \dots, x_N)$ ，Gibbs 采样每一步只更新一个变量 x_i ，把它直接替换为从条件分布 $P(x_i | \mathbf{x}_{-i})$ 中抽取的新值（ $\mathbf{x}_{-i}$ 表示除 x_i 外的全部变量，在这一步中保持不变）。

可以证明，这一规则恰好是提议分布 $g(\mathbf{x} \rightarrow \mathbf{x}') = P(x'_i | \mathbf{x}_{-i})$ （只在第 i 个坐标上提议、且提议本身就按条件分布抽取）的 Metropolis 算法，其接受概率恒等于 1：

$$A(\mathbf{x} \rightarrow \mathbf{x}') = \min \left(1, \frac{\pi(\mathbf{x}') g(\mathbf{x}' \rightarrow \mathbf{x})}{\pi(\mathbf{x}) g(\mathbf{x} \rightarrow \mathbf{x}')} \right) = \min \left(1, \frac{P(x'_i | \mathbf{x}_{-i}) P(x_i | \mathbf{x}_{-i})}{P(x_i | \mathbf{x}_{-i}) P(x'_i | \mathbf{x}_{-i})} \right) = 1,$$

这里用到了 $\pi(\mathbf{x}) = P(\mathbf{x}_{-i})P(x_i | \mathbf{x}_{-i})$ （ $\mathbf{x}_{-i}$ 在这一步不变，两边的 $P(\mathbf{x}_{-i})$ 约去）。“永远接受”意味着 Gibbs 采样不需要计算任何接受/拒绝的比较，只需要能从每个变量的条件分布中抽样——这正是第五章习题里“逐个像素、根据条件概率采样更新”这一具体做法的理论依据。

§ C.5 遍历性：反复跳转真的能走到每一个角落吗？

细致平衡保证了目标分布是一个平稳分布，但没有保证“从任意起点出发反复游走，最终一定会收敛到它”——原则上可能存在多个平稳分布，或者链被“困”在状态空间的一部分、永远到不了另一部分。排除这些病态情形的条件称为遍历性（ergodicity），大致要求：

- 不可约性（irreducibility）：从任意状态出发，都存在一条概率非零的路径到达任意其他状态；

- 非周期性 (aperiodicity): 不存在使链只能在固定周期后才可能回到某状态这种“打拍子”式的限制。

只要转移规则满足这两条 (Metropolis 与 Gibbs 采样在提议分布“哪里都有可能去到”的前提下通常自动满足), 马尔可夫链遍历定理保证: 无论从哪个初始状态出发, $t \rightarrow \infty$ 时刻的分布 $P_t(x)$ 都会收敛到唯一的平稳分布 $\pi(x)$, 且沿途访问各状态的时间平均也收敛到 $\pi(x)$ 。这一定理的证明超出本附录范围 (属于概率论中马尔可夫链理论的标准内容), 这里只陈述结论、并在上面的双态系统例子中直接验证了它的结果。

■ 小结: 这如何回答第五章的困难

第五章的核心困境是: 配分函数 Z 的计算随变量数目指数增长, 无法穷举。本附录说明了 MCMC 方法如何绕开这一困难——Metropolis 与 Gibbs 采样的接受概率或条件分布, 都只依赖于能量的差值或局部条件分布, 从未出现过全局求和 $Z = \sum_{\mathbf{x}} e^{-\beta E(\mathbf{x})}$ 本身。代价是: 只能得到一个通过反复采样、随时间收敛的近似, 而非一步到位的精确解——这与第六章变分方法“用近似换取可计算性”是同一种权衡的两种不同实现方式。

参考文献

- [1] M. Mézard, A. Montanari, *Information, Physics, and Computation*, Oxford University Press, 2009.
- [2] E. Ising, “Beitrag zur Theorie des Ferromagnetismus,” *Zeitschrift für Physik*, 31(1):253–258, 1925.
- [3] L. Onsager, “Crystal Statistics. I. A Two-Dimensional Model with an Order-Disorder Transition,” *Physical Review*, 65(3–4):117–149, 1944.
- [4] N. Metropolis, A. W. Rosenbluth, M. N. Rosenbluth, A. H. Teller, E. Teller, “Equation of State Calculations by Fast Computing Machines,” *The Journal of Chemical Physics*, 21(6):1087–1092, 1953.
- [5] W. K. Hastings, “Monte Carlo Sampling Methods Using Markov Chains and Their Applications,” *Biometrika*, 57(1):97–109, 1970.
- [6] C. H. Bennett, “The Thermodynamics of Computation—a Review,” *International Journal of Theoretical Physics*, 21(12):905–940, 1982.
- [7] R. Landauer, “Irreversibility and Heat Generation in the Computing Process,” *IBM Journal of Research and Development*, 5(3):183–191, 1961.
- [8] C. E. Shannon, “A Mathematical Theory of Communication,” *Bell System Technical Journal*, 27(3):379–423, 27(4):623–656, 1948.
- [9] S. Kullback, R. A. Leibler, “On Information and Sufficiency,” *Annals of Mathematical Statistics*, 22(1):79–86, 1951.
- [10] E. T. Jaynes, “Information Theory and Statistical Mechanics,” *Physical Review*, 106(4):620–630, 1957.
- [11] A. L. Berger, S. A. Della Pietra, V. J. Della Pietra, “A Maximum Entropy Approach to Natural Language Processing,” *Computational Linguistics*, 22(1):39–71, 1996.
- [12] N. Tishby, F. C. Pereira, W. Bialek, “The Information Bottleneck Method,” arXiv:physics/0004057, 2000.
- [13] J. M. Hammersley, P. Clifford, “Markov Fields on Finite Graphs and Lattices,” unpublished manuscript, 1971.

- [14] J. Besag, "Spatial Interaction and the Statistical Analysis of Lattice Systems," *Journal of the Royal Statistical Society, Series B*, 36(2):192–236, 1974.
- [15] S. Geman, D. Geman, "Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 6(6):721–741, 1984.
- [16] R. Kindermann, J. L. Snell, *Markov Random Fields and Their Applications*. American Mathematical Society, 1980.
- [17] R. A. Fisher, "On the Mathematical Foundations of Theoretical Statistics," *Philosophical Transactions of the Royal Society A*, 222:309–368, 1922.
- [18] J. A. Nelder, R. W. M. Wedderburn, "Generalized Linear Models," *Journal of the Royal Statistical Society, Series A*, 135(3):370–384, 1972.
- [19] A. P. Dempster, N. M. Laird, D. B. Rubin, "Maximum Likelihood from Incomplete Data via the EM Algorithm," *Journal of the Royal Statistical Society, Series B*, 39(1):1–38, 1977.
- [20] S. Amari, "Natural Gradient Works Efficiently in Learning," *Neural Computation*, 10(2):251–276, 1998.
- [21] J. J. Hopfield, "Neural Networks and Physical Systems with Emergent Collective Computational Abilities," *Proceedings of the National Academy of Sciences*, 79(8):2554–2558, 1982.
- [22] D. H. Ackley, G. E. Hinton, T. J. Sejnowski, "A Learning Algorithm for Boltzmann Machines," *Cognitive Science*, 9(1):147–169, 1985.
- [23] P. Smolensky, "Information Processing in Dynamical Systems: Foundations of Harmony Theory," in D. E. Rumelhart, J. L. McClelland (eds.), *Parallel Distributed Processing*, Vol. 1, Chapter 6, pp. 194–281. MIT Press, 1986.
- [24] G. E. Hinton, T. J. Sejnowski, "Learning and Relearning in Boltzmann Machines," in D. E. Rumelhart, J. L. McClelland (eds.), *Parallel Distributed Processing*, Vol. 1, Chapter 7, pp. 282–317. MIT Press, 1986.
- [25] D. E. Rumelhart, G. E. Hinton, R. J. Williams, "Learning Representations by Back-Propagating Errors," *Nature*, 323:533–536, 1986.
- [26] R. Salakhutdinov, G. Hinton, "Deep Boltzmann Machines," *Proceedings of the 12th International Conference on Artificial Intelligence and Statistics (AISTATS)*, pp. 448–455, 2009.
- [27] M. I. Jordan, Z. Ghahramani, T. S. Jaakkola, L. K. Saul, "An Introduction to Variational Methods for Graphical Models," *Machine Learning*, 37(2):183–233, 1999.

- [28] R. M. Neal, G. E. Hinton, “A View of the EM Algorithm that Justifies Incremental, Sparse, and Other Variants,” in M. I. Jordan (ed.), *Learning in Graphical Models*, pp. 355–368. Kluwer Academic Publishers, 1998.
- [29] D. M. Blei, A. Kucukelbir, J. D. McAuliffe, “Variational Inference: A Review for Statisticians,” *Journal of the American Statistical Association*, 112(518):859–877, 2017.
- [30] D. P. Kingma, M. Welling, “Auto-Encoding Variational Bayes,” *International Conference on Learning Representations (ICLR)*, 2014.
- [31] P. Mehta, M. Bukov, C.-H. Wang, A. G. R. Day, C. Richardson, C. K. Fisher, D. J. Schwab, “A High-Bias, Low-Variance Introduction to Machine Learning for Physicists,” *Physics Reports*, 810:1–124, 2019.
- [32] G. Carleo, I. Cirac, K. Cranmer, L. Daudet, M. Schuld, N. Tishby, L. Vogt-Maranto, L. Zdeborová, “Machine Learning and the Physical Sciences,” *Reviews of Modern Physics*, 91:045002, 2019.
- [33] Y. Bahri, J. Kadmon, J. Pennington, S. S. Schoenholz, J. Sohl-Dickstein, S. Ganguli, “Statistical Mechanics of Deep Learning,” *Annual Review of Condensed Matter Physics*, 11:501–528, 2020.
- [34] Y. LeCun, Y. Bengio, G. Hinton, “Deep Learning,” *Nature*, 521:436–444, 2015.
- [35] D. J. C. MacKay, *Information Theory, Inference, and Learning Algorithms*. Cambridge University Press, 2003.
- [36] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. MIT Press, 2012.
- [37] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [38] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*. MIT Press, 2016.
- [39] A. Engel, C. Van den Broeck, *Statistical Mechanics of Learning*. Cambridge University Press, 2001.
- [40] M. Oppen, D. Saad (eds.), *Advanced Mean Field Methods: Theory and Practice*. MIT Press, 2001.